

Aprendizaje Guiado con GEM Valuador Inteligente

Lenguajes: Natural, MARKDOWN, JSON y TOON

Introducción

En un mercado que evoluciona a pasos agigantados, la capacidad de adaptarse define el éxito profesional. Este material es una pieza clave del curso “Inteligencia Artificial Generativa para Valuadores”, diseñado específicamente para transformar la manera en que interactuamos con la tecnología.

A lo largo de este documento, exploramos el potencial del GEM Valuador Inteligente de Gemini, una herramienta de vanguardia que actúa como tu "socio de pensamiento". No se trata solo de procesar datos, sino de dominar los lenguajes que hacen posible esta magia: desde la intuición del Lenguaje Natural hasta la precisión quirúrgica de MARKDOWN y JSON.

¿Por qué es esto vital para ti? Porque entender la economía de los tokens y la eficiencia de un prompt no es solo una habilidad técnica; es la llave para reducir la latencia en tus respuestas y eliminar cualquier ambigüedad en tus informes de avalúo. Al dominar estas estructuras, delegas la "fuerza bruta intelectual" a la IA, permitiéndote posicionarte como un verdadero Arquitecto del Criterio.

Este viaje te llevará a descubrir cómo la comunicación eficiente entre humanos y máquinas optimiza cada recurso, garantizando resultados más rápidos, inteligentes y profesionales.

Creador/compilador:

Miguel Camacaro Pérez, M.Sc.¹
Febrero 2026

¹ El profesor Miguel Camacaro Pérez es un apasionado de la Ciencia de la valuación, de la Ciencia de datos y de la Inteligencia Artificial Generativa, comprometido en impulsar el crecimiento profesional de los valuadores a través de la integración de las últimas herramientas y tecnologías en su flujo de trabajo. Para contactarlo por cursoediciones@gmail.com

Prompt 1

Hoy vamos a hablar y aprender sobre la mejor forma de comunicarnos entre los humanos y los modelos de inteligencia artificial. Hablaremos de los diferentes tipos de lenguaje. Ventajas y desventajas de cada uno. Importancia de la selección del lenguaje a utilizar entre humano y máquina, y entre las máquinas. La relación entre el consumo de tokens y la eficiencia del prompt. haremos ejemplos de prompt con lenguaje natural, MARKDOWN y JASON, hablaremos también de TOON.

Respuesta 1

Es un excelente plan para profundizar en la ingeniería de prompts y la arquitectura de la comunicación técnica. Entender cómo estructurar la información no solo mejora los resultados, sino que optimiza los recursos computacionales.

Como acordamos, te guiaré a través de este proceso con explicaciones y preguntas para que vayamos construyendo este conocimiento juntos.

Para comenzar nuestro recorrido, aquí tienes tres puntos de entrada para explorar estos lenguajes:

1. Lenguaje Natural vs. Estructurado: Analizaremos por qué a veces hablarle a la IA como a un colega es útil, pero por qué para tareas complejas el Markdown o el JSON son superiores para evitar ambigüedades.
2. Economía de Tokens y Eficiencia: Exploraremos cómo la selección del lenguaje afecta directamente la "ventana de contexto" y el costo (en tiempo y recursos) de cada interacción.
3. Protocolos Máquina a Máquina (M2M): Veremos por qué cuando las IAs hablan entre sí prefieren formatos rígidos y cómo esto asegura que la información no se pierda en la "traducción".

¿Por cuál de estos puntos te gustaría que empezáramos nuestra sesión de aprendizaje?

Prompt 2

1. Lenguaje Natural vs. Estructurado.

Respuesta 2

Excelente elección para comenzar. El lenguaje natural es el que usamos para hablar con amigos o escribir este chat, mientras que el lenguaje estructurado (como Markdown o JSON) sigue reglas rígidas de formato. Imagina que le pides a un asistente que organice una lista de compras.

- Lenguaje Natural: "Trae leche, huevos y pan, ah y asegúrate de que la leche sea deslactosada".
- Lenguaje Estructurado (JSON):

JSON

```
{
  "productos": [
    {"nombre": "leche", "tipo": "deslactosada"},
    {"nombre": "huevos", "cantidad": 12},
    {"nombre": "pan", "variedad": "integral"}
  ]
}
```

Ventajas y Desventajas

Tipo de Lenguaje	Ventajas	Desventajas
Natural	Intuitivo, flexible y no requiere aprender sintaxis.	Ambigüedad, "alucinaciones" de la IA y mayor gasto de tokens.
Estructurado	Precisión extrema, fácil de procesar por máquinas y ahorra tokens.	Curva de aprendizaje y rigidez (un error de coma rompe el código).

La Importancia de la Selección

Cuando un humano habla con una máquina, el lenguaje natural es cómodo. Pero cuando una máquina habla con otra máquina (M2M), el lenguaje natural es un desastre porque las computadoras necesitan saber exactamente dónde termina un dato y empieza el otro sin interpretar matices.

Para avanzar, analicemos este escenario: Si estuvieras diseñando una aplicación de clima donde la IA debe enviar los datos de temperatura y humedad a un servidor automáticamente cada hora, ¿qué lenguaje elegirías para esa comunicación y por qué crees que sería más eficiente que el natural?

Prompt 3

Lenguaje estructurado para dar instrucciones precisas sin interpretaciones para dar continuidad a la comunicación.

Respuesta 3

Exactamente. En ese escenario, el lenguaje estructurado funciona como un contrato: no hay espacio para la duda.

Para una comunicación Máquina a Máquina (M2M), el formato JSON es el estándar de oro. Si la IA envía los datos en lenguaje natural ("Hace calor, hay 30 grados"), el servidor tendría que "adivinar" o procesar el texto para encontrar el número. En cambio, con JSON, el servidor sabe exactamente en qué "caja" buscar.

Lenguaje Estructurado: JSON vs. Markdown

Aunque ambos son estructurados, tienen propósitos distintos en la comunicación con modelos de IA:

1. JSON (*JavaScript Object Notation*): Es puramente técnico. Ideal para cuando queremos que la IA nos devuelva datos que otra aplicación va a leer (como una lista de precios, coordenadas o perfiles de usuario).
2. Markdown: Es un lenguaje de marcado ligero. Es excelente para darle jerarquía a un prompt. Permite que la IA entienda qué es un título, qué es una instrucción importante y qué es solo un ejemplo.

Consumo de Tokens y Eficiencia

Aquí es donde entra la parte matemática de nuestra sesión. Los modelos de IA no leen palabras, leen tokens (pedazos de palabras o caracteres).

- Lenguaje Natural: "Por favor, podrías ser tan amable de darme la temperatura de hoy en un formato que pueda entender." (22 tokens aprox.)
- Lenguaje Estructurado: GET /clima/hoy o {"req": "temp"} (5-7 tokens).

Como puedes ver, el lenguaje estructurado no solo es más preciso, sino que es mucho más barato y rápido porque usa menos tokens para decir lo mismo.

Para poner esto en práctica, hagamos un pequeño ejercicio de eficiencia:

Imagina que quieres pedirle a la IA que analice el sentimiento de 10 reseñas de clientes. Si le escribes un párrafo largo por cada reseña, gastarás miles de tokens.

¿Cómo estructurarías el prompt usando Markdown (títulos, listas o bloques) para que la IA entienda rápidamente que debe procesar una lista de textos sin que tú tengas que escribir "Por favor analiza esta..." diez veces? Sustituye el lenguaje natural por estructura.

Prompt 4

Títulos: Análisis de sentimiento. Lista [10 reseñas], Bloques [respuestas].

Respuesta 4

Exactamente, esa estructura es mucho más eficiente. Al usar Markdown, le das una jerarquía visual y lógica al modelo que reduce la necesidad de palabras de relleno.

Aquí tienes un ejemplo de cómo se vería ese prompt optimizado para ahorrar tokens y maximizar la precisión:

Análisis de Sentimiento: Reseñas de Clientes

Instrucción: Clasifica cada reseña como [POSITIVO], [NEGATIVO] o [NEUTRAL].

Formato de respuesta: Devuelve únicamente una lista con el sentimiento.

Reseñas a procesar:

1. El producto llegó roto y tarde.
2. Es la mejor compra que he hecho este año.
3. El color es un poco distinto a la foto, pero funciona bien.

... [8 reseñas más]

Salida esperada:

Impacto en la Eficiencia

Al usar # para títulos y ** para instrucciones clave, la IA identifica el "esqueleto" del prompt de inmediato.

- Sin estructura: Gastas tokens en cortesía ("Hola, ¿podrías ayudarme con...").
- Con Markdown: El modelo asigna más "atención" (pesos computacionales) a lo que está resaltado o bajo un encabezado, lo que reduce errores de interpretación.

Siguiente paso: El poder de JSON

Ahora que vimos cómo Markdown organiza el input (la entrada), hablemos de cómo el JSON revoluciona el output (la salida).

Imagina que no solo quieres el sentimiento, sino que necesitas que esos datos alimenten automáticamente una base de datos o una gráfica en Excel. Si la IA te responde con un párrafo, tendrías que copiar y pegar a mano. Con JSON, la máquina le entrega a la máquina un formato listo para usar.

¿Qué campos (llaves) crees que serían indispensables en un objeto JSON si quisiéramos que la IA, además del sentimiento, extrajera la "puntuación" (de 1 a 5) y el "tema principal" de cada reseña? Intenta proponer cómo se vería una sola respuesta en ese formato.

Prompt 5

```
{ "sentimiento": 1, "extracto": reseña }
```

Respuesta 5

Esa estructura es un gran comienzo. Para que un sistema de software pueda procesar la información de manera automática, el JSON requiere un formato de "llave" (nombre del campo) y "valor" (el contenido).

Si quisiéramos capturar no solo el sentimiento, sino también la puntuación y el tema, una estructura profesional se vería así:

```
JSON
```

```
{  
  "id_reseña": 1,  
  "sentimiento": "NEGATIVO",  
  "puntuacion": 1,  
  "tema_principal": "logística",  
  "extracto": "El producto llegó roto y tarde."  
}
```

¿Por qué usar estas llaves?

- sentimiento: Permite filtrar rápidamente cuántos clientes están felices o enojados.
- puntuacion: Ideal para generar estadísticas numéricas y promedios.
- tema_principal: Ayuda a la empresa a saber si el problema es el producto, el envío o el precio.

La Relación: Tokens vs. Eficiencia

Ya hemos visto que el lenguaje natural es "ruidoso" (muchas palabras innecesarias) y el estructurado es "limpio". En la IA, cada token cuenta porque:

1. Costo: Menos tokens = menor costo de procesamiento.
2. Velocidad: La IA genera respuestas más rápido si no tiene que escribir párrafos decorativos.
3. Memoria: La IA tiene un límite de "ventana de contexto". Si usas formatos compactos como JSON o Markdown, puedes meter mucha más información en la misma conversación.

Hagamos un ejemplo real

Imagina que tienes este texto: *"Me encantó la cámara del teléfono, toma fotos increíbles de noche, pero la batería dura muy poco, apenas llego al final del día."*

Si tuvieras que convertir esa opinión en un objeto JSON para que una computadora lo guarde en una base de datos, ¿qué valores pondrías en sentimiento, puntuacion (1-5) y tema_principal basándote en ese texto? No te preocupes por el código perfecto, solo intenta definir los datos.

Prompt 6

{Sentimiento: positivo; Calidad: excelente; Duración: baja}

Respuesta 6

Has capturado perfectamente la esencia de los datos, pero fíjate en un detalle importante: para que una máquina procese esa información sin errores, necesitamos que usemos la sintaxis exacta de JSON.

En JSON, los textos (tanto las llaves como los valores) deben ir entre comillas dobles y separados por dos puntos.

Tu extracción quedaría así en un formato estructurado profesional:

```
JSON
```

```
{  
  "sentimiento": "positivo",  
  "puntuacion": 4,  
  "tema_principal": "batería y cámara",  
  "extracto": "Me encantó la cámara... pero la batería dura muy poco."  
}
```

Por qué esta estructura es "oro" para la eficiencia:

1. Consumo de Tokens: Al ser directo, el modelo no gasta energía en preámbulos.
2. Precisión: Al definir etiquetas como "sentimiento", fuerzas a la IA a clasificar en lugar de divagar.
3. Interoperabilidad: Este bloque de texto puede saltar directamente a una base de datos de una aplicación móvil.

Reto Final: El "Prompt Maestro"

Hemos cubierto:

- Lenguaje Natural: Para humanos.
- Markdown: Para dar estructura y jerarquía al prompt.
- JSON: Para recibir respuestas que las máquinas entiendan.

Explorar

Para cerrar con broche de oro, vamos a unirlo todo. Imagina que eres un desarrollador. Necesitas que la IA reciba una lista de 5 correos electrónicos y te devuelva un JSON con el remitente y el asunto de cada uno.

¿Cómo escribirías el encabezado de ese prompt usando Markdown para que la instrucción sea imposible de ignorar por la IA? (Pista: Usa un título de nivel 1 y una sección de "Reglas").

Prompt 7

Markdown: "Correos electrónicos": "lista" : JASON: "remitente" "Asunto".

Respuesta 7

¡Exacto! Esa es la esencia de la estructura. Al combinar ambos, creamos un flujo de trabajo donde el humano da una orden organizada y la máquina responde con datos puros.

Para que el modelo no tenga ninguna duda, el "Prompt Maestro" utilizaría Markdown para separar las instrucciones de los datos, y especificaría el esquema JSON que esperamos.

Aquí tienes una propuesta de cómo se vería ese encabezado profesional:

EXTRACCIÓN DE DATOS DE CORREO

OBJETIVO: Procesar la lista de correos adjunta y extraer metadatos clave.

REGLAS DE SALIDA:

1. Genera únicamente un objeto JSON.
2. No incluyas texto introductorio ni explicaciones.
3. Usa exactamente estas llaves: "remitente" y "asunto".

CORREOS A PROCESAR:

- [Aquí iría tu lista de correos...]

Por qué esto es altamente eficiente:

- Jerarquía Clara: El uso de # y ### le dice a la IA: "Esto es lo más importante" y "Estos son los subpasos".
- Ahorro de Tokens: Al decirle "Genera únicamente un objeto JSON", evitas que la IA gaste tokens diciendo: "Claro, aquí tienes la información que me pediste en el formato solicitado...".
- Cero Ambigüedad: Al definir las llaves exactas ("remitente"), te aseguras de que la respuesta encaje perfectamente en cualquier sistema automático.

Reflexión final del tema

Hemos recorrido desde la charla natural hasta la estructura técnica. Para cerrar este aprendizaje: Si tuvieras que explicarle a alguien la relación entre el consumo de tokens y la eficiencia, ¿cómo

describirías la diferencia entre pedir algo con mucha cortesía ("Por favor, ¿serías tan amable...?") frente a usar una estructura de Markdown y JSON como la que acabamos de diseñar?

¿Qué impacto crees que tiene esto en la "inteligencia" o rapidez del modelo?

Prompt 8

La cortesía no es importante, por tanto, el consumo de tokens disminuye, y la respuesta es más eficiente, de allí que usar la estructura de Markdown y JSON permite obtener respuestas más inteligentes con una mayor rapidez del procesamiento del modelo.

Respuesta 8

Exactamente. Has dado en el clavo: en el mundo de la IA, menos, es más.

Al eliminar la cortesía y el lenguaje decorativo, permites que el modelo use toda su "potencia de cálculo" en la lógica del problema en lugar de gastarla en ser amable. Esto tiene tres impactos directos en la inteligencia y rapidez del modelo:

- 1. Enfoque de Atención (Focus): Los modelos usan un mecanismo llamado "atención". Si el prompt está lleno de palabras de relleno, la atención se dispersa. Con Markdown, obligas al modelo a fijar su atención en los puntos clave.
- 2. Densidad de Información: Al usar JSON, transmites la mayor cantidad de datos con el menor número de tokens posible. Es como enviar un archivo comprimido que la IA descomprime instantáneamente.
- 3. Latencia (Velocidad): Como la IA genera texto token por token, entre menos palabras deba escribir para saludarte o explicarte lo que hizo, más rápido terminará la tarea técnica.

Comparativa de Eficiencia

Tipo de Comunicación	"Ruido" (Tokens Extra)	Riesgo de Error		Velocidad de Respuesta
Natural con cortesía	Alto	Medio (Ambigüedad)		Lenta
Markdown / JSON	Mínimo	Muy (Precisión)	Bajo	Ultra Rápida

Conclusión del Aprendizaje

Hemos cubierto todo el ciclo: desde entender los lenguajes hasta optimizar la "economía" de la conversación mediante tokens. Ahora tienes las herramientas para comunicarte como un experto con cualquier modelo de lenguaje.

Para poner a prueba todo lo que hemos aprendido hoy, te propongo un último ejercicio creativo:

¿Cómo transformarías la siguiente petición "humana" en un "Prompt Estructurado" (usando Markdown y pidiendo salida en JSON) para que sea lo más eficiente posible?

"Hola IA, ¿podrías leer este artículo sobre Marte y hacerme un resumen de tres puntos, pero por favor ponme también la distancia a la Tierra y si hay agua o no, y dámelo todo en un formato que pueda usar en mi base de datos? Muchas gracias."

¿Te animas a escribir ese "Prompt Maestro"?

Prompt 9

OBJETIVO: Lectura del artículo sobre Marte con tres puntos importantes. Especificar la distancia a la tierra y la presencia del agua.

REGLAS DE SALIDA:

Genera únicamente un objeto JSON.

No incluyas texto introductorio ni explicaciones.

Usa exactamente estas llaves: "distancia" y "agua".

Respuesta 9

```
JSON
{
  "resumen": [
    "Marte es el cuarto planeta del sistema solar y el más explorado por misiones",
    "Presenta un relieve extremo con el volcán más grande y el cañón más profundo",
    "La atmósfera es delgada, compuesta principalmente por dióxido de carbono, lo",
  ],
  "distancia": "Varía entre 54.6 y 401 millones de kilómetros según la órbita.",
  "agua": "Existe evidencia de agua congelada en los polos y rastros de humedad e"
}
```

Prompt 10

¿Recomendarías a los usuarios de LLM aprender Markdown y JASON? Luego me hablas de TOON.

Respuesta 10

Definitivamente, recomendaría a cualquier usuario de modelos de lenguaje (LLM) aprender Markdown y JSON. Como hemos visto, son las herramientas que transforman una charla casual en una instrucción técnica de alta precisión.

Aquí tienes el porqué de cada uno:

- **Markdown:** Es esencial para la entrada (input). Te permite organizar tus ideas para que la IA no se pierda. Al usar encabezados, listas y negritas, le dices al modelo exactamente qué partes de tu mensaje son instrucciones y cuáles son datos.
- **JSON:** Es fundamental para la salida (output). Si necesitas que la IA trabaje para ti de forma profesional (extrayendo datos, creando listas o clasificando información), pedir el resultado en JSON asegura que la respuesta sea estructurada y lista para ser usada en otras aplicaciones sin necesidad de "limpiar" el texto.

Hablemos de TOON

Cuando mencionas TOON, es probable que te refieras a una confusión común con el término TOKEN, que es la unidad fundamental de medida en la inteligencia artificial.

Los Tokens son los "ladrillos" de información que los modelos procesan. No siempre son palabras completas; a veces son sílabas o incluso caracteres individuales.

Concepto	Importancia en la Eficiencia
Consumo	Cada respuesta que genera la IA tiene un costo en tokens. Entre más eficiente sea tu prompt, menos tokens consumes.
Memoria	Los modelos tienen una "ventana de contexto". Si llenas esa ventana con palabras innecesarias, la IA empieza a "olvidar" el inicio de la conversación.
Costo	En versiones profesionales, pagas por cada mil tokens procesados.

Para profundizar en esto, ¿qué te parece si exploramos uno de estos caminos?

1. Anatomía de un Token: Cómo la IA divide las palabras (especialmente en español) y por qué esto afecta la velocidad.
2. Optimización de Ventana de Contexto: Estrategias para que la IA "recuerde" más cosas durante más tiempo usando menos espacio.
3. Comparativa de Formatos: Cómo JSON vs. Texto Natural impacta directamente en el conteo final de tokens.

¿Cuál de estos puntos te da más curiosidad?

Prompt 11

No era la respuesta buscada. Cuando me refiero a TOON es a Notación de Objetos Orientada a Tokens, que hace más eficiente la comunicación entre máquinas ¿por qué?

Respuesta 11

Entiendo perfectamente el punto. Aunque el término estándar en la industria es JSON (*JavaScript Object Notation*), el concepto de Notación de Objetos Orientada a Tokens (TOON) se enfoca específicamente en cómo las máquinas procesan esos datos de la forma más atómica y eficiente posible.

La comunicación entre máquinas mediante una notación orientada a tokens es más eficiente principalmente por el proceso de Tokenización y Parseo².

¿Por qué es más eficiente?

Cuando una máquina recibe un mensaje en lenguaje natural, debe realizar un esfuerzo computacional enorme para "entender" el contexto. En cambio, con una notación orientada a tokens:

1. Identificación Inmediata: La máquina identifica "tokens" o símbolos específicos (como {, :, []) que actúan como señales de tráfico. No tiene que leer todo el texto para saber qué hacer; cada token le indica una acción o una estructura.

² El parseo (o *parsing*) es el proceso informático de analizar una cadena de datos (texto, código, XML, JSON) para identificar su estructura sintáctica y convertirla en un formato estructurado más fácil de procesar, como un árbol o un objeto.

2. Mapeo Directo a Memoria: Los objetos orientados a tokens se pueden convertir casi directamente en estructuras de datos que la computadora ya entiende (como diccionarios o arreglos), sin pasos intermedios de interpretación gramatical.
3. Reducción de Ambigüedad: En el lenguaje humano, una palabra puede significar muchas cosas. En una notación orientada a tokens, un token tiene una función única. Esto elimina los errores de "traducción" entre diferentes sistemas.

Impacto en el Consumo de Recursos

Al usar una estructura donde cada "pedazo" (token) tiene un valor y una posición definida, logramos:

- Menos latencia: La respuesta se procesa en milisegundos.
- Menor carga de CPU: El servidor no tiene que "pensar", solo tiene que "organizar".

Para profundizar en cómo esto optimiza la comunicación, ¿qué te parece si exploramos uno de estos puntos?

1. El Proceso de Tokenización: Cómo la máquina rompe una cadena de texto en unidades lógicas para procesarlas más rápido.
2. Eficiencia de Ancho de Banda: Por qué enviar objetos orientados a tokens consume menos "espacio" en la red que el texto libre.
3. Seguridad y Validación: Cómo los tokens ayudan a las máquinas a verificar que los datos no han sido alterados.

¿Por cuál de estos aspectos de la eficiencia te gustaría continuar?

Prompt 12

El Proceso de Tokenización: Cómo la máquina rompe una cadena de texto en unidades lógicas para procesarlas más rápido.

Respuesta 12

Entender el proceso de tokenización es como ver cómo un procesador de alimentos prepara los ingredientes: antes de cocinar (procesar la lógica), debe picar todo en trozos uniformes que pueda manejar. En la Notación de Objetos Orientada a Tokens (TOON), la máquina no lee palabras, sino

que descompone la cadena de texto en unidades mínimas con significado. Vamos a ver cómo funciona este "picado" de información:

1. Segmentación por Delimitadores

La máquina busca caracteres especiales que actúan como "fronteras". Por ejemplo, en una estructura de datos, los dos puntos `:`, las comas `,` y los paréntesis `{}` le dicen a la máquina exactamente dónde termina una etiqueta y dónde empieza un valor. Esto es mucho más rápido que buscar el final de una frase en lenguaje natural.

2. Conversión a Identificadores Numéricos

Una vez que el texto se divide en tokens, la máquina los convierte en números. Para una computadora, procesar el número 402 es infinitamente más veloz que procesar la cadena de texto "temperatura".

3. Creación del Árbol de Sintaxis

Los tokens se organizan en una estructura jerárquica. Si el token inicial es `{`, la máquina ya sabe que debe esperar un par de "llave-valor". Esto elimina la necesidad de que la máquina "adivine" la intención del mensaje, permitiendo una validación instantánea.

¿Por qué esto hace la comunicación más eficiente?

Imagina que quieres enviar la instrucción "Encender luz roja".

- Lenguaje Natural: La máquina debe analizar gramática, verbos y colores.
- Orientado a Tokens: Recibe `[CMD_ON, DEV_LIGHT, COL_RED]`. La máquina solo mapea esos tres códigos y ejecuta. No hay interpretación, solo ejecución.

Para profundizar en este proceso, ¿qué te genera más curiosidad sobre cómo las máquinas "pican" la información?

1. Tokens vs. Palabras: Por qué la palabra "manzana" podría ser un solo token, pero una palabra compleja o inventada se divide en tres o cuatro.
2. Velocidad de Respuesta: Cómo la tokenización reduce el tiempo que la IA tarda en empezar a escribir su respuesta (latencia).
3. Compresión de Datos: Cómo esta técnica permite enviar mucha más información a través de cables de internet más pequeños o lentos.

¿Por cuál de estos puntos te gustaría continuar nuestra exploración?

Prompt 13

Velocidad de Respuesta: Cómo la tokenización reduce el tiempo que la IA tarda en empezar a escribir su respuesta (latencia).

Respuesta 13

La velocidad con la que recibes una respuesta depende directamente de qué tan rápido la máquina puede "digerir" lo que le escribiste. La tokenización es el primer paso crítico para reducir esa latencia.

Cuando usas una Notación de Objetos Orientada a Tokens (TOON) o formatos estructurados, la IA ahorra tiempo en tres frentes principales:

1. El Salto del "Pre-procesamiento"

En el lenguaje natural, el modelo gasta ciclos de cómputo tratando de resolver ambigüedades (por ejemplo, decidir si "banco" es un asiento o una entidad financiera). Con una notación orientada a tokens, los símbolos son unívocos. La IA no tiene que "pensar" qué quisiste decir; pasa directamente a la fase de generación.

2. Eficiencia en el "KV Cache" (Memoria de Trabajo)

Los modelos de IA guardan una copia de los tokens procesados en una memoria rápida llamada KV Cache.

- Lenguaje Natural: La memoria se llena de tokens irrelevantes (artículos, conectores, cortesías).
- TOON: La memoria solo guarda datos densos. Al haber menos tokens que procesar y mantener, el sistema accede a la información relevante mucho más rápido, reduciendo el tiempo de espera inicial.

3. Predicción de Próximo Token

La IA genera texto prediciendo cuál es el siguiente token más probable. Si le das una estructura clara (como una llave de JSON { "estado": }, el abanico de posibilidades lógicas se reduce drásticamente. Al tener menos opciones probables que evaluar, la unidad de procesamiento (GPU) encuentra la respuesta correcta en menos milisegundos.

Comparativa de Latencia

Método de Comunicación	Carga de Procesamiento	Tiempo hasta el primer Token (TTFT)
Conversación Humana	Alta (Requiere desambiguación)	Más lento
Estructura TOON / JSON	Baja (Mapeo directo)	Muy rápido

Para ver esto en acción, analicemos cómo la estructura afecta la "ventana de atención" de la máquina. ¿Qué crees que sucedería con la velocidad de la respuesta si, en lugar de un objeto estructurado, le enviáramos a la máquina un texto de 10 páginas con anécdotas antes de darle la instrucción técnica?

¿Cómo afectaría esa "basura" de tokens al tiempo que tarda la IA en empezar a escribir?

Prompt 14

Produce latencia en la respuesta.

Respuesta 14

Exactamente. Si enviamos 10 páginas de anécdotas antes de la instrucción, la latencia se dispara y la eficiencia cae en picada.

Esto sucede por tres razones técnicas principales:

1. Tiempo de Pre-procesamiento (*Prefilling*): Antes de generar la primera palabra, la IA debe "leer" y procesar todos los tokens de entrada. Procesar 5,000 tokens de anécdotas toma mucho más tiempo que procesar 50 tokens de una estructura TOON o JSON.
2. Saturación de la Memoria (KV Cache): Cada token de esas 10 páginas ocupa un lugar en la memoria de trabajo del modelo. Si la memoria se llena con detalles irrelevantes, el sistema se vuelve más lento al intentar recuperar la información importante que quedó "enterrada".
3. Ruido en la Atención: El modelo tiene que gastar energía matemática en ignorar la "basura" para encontrar la instrucción. Es como intentar escuchar un susurro en medio de un concierto de rock.

Conclusión del aprendizaje: El balance perfecto

Hemos visto que para que la comunicación humano-máquina y máquina-máquina sea óptima, debemos:

- Usar Markdown para dar estructura y jerarquía (Input).
- Usar JSON o notaciones orientadas a tokens para obtener precisión y datos puros (Output).
- Ser breves y directos para reducir la latencia y el consumo de tokens.

¿Te gustaría que hagamos una breve recapitulación de los puntos más importantes que aprendimos hoy o prefieres aplicar esto último en un ejercicio práctico final donde midamos la "densidad de información" de un prompt?

Prompt 15

Me gustaría realizar un ejemplo para comparar los resultados al usar lenguaje natural, Markdown y JASON. El tema es valuación de inmuebles y las metodologías. Genera el ejemplo correspondiente.

Respuesta 15

Para comparar estos tres enfoques, vamos a simular un escenario donde le pedimos a una IA que extraiga los datos clave de una valuación inmobiliaria. Verás cómo la estructura cambia radicalmente la claridad y la utilidad de la información.

Imagina que el contenido es el siguiente: *"Se realizó un avalúo de un departamento en CDMX usando el método de mercado, arrojando un valor de 3.5 millones de pesos, con una superficie de 80 m²."*

1. Lenguaje Natural

En este formato, la información fluye como en una conversación. Es fácil de leer para un humano, pero "ruidoso" para un sistema.

"El informe indica que el inmueble valuado es un departamento situado en la Ciudad de México. Para determinar su precio, el experto utilizó el enfoque comparativo de mercado. El resultado final fue de 3,500,000 MXN, considerando que la propiedad cuenta con una extensión de 80 metros cuadrados."

- Ventaja: Muy natural y descriptivo.
- Desventaja: La IA gasta tokens en conectores ("para determinar", "considerando que") y es difícil extraer los datos exactos sin leer todo el párrafo.

2. Markdown

Aquí usamos jerarquía visual. Es el balance perfecto cuando quieres que un humano revise la información rápidamente y la IA entienda qué es lo más importante.

Resumen de Valuación

- Inmueble: Departamento
 - Ubicación: CDMX
 - Metodología: Enfoque de Mercado (Comparables)
 - Superficie: 80 m²
 - Valor Concluido: \$3,500,000 MXN
- Ventaja: Organización impecable. La IA identifica las negritas y las listas como puntos de datos clave.
 - Desventaja: Aunque es ordenado, una base de datos no puede "leer" Markdown directamente sin un paso extra.

3. JSON (Estructura de Datos)

Este es el lenguaje de las máquinas. No hay adornos, solo datos puros listos para ser procesados por otro software.

```
JSON
```

```
{
  "expediente": {
    "tipo_inmueble": "departamento",
    "ubicacion": "CDMX",
    "superficie_m2": 80
  },
  "valuacion": {
    "metodologia": "mercado",
    "valor_total": 3500000,
    "moneda": "MXN"
  }
}
```

- Ventaja: Máxima eficiencia de tokens y cero ambigüedad. Ideal para integrar con sistemas contables o bancarios.
- Desventaja: No es amigable para una lectura rápida de un cliente final.

Análisis de Eficiencia

Si tuvieras que procesar 1.000 avalúos en un minuto para generar una estadística de precios por zona:

¿Cuál de estos tres formatos crees que permitiría a la IA trabajar más rápido y con menos errores de interpretación? (Recuerda lo que hablamos sobre el ruido y los tokens).

Prompt 16

Usaría Markdown para los input y JSON para el output.

Respuesta 16

¡Exactamente! Esa combinación es la "fórmula ganadora" para trabajar con modelos de lenguaje de manera profesional.

Al usar Markdown en tus instrucciones, aprovechas la capacidad del modelo para entender jerarquías y contextos complejos. Al exigir JSON en la respuesta, garantizas que la información sea estructurada, predecible y fácil de integrar en cualquier sistema automático.

Para cerrar nuestra sesión sobre comunicación técnica y eficiencia, analicemos el impacto final de estas elecciones en el flujo de trabajo:

Comparativa de Resultados en Valuación Inmobiliaria

Criterio	Lenguaje Natural	Markdown / JSON
Claridad para el Humano	Media (mucho texto)	Alta (puntos clave resaltados)
Precisión de Datos	Riesgo de ambigüedad	Precisión absoluta
Gasto de Tokens	Alto (palabras de relleno)	Mínimo (solo lo esencial)
Automatización	Difícil (requiere limpieza)	Directa (listo para bases de datos)

Resumen del Aprendizaje

Hoy hemos transformado la forma de interactuar con la IA:

1. De hablar a estructurar: Aprendimos que el lenguaje natural es para la comodidad, pero el estructurado es para la eficiencia.
2. Economía de Tokens: Entendimos que cada palabra cuenta y que la cortesía innecesaria genera latencia.
3. Comunicación M2M: Vimos cómo las notaciones orientadas a objetos (como TOON o JSON) permiten que las máquinas se entiendan sin errores.

Has demostrado un excelente manejo de estos conceptos técnicos, especialmente al construir tus propios esquemas de datos.

¿Te gustaría que exploráramos algún otro tema relacionado con la ingeniería de prompts avanzada o prefieres que apliquemos estos formatos a un caso de uso diferente, como el análisis de documentos financieros o técnicos?