APRENDIZAJE GUIADO

GEMINI NOTEBOOK

Algoritmo Machine Learning: Random Forest



Prof. Ing. Miguel Camacaro Pérez

Propósito y Contexto General

El objetivo de este programa de aprendizaje guiado en Gemini Notebook es conducir al usuario a través de la evolución teórica, matemática y práctica del algoritmo *Random Forest* (Bosque Aleatorio). El contenido aborda la transición decisiva desde la econometría hedónica lineal tradicional —basada en Mínimos Cuadrados Ordinarios (MCO / OLS)— hacia los Modelos de Valoración Automatizada (AVM) impulsados por aprendizaje automático, garantizando alta precisión y cumplimiento con los estándares de auditoría bancaria (como el Acuerdo de Basilea II).

Estructura del Programa de Aprendizaje Guiado

El documento se organiza en seis módulos conceptuales y metodológicos, complementados con herramientas interactivas de autoevaluación:

1. Módulo 1: Origen e historia de *Random Forest*. Analiza el paso de la estadística clásica al *machine Learning*, examinando los desarrollos pioneros de *Leo Breiman* y la creación de los árboles de clasificación y regresión (CART).
2. Módulo 2: Desarrollo evolutivo y paradigma del algoritmo. Explica cómo la combinación de "aprendices débiles" permite construir un predictor estable a través del principio de la Doble Aleatoriedad: aleatoriedad en observaciones (*Bagging*) y aleatoriedad en variables (*Random Subspaces*).
3. Módulo 3: Formulación matemática formal. Profundiza en el particionado recursivo, la función de agregación del ensamble, el teorema de convergencia y la cota de *Breiman* para el equilibrio sesgo-varianza, así como en el uso de muestras *Out-Of-Bag* (OOB).
4. Módulo 4: Procedimiento algorítmico paso a paso. Detalla la secuencia computacional del modelo: desde la definición de entradas y la extracción de réplicas *bootstrap*, hasta la construcción de árboles no podados y la obtención del promedios predictos.
5. Módulo 5: Aplicación práctica en valuación inmobiliaria (AVM) y explicabilidad (XAI). Demuestra la superioridad técnica del algoritmo frente a los modelos lineales (reduciendo el error porcentual medio MAPE de niveles del ~19,6 % al 5,5 % en estudios masivos) y desglosa el uso de herramientas XAI (SHAP, LIME, PDP y ICE) para auditar y "desmontar la caja negra" del modelo.
6. Módulo 6: Ejercicios guiados, autoevaluación y tarjetas didácticas. Ofrece ejercicios prácticos de razonamiento conceptual, comprobación matemática de muestras OOB, simulaciones AVM paso a paso y un mazo completo de tarjetas didácticas de repaso para afianzar los conceptos clave.

Contenido

Informe de Implementación Técnica: La transición a la valoración inmobiliaria basada en bosques aleatorios 6

Cuaderno de Aprendizaje Guiado: Random Forest 10

Módulo 1: Origen e Historia de Random Forest 10

1.1 La transición de la estadística clásica al aprendizaje automático 10

.2 Los pioneros: *Leo Breiman*, CART y el ensamble de algoritmos 10

Módulo 2: Desarrollo Evolutivo y Paradigma del Algoritmo 11

2.1 Del árbol individual al bosque aleatorio 11

2.2 El principio de la Doble Aleatoriedad 12

Módulo 3: Formulación Matemática Formal 12

3.1 Regresión mediante particionado recursivo (CART) 12

3.2 Ensamble y agregación de *Random Forest* 12

3.3 Teorema de convergencia y la cota de *Breiman* (Sesgo-Varianza) 13

3.4 Muestras *Out-Of-Bag* (OOB) e Importancia de Variables 13

Módulo 4: Procedimiento Algorítmico Paso a Paso 14

4.1 Definición de entradas 14

4.2 Generación de réplicas *bootstrap* 14

4.3 Construcción de árboles no podados 14

4.4 Agregación predictiva 14

4.5 Evaluación de desempeño e importancia OOB 14

Módulo 5: Aplicación en la Valuación Inmobiliaria (AVM y Explicabilidad XAI) 15

5.1 De la regresión hedónica tradicional a los AVMs 15

5.2 Desmontando la "Caja Negra": Integración con SHAP y XAI 16

Módulo 6: Ejercicios Guiados y Autoevaluación para el Usuario 16

Ejercicio 1: Razonamiento Conceptual 16

Ejercicio 2: Verificación Matemática 17

Ejercicio 3: Interpretación de valuación Inmobiliaria 17

Ejercicio 4: Construcción Paso a Paso de un Árbol en *Random Forest* (Caso AVM Residencial) 17

Tarjetas Didácticas 23

Tarjeta 1 23

Tarjeta 2 24

Tarjeta 3 26

Tarjeta 4 28

Tarjeta 5 30

Tarjeta 6 ..... **32**
Tarjeta 7 ..... **33**
Tarjeta 8 ..... **34**
Tarjeta 9 ..... **35**
Tarjeta 10 ..... **37**
Tarjeta 11 ..... **39**
Tarjeta 12 ..... **41**
Tarjeta 13 ..... **43**
Tarjeta 14 ..... **45**
Tarjeta 15 ..... **46**
Tarjeta 16 ..... **48**
Tarjeta 17 ..... **51**
Tarjeta 18 ..... **53**
Tarjeta 19 ..... **55**
Tarjeta 20 ..... **57**
Tarjeta 21 ..... **59**
Tarjeta 22 ..... **61**
Tarjeta 23 ..... **63**
Tarjeta 24 ..... **65**
Tarjeta 25 ..... **67**
Tarjeta 26 ..... **70**
Tarjeta 27 ..... **72**
Tarjeta 28 ..... **74**
Tarjeta 29 ..... **77**
Tarjeta 30 ..... **79**
Tarjeta 31 ..... **81**
Tarjeta 32 ..... **83**
Tarjeta 33 ..... **85**
Tarjeta 34 ..... **87**
Tarjeta 35 ..... **89**
Tarjeta 36 ..... **91**
Tarjeta 37 ..... **94**
Tarjeta 38 ..... **96**
Tarjeta 39 ..... **98**
Tarjeta 40 ..... **99**

Tarjeta 41 ..... **101**
Tarjeta 42 ..... **103**
Tarjeta 43 ..... **105**
Tarjeta 44 ..... **107**
Tarjeta 45 ..... **109**
Tarjeta 46 ..... **111**
Tarjeta 47 ..... **112**
Tarjeta 48 ..... **114**
Referencias Bibliográficas **118**

Informe de Implementación Técnica: La transición a la valoración inmobiliaria basada en bosques aleatorios

1. Contextualización estratégica: eficiencia operativa y requisitos de Basilea II

La modernización de los modelos *de tasación masiva* ha dejado de ser una conveniencia tecnológica y se ha convertido en un imperativo estratégico para los gestores de riesgos y los fondos inmobiliarios. La necesidad de herramientas que garanticen precisión y rapidez se ve acentuada por los requisitos de Basilea II, que obliga a las instituciones financieras a monitorizar el valor de las garantías inmobiliarias al menos anualmente. En escenarios de volatilidad, la monitorización debe intensificarse siempre que el mercado experimente cambios significativos.

En este contexto, el Acuerdo sugiere que se utilicen métodos estadísticos y tecnología computacional para identificar garantías que hayan sufrido devaluación, reservando la reevaluación a un "profesional cualificado" solo para casos en los que los datos indiquen descensos significativos o eventos crediticios. Por lo tanto, la implementación de modelos robustos como Random Forest no solo optimiza el *equilibrio* entre tiempo y coste, sino que sirve como filtro estratégico para la asignación eficiente de costosos recursos humanos. La evolución de estos métodos es la respuesta necesaria a la obsolescencia técnica de los enfoques lineales, cuyos coeficientes se vuelven insostenibles ante la complejidad de los mercados inmobiliarios modernos.

2. La crisis del enfoque tradicional: limitaciones del modelo de mínimos cuadrados ordinarios (OLS)

La base teórica de los modelos hedónicos clásicos, establecida por Lancaster (1966) y Rosen (1974), se basa en la premisa de que el sector inmobiliario es un conjunto de atributos que generan utilidad. Aunque el modelo de mínimos cuadrados ordinarios (OLS) ha sido el estándar histórico por su simplicidad, conlleva serias responsabilidades técnicas en mercados heterogéneos:

- Especificación incorrecta de la forma funcional: La OLS impone una rigidez lineal que ignora la naturaleza intrínsecamente no lineal de la formación de precios.
- Separabilidad de atributos y coeficientes insostenibles: El modelo asume que el efecto de cada variable es constante e independiente. En la práctica, esto da lugar a "*coeficientes insostenibles*" porque el valor de un atributo (como un balcón) varía según el contexto del segmento de mercado u otras interacciones entre variables.
- Vulnerabilidad a la multicolinealidad: La correlación entre variables predictivas (por ejemplo, área total y número de vacantes) genera inestabilidad en el modelo OLS, lo que requiere un

trabajo exhaustivo de ingeniería de atributos y selección manual de variables para evitar distorsiones.

Para capturar la complejidad observada, se necesita una arquitectura que no dependa de descripciones explícitas y simplistas impuestas por el modelador, sino que aprenda las interdependencias directamente a partir de los datos.

3. La arquitectura del bosque aleatorio: estabilidad mediante el embolsado

El algoritmo de Bosque Aleatorio (RF) representa una evolución sobre los Árboles de Decisión (DT) utilizando la técnica *de Agregación Bootstrap* (*Bagging*), propuesta por Leo Breiman. La base central del Encapsulamiento es que funciona mejor en procedimientos de predicción inestables. Mientras que un solo árbol de decisión es "nervioso" (pequeños cambios en los datos generan grandes cambios en la estructura), la agregación de múltiples *réplicas bootstrap* transforma estos predictores inestables en una solución de alto rendimiento y baja varianza.

Los diferenciadores técnicos para la gestión de activos incluyen:

- Hiperparámetros de control: La implementación óptima identificada en estudios de alta densidad utiliza 50 árboles con una profundidad de 17, una configuración que equilibra el poder predictivo sin incurrir *en sobreajuste*.
- Tratamiento de variables categóricas: La RF se ocupa de forma nativa de atributos cualitativos (por ejemplo, tipo de calentamiento, marca del revelador), evitando la proliferación de parámetros que normalmente causa *sobreajuste* en múltiples regresiones.
- IA explicable (XAI): A diferencia de los modelos de "caja negra", RF ofrece interpretabilidad gracias a la importancia de las variables, permitiendo a los gestores entender qué factores (área, ubicación, fecha) están impulsando efectivamente el valor de la cartera.
- Flexibilidad jerárquica: El modelo permite que la influencia de un atributo varíe según el segmento, capturando la inestabilidad natural del mercado.

4. Evidencia de precisión: El estudio de caso de Gangnam y Liubliana

La superioridad del Bosque Aleatorio sobre el OLS e incluso el juicio humano se demuestra mediante datos experimentales en mercados altamente complejos. En el distrito de Gangnam (Corea del Sur), la RF ha alcanzado niveles de precisión que redefinen el estándar de *la valoración* masiva:

Métricas de rendimiento	Modelo OLS (Tradicional)	Modelo Random Forest (Propuesto)	Impacto Estratégico
MAPE (Error Medio)	~19,61%	5,48%	Precisión superior a la de los evaluadores humanos (12%)
Precisión (Tasa < 5%)	17,4%	72,0%	Fiabilidad extrema en cuanto a las proporciones de garantía.
R-Cuadrado (R^2)	0,726	0,976	Explicación del 97,6% de la variabilidad del mercado.
COD (Dispersión)	19,57	5,48	Equidad y uniformidad en las evaluaciones masivas.

Es esencial destacar el caso de Liubliana (Eslovenia), que funcionó como una verdadera "prueba de estrés" para el modelo. Durante el periodo 2008-2013, el mercado local sufrió una caída del 28% en los precios. Random Forest mantuvo su superioridad estadística incluso durante este ciclo de "caída", demostrando ser resiliente en escenarios de grave recesión económica, crítica para la gestión del riesgo bancario.

5. Mitigación de riesgos: reducción de valores atípicos y estabilidad en datos complejos

Para un gestor de fondos inmobiliarios, los errores catastróficos en activos individuales son más peligrosos que los errores medios moderados. La arquitectura RF demuestra una capacidad superior para mitigar "excepciones":

- Datos de desviación extrema: La probabilidad de errores superiores al 50% se reduce del 3,8% en OLS a solo 0,5% en RF. Esto garantiza que la valoración de la garantía no se exprese erróneamente y que pueda llevar a decisiones crediticias erróneas.
- Operacionalización de la multicolinealidad: Variables como "Área" (Índice 3) y "Plazas de Aparcamiento" (Índice 21) suelen llevar información redundante. Mientras que la OLS requiere ingeniería manual de atributos para evitar la multicolinealidad, la RF procesa esta correlación de forma inteligente y automatizada, identificando la importancia relativa sin necesidad de intervención humana constante.
- Aplicabilidad en tiempo real: Como demuestra el análisis de segmentación temporal, la superioridad de RF se mantiene incluso cuando el modelo tiene prohibido usar datos "futuros"

para predecir valores pasados. Esto valida su aplicabilidad en entornos de producción bancaria, donde solo está disponible el historial acumulado.

6. Conclusión y recomendación técnica

Random Forest se ha consolidado como el nuevo estándar de oro para la valoración masiva de activos inmobiliarios. Su capacidad para manejar la no linealidad y las complejas interacciones entre atributos supera las limitaciones históricas de los modelos lineales y la inconsistencia de las valoraciones puramente manuales.

Según este análisis técnico, se recomiendan las siguientes acciones:

1. Adopción de RF para la monitorización colateral: Implementar el modelo con una configuración de 50 árboles para cumplir con los requisitos de Basilea II, aprovechando el MAPE del 5,48 % para reducir costes con evaluaciones profesionales innecesarias.
2. Reemplazo de modelos lineales inestables: migración de sistemas de evaluación *de masas asistida por ordenador (CAMA)* de OLS a RF para eliminar errores derivados de especificaciones funcionales incorrectas e interacciones de variables no capturadas.
3. Exploración de Datos Geográficos Densos: Mejorar la precisión del modelo mediante la integración de variables de ubicación y vecindario, un área donde Random Forest demuestra máxima eficiencia al procesar grandes volúmenes de datos georreferenciados.

Cuaderno de Aprendizaje Guiado: Random Forest

Estructura del Cuaderno

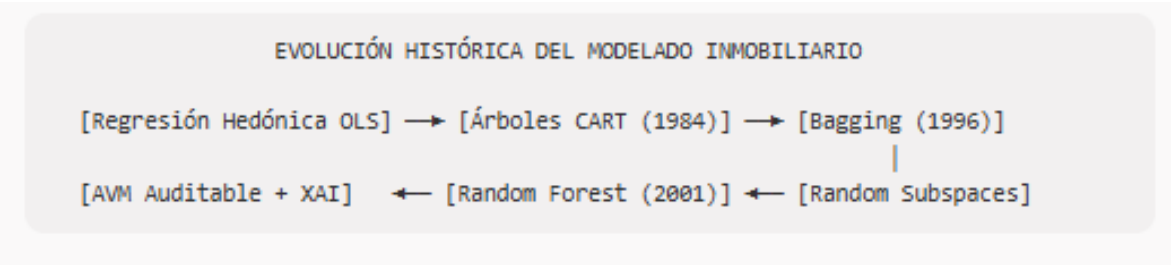
1. Módulo 1: Origen e Historia de Random Forest
2. Módulo 2: Desarrollo Evolutivo y Paradigma del Algoritmo
3. Módulo 3: Formulación Matemática Formal
4. Módulo 4: Procedimiento Algorítmico Paso a Paso
5. Módulo 5: Aplicación Práctica en la Valuación Inmobiliaria (AVM y Explicabilidad XAI)
6. Módulo 6: Ejercicios Guiados y Autoevaluación para el Usuario

Módulo 1: Origen e Historia de Random Forest

1.1 La transición de la estadística clásica al aprendizaje automático

Durante décadas, la estimación del valor de los bienes inmuebles se fundamentó de manera casi exclusiva en modelos de regresión lineal múltiple basados en Mínimos Cuadrados Ordinarios (MCO / OLS). Estos modelos hedónicos tradicionales asumían una relación rígida y lineal entre el precio del inmueble y sus características estructurales o de ubicación. Sin embargo, la ciencia estadística y la informática convergieron a finales del siglo XX para abordar problemas donde las suposiciones paramétricas de linealidad y normalidad fallaban.

En este contexto emergieron las metodologías de remuestreo computacional, como el Bootstrap desarrollado por Bradley Efron y Robert Tibshirani, el cual demostró que era posible inferir la precisión y variabilidad de un estimador mediante el muestreo repetido con reemplazo directamente sobre los datos observados, sin requerir fórmulas analíticas complejas ni supuestos de distribución normal.



1.2 Los pioneros: *Leo Breiman*, CART y el ensamble de algoritmos

El origen directo de *Random Forest* se remonta a la cadena evolutiva iniciada por *Leo Breiman*, *Jerome Friedman*, *Richard Olshen* y *Charles Stone* (1984) con la creación de los Árboles de

Clasificación y Regresión (CART). Aunque CART permitía capturar no linealidades, padecía de una gran inestabilidad: pequeñas variaciones en el conjunto de entrenamiento generaban cambios drásticos en la estructura del árbol.

Para solucionar esta limitación, *Breiman* introdujo en 1996 el método de *Bagging* (*Bootstrap Aggregating*), demostrando que promediar las predicciones de múltiples árboles entrenados sobre réplicas bootstrap reducía drásticamente la varianza del modelo. Paralelamente, *Tin Kam Ho* (1998) propuso el método de Subespacios Aleatorios (*Random Subspace*), donde cada árbol se entrenaba seleccionando al azar un subconjunto de variables independientes.

En 2001, *Leo Breiman* unificó ambos principios en su artículo fundacional *Random Forests*, introduciendo la inyección simultánea de aleatoriedad en observaciones (filas) y variables (columnas) para construir ensambles de árboles no podados con baja correlación entre sí.

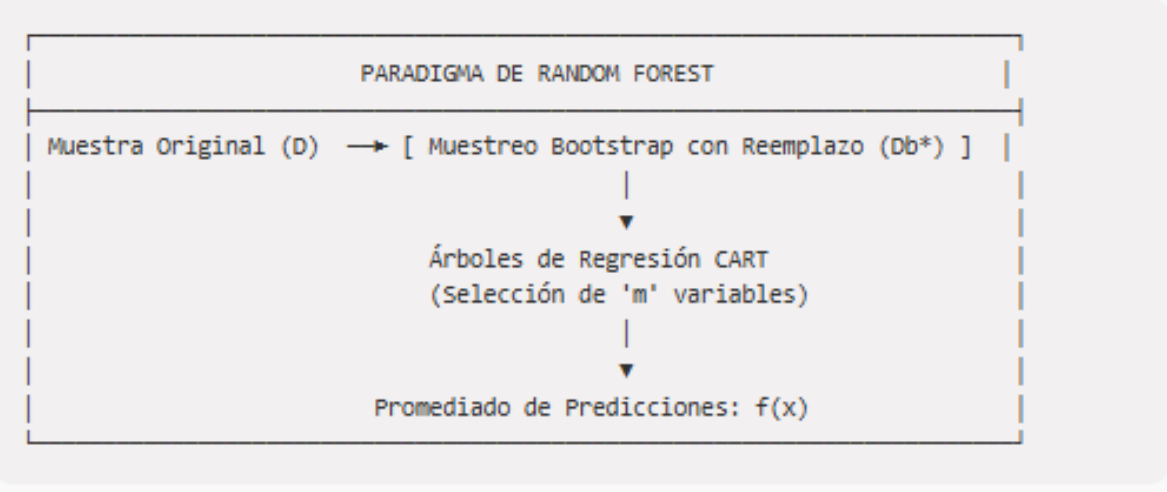
Módulo 2: Desarrollo Evolutivo y Paradigma del Algoritmo

2.1 Del árbol individual al bosque aleatorio

Un árbol de regresión individual (CART) segmenta el espacio de características en hiper-rectángulos mediante divisiones binarias sucesivas. Aunque es intuitivo, presenta dos grandes inconvenientes:

1. Alta varianza (Inestabilidad): Sensible al ruido o a observaciones atípicas.
2. Sobreajuste (*Overfitting*): Tiende a memorizar los datos de entrenamiento si se expande a máxima profundidad.

Random Forest resuelve este dilema transformando un conjunto de "aprendices débiles" (*weak learners*) e inestables en un "predictor fuerte" y estable.



2.2 El principio de la Doble Aleatoriedad

El éxito predictivo de *Random Forest* radica en dos mecanismos estocásticos complementarios:

- Aleatoriedad a nivel de observaciones (*Bagging*): Cada árbol se entrena con una muestra bootstrap de tamaño N elegida con reemplazo de los datos originales.
- Aleatoriedad a nivel de variables (*Random Subspaces*): En cada nodo de cada árbol, el algoritmo no busca la mejor división entre *todas* las características p, sino únicamente entre un subconjunto m elegido aleatoriamente (donde típicamente $m \ll p$).

Esta doble aleatoriedad rompe la correlación entre los árboles del bosque, garantizando que estructuras *dominance* no opaquen a variables secundarias pero informativas.

Módulo 3: Formulación Matemática Formal

3.1 Regresión mediante particionado recursivo (CART)

Para un árbol de regresión individual, dado un espacio dividido en M regiones ortogonales $R_1, R_2, \dots, R_M$, la función de predicción se expresa como:

$$f(x) = \sum_{m=1}^{M} c_m \, I(x \in R_m)$$

Donde la constante c_m representa el valor promedio de la variable respuesta Y_i (precio del inmueble) en la región R_m.

$$c_m = \frac{1}{N_m} \sum_{x_i \in R_m} y_i$$

La selección de la variable de división x_j y el punto de corte t en cada nodo se efectúa minimizando la Suma de Residuos al Cuadrado (RSS):

$$\text{RSS} = \sum_{x_i \in R_{\text{izq}}} \left(y_i - c_{\text{izq}}\right)^2 + \sum_{x_i \in R_{\text{der}}} \left(y_i - c_{\text{der}}\right)^2$$

3.2 Ensamble y agregación de *Random Forest*

El predictor de *Random Forest* para regresión $f_{\text{RF}}(x)$ es el promedio numérico no ponderado de B árboles de decisión individuales $T(x; \Theta_b)$:

$$f_{\text{RF}}(x) = \frac{1}{B}\sum_{b=1}^{B} T\,(x;\Theta_b)$$

Donde Θ_b es un vector aleatorio independiente e idénticamente distribuido (i.i.d.) que rige tanto la muestra bootstrap como la selección de variables en cada nodo del árbol b.

3.3 Teorema de convergencia y la cota de *Breiman* (Sesgo-Varianza)

A medida que el número de árboles B tiende a infinito, la ley fuerte de los grandes números garantiza que el error de generalización de *Random Forest* converge casi seguro a un límite, evitando el sobreajuste al añadir más árboles:

$$\mathbb{E}_{X,Y}\left(Y - \frac{1}{B}\sum_{b=1}^{B} T\,(X;\Theta_b)\right)^2 \underset{B\to\infty}{\overset{\text{c.s.}}{\to}} \mathbb{E}_{X,Y}(Y - \mathbb{E}_{\Theta}[T(X;\Theta)])^2$$

Breiman demostró formalmente que el error de generalización del bosque $PE^*(\text{bosque})$ está acotado por la correlación promedio entre los residuos de los árboles $(\bar{\rho})$ y el error cuadrático medio individual de los árboles $PE^*(\text{árbol})$:

$$PE^*(\text{bosque}) \leq \bar{\rho} \cdot PE^*(\text{árbol})$$

Interpretación clave: Para maximizar la precisión de la valoración, el algoritmo debe minimizar la correlación entre árboles $(\bar{\rho})$ manteniendo la capacidad predictiva individual de cada árbol $PE^*(\text{árbol})$.

3.4 Muestras *Out-Of-Bag* (OOB) e Importancia de Variables

Dado que cada muestra *bootstrap* se selecciona con reemplazo, la probabilidad de que una observación particular no sea seleccionada en una réplica es:

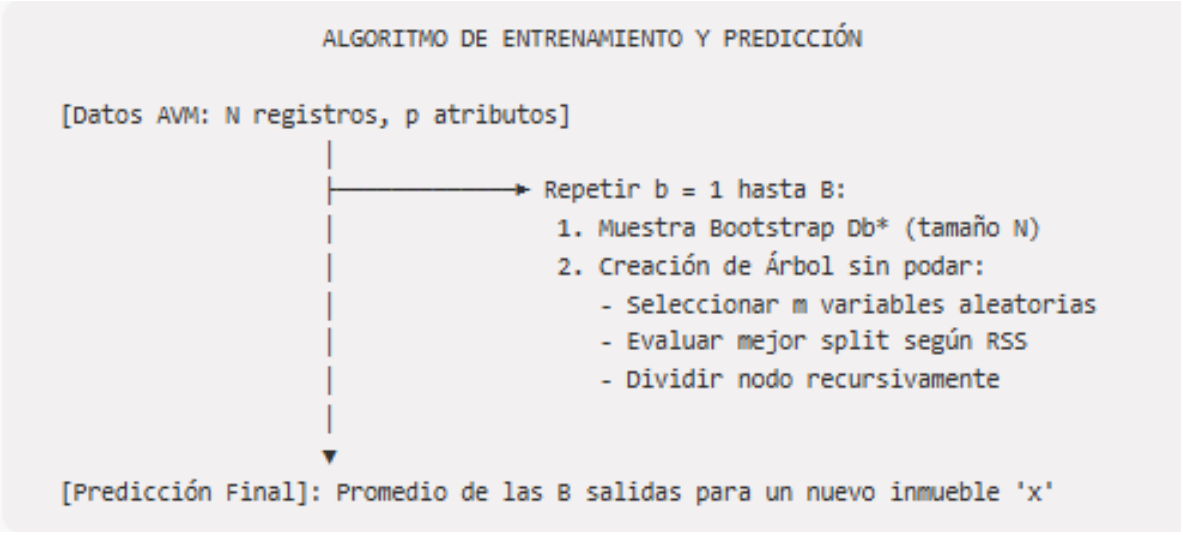
$$\lim_{N\to\infty}\left(1 - \frac{1}{N}\right)^N = \frac{1}{e} \approx 0.368$$

Aproximadamente el 36.8% de las observaciones quedan fuera de cada árbol (muestras Out-Of-Bag o OOB)33more_horiz. Las predicciones OOB proporcionan un estimador insesgado del error de generalización sin necesidad de validación cruzada externa34more_horiz.

Para medir la Importancia de Variables por Permutación OOB, se permutan al azar los valores de la variable x_j en los datos OOB y se mide el incremento en el Error Cuadrático Medio (ΔMSE):

$$\text{Importancia}\left(x_j\right) = \text{MSE}_{\text{OOB}}\left(\text{permutada } x_j\right) - \text{MSE}_{\text{OOB}}(\text{original})$$

Módulo 4: Procedimiento Algorítmico Paso a Paso



4.1 Definición de entradas

Dado un conjunto de datos AVM con N transacciones inmobiliarias y $p$variables explicativas (superficie, antigüedad, baños, coordenadas, renta de la zona, etc.).

4.2 Generación de réplicas *bootstrap*

Para cada árbol $b = 1, \dots, B$, extraer una muestra D_b^* de tamaño N mediante muestreo aleatorio con reemplazo de D.

4.3 Construcción de árboles no podados

- En cada nodo del árbol, seleccionar aleatoriamente $m$variables de las p disponibles (en regresión, $m = \lfloor p/3 \rfloor$ por defecto).
- Seleccionar la variable $x_j \in m$ y el punto de corte t que maximice la reducción de la suma de residuos al cuadrado (RSS).
- Dividir el nodo en dos nodos hijos y repetir el proceso recursivamente hasta alcanzar el tamaño de hoja mínimo establecido (p. ej., min_samples_leaf = 5) sin aplicar poda.

4.4 Agregación predictiva

Para valorar un nuevo inmueble con características x, calcular la predicción final como el promedio de los B árboles.

4.5 Evaluación de desempeño e importancia OOB

Calcular las métricas de error (MAPE, RMSE, R^2) sobre las predicciones OOB y evaluar la importancia de cada atributo mediante permutación OOB.

Módulo 5: Aplicación en la Valuación Inmobiliaria (AVM y Explicabilidad XAI)

5.1 De la regresión hedónica tradicional a los Modelos de Valoración Automática (AVM)

En la práctica profesional de la tasación masiva, el modelo hedónico tradicional asume que la función de valor es aditiva y lineal. Sin embargo, el mercado habitacional presenta interacciones complejas y no linealidades espaciales y estructurales (por ejemplo, el impacto de 20 m² adicionales no es constante, sino que depende de la ubicación y la categoría del inmueble).

Random Forest aprende implícitamente estas interacciones complejas sin requerir una especificación funcional previa.

DEMOSTRACIÓN DE DESEMPEÑO EMPÍRICO EN AVM

Estudio / Ubicación	Regresión OLS / MCO	Random Forest (RF)
Gangnam, Corea del Sur (Hong et al., 2020)	MAPE: ~20.0% Pred. <5% err: 17.5%	MAPE: 5.5% Pred. <5% err: 72.0%
Sevilla, España (INVI, 2026)	MAE: 45,153.9 € MAPE: 27.8% | R^2: 0.78	MAE: 32,143.9 € MAPE: 19.6% | R^2: 0.87
Ljubljana, Eslovenia (Čeh et al., 2018)	MAPE: 17.0% R^2: 0.23	MAPE: 7.0% R^2: 0.57

- Estudio de *Gangnam*, Corea del Sur (*Hong et al*., 2020): Analizando 16.601 transacciones de apartamentos, *Random Forest* redujo el margen de error porcentual medio (MAPE) de casi el 20 % obtenido por el modelo OLS tradicional a solo un 5,5 %, alcanzando un 72 % de predicciones con un margen de error menor al 5 %.
- Estudio de Sevilla, España (Revista INVI, 2026): Evaluando 1.710 ofertas de viviendas, *Random Forest* redujo el error absoluto medio (MAE) en más de 13.000 € respecto al MCO, reduciendo el MAPE del 27,8% al 19,6% e incrementando el coeficiente de determinación R^2 de 0,788 a 0,87045.
- Estudio de *Ljubljana*, Eslovenia (*Čeh et al*., 2018): Sobre 7.407 transacciones, RF superó drásticamente a la regresión lineal reduciendo el MAPE del 17 % al 7 % y elevando el R^2 del 0,23 al 0,57, capturando con alta sensibilidad las áreas de valor de alta gama que MCO subvaloraba sistemáticamente.
- Estudio de Madrid, España (Guijarro, 2023): La incorporación de la variable espacial *"Área de Valor"* (agrupación de secciones censales vecinas) demostró que los modelos basados

en árboles capturan la dinámica de precios reduciendo los errores predictivos por debajo del 13 % de MAPE.

5.2 Desmontando la "Caja Negra": Integración con SHAP y XAI

Para cumplir con las normas profesionales de valuación, un modelo AVM no solo debe ofrecer una estimación numérica puntual, sino también explicar el origen de dicho valor. Mediante la integración de SHAP (*Shapley Additive exPlanations*) y gráficos de dependencia parcial (PDP e ICE), la predicción de *Random Forest* se descompone en un valor base escalar más la suma de las contribuciones explícitas (en euros) de cada característica:

$$f(x) = \mathbb{E}[f(X)] + \sum_{j=1}^{p} \phi_j$$

```
EJE DE VALORACIÓN AUDITABLE CON VALORES SHAP

Valor Base Medio E[f(X)]:         300.000 €
-------------------------------------------
+ Superficie (110 m²):            + 48.000 €
+ Renta Media Zona (Nivel Alto):  + 31.000 €
+ Garaje incluido:                + 14.000 €
+ Conservación Excelente:         + 12.000 €
- Sin Ascensor:                   -  9.500 €
- Antigüedad (45 años):           - 17.000 €
-------------------------------------------
= Valor Estimado por RF:          368.500 €
```

Esta descomposición convierte a *Random Forest* en un entorno completamente auditable por tasadores profesionales, combinando alta precisión no lineal con transparencia analítica.

Módulo 6: Ejercicios Guiados y Autoevaluación para el Usuario

Ejercicio 1: Razonamiento Conceptual

- Pregunta: ¿Por qué un modelo de *Random Forest* no se sobre ajusta (*overfit*) al incrementar el número de árboles B a valores elevados (p. ej., B = 1.000)?
  Respuesta guiada: Debido a la Ley Fuerte de los Grandes Números demostrada por *Breiman*, el error de generalización de *Random Forest* converge a un límite constante a medida que $B \to \infty$. Añadir más árboles reduce la varianza de la estimación sin incrementar la complejidad de la frontera de decisión ni memorizar el ruido.

Ejercicio 2: Verificación Matemática

- Pregunta: En un dataset AVM con $N = 10.000$ inmuebles, si entrenamos un bosque con $B = 500$ árboles, ¿cuántos inmuebles aproximadamente se utilizan para evaluar el error insesgado OOB de cada árbol individual?
- Cálculo: Dado que cada muestra *bootstrap* deja fuera al $\approx 36{,}8\%$ de los registros:

$$\text{Registros OOB por árbol} = 10.000 \times 0{,}368 = 3{,}680 \text{ inmuebles}$$

Estas 3.680 observaciones sirven para estimar la importancia de las variables y el error de generalización sin requerir un conjunto de validación separado.

Ejercicio 3: Interpretación de valuación Inmobiliaria

- Pregunta: Un tasador observa que la regresión hedónica lineal otorga un valor negativo significativo al número de habitaciones cuando se controla por la superficie total, mientras que *Random Forest* asigna un impacto SHAP positivo y no lineal. ¿A qué se debe esta discrepancia?
- Respuesta guiada: La regresión lineal sufre de alta multicolinealidad entre la superficie y el número de habitaciones. Al obligar a un coeficiente lineal único, el MCO penaliza la fragmentación excesiva de la vivienda. *Random Forest*, mediante dividendos de subespacios aleatorios y combinaciones no lineales, detecta que añadir habitaciones incrementa el valor hasta cierto umbral óptimo (p. ej., de 2 a 3 dormitorios), tras el cual el efecto marginal se estabiliza.

Ejercicio 4: Construcción Paso a Paso de un Árbol en *Random Forest* (Caso AVM Residencial)

Este ejercicio está diseñado para que los usuarios de tu web comprendan de forma práctica y numérica el funcionamiento interno de un árbol de regresión individual dentro de un entorno de *Random Forest*, aplicando el principio de doble aleatoriedad y la minimización de la Suma de Residuos al Cuadrado (RSS).

1. Dataset Inicial de Ejemplo (Muestra de Mercado AVM)

Imaginemos una muestra simplificada de 5 inmuebles $(N = 5)$ con 3 variables explicativas $p = 3$):

- X_1: Superficie (m²)
- X_2: Número de Baños
- X_3: Distancia al Centro (km)
- Y: Precio Real de Transacción (€)

Inmueble	Superficie (m^2) [X_1]	Baños [X_2]	Distancia (km) [X_3]	Precio Real (Y)
A	60	1	5.0	180.000 €
B	80	1	3.0	240.000 €
C	100	2	2.0	310.000 €
D	120	2	1.0	350.000 €
E	140	3	1.5	420.000 €

Paso 1: Primera Fuente de Aleatoriedad — Muestreo *Bootstrap* (Filas)

Para construir el Árbol #1 del bosque, el algoritmo no utiliza el conjunto de datos completo, sino que genera una muestra *bootstrap* (D_b^*) de tamaño $N = 5$ seleccionada con reemplazamiento.

- Sorteo Aleatorio obtenido: [A, B, B, D, E]
- *Nota metodológica*: El inmueble C no fue seleccionado en esta extracción; por lo tanto, forma parte del grupo *Out-Of-Bag* (OOB) de este árbol (usado posteriormente para validar el modelo sin sesgo).

Subconjunto de entrenamiento para el Árbol #1:

1. Inmueble A: (60 m^2, 1 baño, 5.0 km) → **180.000 €**
2. Inmueble B (copia 1): (80 m^2, 1 baño, 3.0 km) → **240.000 €**
3. Inmueble B (copia 2): (80 m^2, 1 baño, 3.0 km) → **240.000 €**
4. Inmueble D: (120 m^2, 2 baños, 1.0 km) → **350.000 €**
5. Inmueble E: (140 m^2, 3 baños, 1.5 km) → **420.000 €**

Precio medio inicial del nodo raíz ($c_{\text{raíz}}$):

$$c_{\text{raíz}} = \frac{180.000 + 240.000 + 240.000 + 350.000 + 420.000}{5} = \mathbf{286.000\ €}$$

Paso 2: Segunda Fuente de Aleatoriedad — Selección de Subespacio Aleatorio (Columnas)

Para dividir el nodo raíz, el algoritmo no evalúa todas las variables disponibles ($p = 3$). En su lugar, selecciona al azar un subconjunto de m variables (por ejemplo, m = 2).

- Sorteo Aleatorio de variables para este nodo: Se seleccionan X_1 (Superficie) y X_3 (Distancia al Centro).

- *(La variable X_2 "Baños" queda excluida temporalmente de la decisión en este nodo específico).*

Paso 3: Elección del Mejor Corte mediante Minimización de RSS.

El árbol debe encontrar la variable y el punto de corte (*t*) entre las variables evaluadas (X_1 y X_3) que reduzca al máximo la Suma de Residuos al Cuadrado (RSS).

$$\text{RSS} = \sum_{i \in \text{Izq}} (y_i - c_{\text{Izq}})^2 + \sum_{i \in \text{Der}} (y_i - c_{\text{Der}})^2$$

Donde c_{Izq} y c_{Der} son los precios promedios de los inmuebles en cada una de las dos ramas resultantes.

Evaluación del Candidato 1: Corte en X_1 (Superficie $\leq 90\ m^2$)

- **Rama Izquierda** ($\leq 90\ m^2$): Inmuebles **[A, B, B]**
  - Precio medio (c_{Izq}) = $(180.000 + 240.000 + 240.000)/3 = \mathbf{220.000}$ €
  - $\text{RSS}_{\text{Izq}} = (180k - 220k)^2 + (240k - 220k)^2 + (240k - 220k)^2 = 1.600 + 400 + 400 = \mathbf{2.400}$ millones
- **Rama Derecha** ($> 90\ m^2$): Inmuebles **[D, E]**
  - Precio medio (c_{Der}) = $(350.000 + 420.000)/2 = \mathbf{385.000}$ €
  - $\text{RSS}_{\text{Der}} = (350k - 385k)^2 + (420k - 385k)^2 = 1.225 + 1.225 = \mathbf{2.450}$ millones
- $\text{RSS}_{\text{Total Corte 1}} = 2.400 + 2.450 = \mathbf{4.850}$ millones

Evaluación del Candidato 2: Corte en X_3 (Distancia al Centro $\leq 2.0\ km$)

- **Rama Izquierda** ($\leq 2.0\ km$): Inmuebles **[D, E]** $\rightarrow c_{\text{Izq}} = 385.000$ € ($\text{RSS}_{\text{Izq}} = 2.450$ millones)
- **Rama Derecha** ($> 2.0\ km$): Inmuebles **[A, B, B]** $\rightarrow c_{\text{Der}} = 220.000$ € ($\text{RSS}_{\text{Der}} = 2.400$ millones)
- $\text{RSS}_{\text{Total Corte 2}} = 2.450 + 2.400 = \mathbf{4.850}$ millones
- **Resultado de Optimización**: Ambas reglas dividen el nodo con la misma precisión óptima (reduciendo el RSS de 38.000 millones en el nodo raiz a solo 4.850 millones). El algoritmo elige **Superficie** $\leq 90\ m^2$ como la condición del nodo primario.

Paso 4: Predicción de un Inmueble Nuevo y Ensamble del Bosque

Supongamos que deseamos valorar una vivienda nueva (X_{nuevo}) con las siguientes características: Superficie = 85 m², Baños = 2, Distancia = 2,5 km.

2. **Predicción del Árbol #1:**
   - Evalúa la condición del nodo: ¿Superficie $\leq 90\ m^2$? **Sí.**
   - Cae en la hoja izquierda, asignando como estimación el promedio de esa región: $\hat{Y}_1 = \mathbf{220.000\ €}$ [1] [8].
3. **Predicción en el resto de Árboles ($b = 2, \ldots, B$):**
   - Debido a que otros árboles se entrenaron con distintas muestras *bootstrap* y evaluaron otras combinaciones de variables (por ejemplo, donde la presencia de 2 baños elevó el valor), los árboles restantes producen predicciones variadas (p. ej., $\hat{Y}_2 = 235.000\ €$, $\hat{Y}_3 = 215.000\ €$, etc.) [1] [7].
4. **Predicción Final del Random Forest (Promediado de Ensamble):**

$$\hat{Y}_{\text{RF}}(X) = \frac{1}{B}\sum_{b=1}^{B}\hat{Y}_b(X) = \frac{220.000 + 235.000 + 215.000 + \ldots}{B} = \mathbf{223.33}$$

Preguntas de Consolidación para los Usuarios de la Web

1. **Evaluación Out-Of-Bag (OOB):** El inmueble C $(100\ m^2, 310.000\ €)$ no se usó para entrenar el Árbol #1. Si pasamos el inmueble C por este Árbol #1 (Superficie $> 90\ m^2$), predice $385.000\ €$. ¿Cuál es el error absoluto de estimación OOB para esta observación en el Árbol #1?
   - *Solución guiada*:
     $$\text{Error OOB} = |310.000\ € - 385.000\ €| = 75.000\ €.$$
2. **Efecto de la Doble Aleatoriedad**: Si la selección aleatoria de variables hubiera excluido la Superficie y obligado al árbol a elegir entre *Baños* y *Distancia*, ¿cómo habría cambiado la estructura del nodo?
   - *Solución guiada*: Habría seleccionado *Distancia* $\leq 2.0\ km$ o *Baños* ≤ 1, demostrando cómo Random Forest explora vías alternativas de valoración que los modelos lineales pasan por alto.

¿Te gustaría que estructuremos este ejercicio como un componente interactivo tipo *widget* en *Python* o *HTML/JavaScript* para integrarlo directamente en el código de tu sitio web?

He generado los componentes interactivos y visuales para tu web en el panel de Studio:

1. ***widget_ejercicio_rf.py***: Un código interactivo en Python (compatible con ***Streamlit***) que permite a tus usuarios simular en vivo la extracción bootstrap, probar la selección aleatoria de variables, evaluar la reducción de la suma de residuos al cuadrado (RSS) y tasar una vivienda nueva en tiempo real.
2. ***arbol_decision_rf_ejercicio-v2.png***: El diagrama esquemático completo de la estructura del árbol de decisión individual construido durante el ejercicio.

```python
"""
Widget Interactivo: Simulación Paso a Paso de Random Forest en AVM Inmobiliario
--------------------------------------------------------------------------------
Este script implementa una aplicación interactiva (Streamlit) para explicar
la construcción de un Árbol de Regresión dentro de Random Forest.
"""

import streamlit as st
import pandas as pd
import numpy as np

st.set_page_config(page_title="Simulador Random Forest AVM", layout="wide")

st.title("🏠 Simulador Interactivo: Random Forest en la Valuación Inmobiliaria")
st.markdown("### Compréndelo paso a paso con datos reales de mercado")

# 1. Dataset Base
st.sidebar.header("Configuración del Mercado")
st.markdown("#### 1. Muestra Original de Mercado (Dataset Base)")
df_original = pd.DataFrame({
    'Inmueble': ['A', 'B', 'C', 'D', 'E'],
    'Superficie_m2': [60, 80, 100, 120, 140],
    'Banos': [1, 1, 2, 2, 3],
    'Distancia_km': [5.0, 3.0, 2.0, 1.0, 1.5],
    'Precio_Real_EUR': [180000, 240000, 310000, 350000, 420000]
})
st.dataframe(df_original, use_container_width=True)

# 2. Muestreo Bootstrap
st.markdown("---")
st.markdown("#### 2. Paso 1: Muestreo Bootstrap (Doble Aleatoriedad - Filas)")
if st.button("🎲 Generar Muestra Bootstrap Aleatoria"):
    np.random.seed(np.random.randint(0, 1000))
    indices_boot = np.random.choice(len(df_original), size=len(df_original), replace=True)
    df_boot = df_original.iloc[indices_boot].reset_index(drop=True)
    st.session_state['df_boot'] = df_boot
    oob = df_original[~df_original['Inmueble'].isin(df_boot['Inmueble'])]
    st.session_state['oob'] = oob

if 'df_boot' in st.session_state:
    st.write("**Muestra Bootstrap Extraída (Entrenamiento del Árbol):**")
    st.dataframe(st.session_state['df_boot'])
    st.info(f"Inmuebles Out-Of-Bag (OOB) excluidos de este árbol: {list(st.session_state['oob']['Inmueble'].v

# 3. Selección de Subespacio Aleatorio
st.markdown("---")
st.markdown("#### 3. Paso 2: Selección de Subespacio Aleatorio (Columnas)")
features = ['Superficie_m2', 'Banos', 'Distancia_km']
selected_features = st.multiselect("Selecciona m=2 variables para evaluar en el nodo:", features, default=['S

if len(selected_features) > 0:
    st.markdown("#### 4. Paso 3: Evaluación de Puntos de Corte (Minimización de RSS)")
    var_split = st.selectbox("Elige la variable para probar punto de corte:", selected_features)
    corte = st.slider("Punto de corte:", float(df_original[var_split].min()), float(df_original[var_split].ma
```

```
        df_eval = st.session_state.get('df_boot', df_original)
        izq = df_eval[df_eval[var_split] <= corte]
        der = df_eval[df_eval[var_split] > corte]

        c_izq = izq['Precio_Real_EUR'].mean() if len(izq) > 0 else 0
        c_der = der['Precio_Real_EUR'].mean() if len(der) > 0 else 0

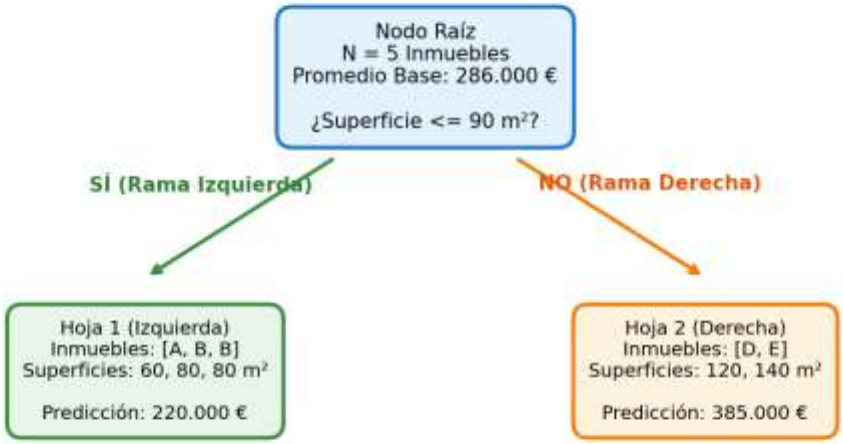
        rss_izq = np.sum((izq['Precio_Real_EUR'] - c_izq)**2) if len(izq) > 0 else 0
        rss_der = np.sum((der['Precio_Real_EUR'] - c_der)**2) if len(der) > 0 else 0
        rss_total = rss_izq + rss_der

        col1, col2, col3 = st.columns(3)
        col1.metric("Rama Izquierda (<= corte)", f"{len(izq)} inmuebles", f"Promed: {c_izq:,.0f} €")
        col2.metric("Rama Derecha (> corte)", f"{len(der)} inmuebles", f"Promed: {c_der:,.0f} €")
        col3.metric("RSS Total del Corte", f"{rss_total/1e6:,.2f} M €²")

    # 4. Tasación de Inmueble Nuevo
    st.markdown("---")
    st.markdown("#### 5. Valuación de Inmueble Nuevo")
    col_a, col_b, col_c = st.columns(3)
    sup_new = col_a.number_input("Superficie (m²):", 40, 200, 85)
    ban_new = col_b.number_input("Baños:", 1, 4, 2)
    dis_new = col_c.number_input("Distancia al Centro (km):", 0.5, 10.0, 2.5)

    if st.button("🌲 Simular Predicción de Random Forest (Ensamble de 100 Árboles)"):
        from sklearn.ensemble import RandomForestRegressor
        X = df_original[['Superficie_m2', 'Banos', 'Distancia_km']]
        y = df_original['Precio_Real_EUR']
        rf = RandomForestRegressor(n_estimators=100, random_state=42)
        rf.fit(X, y)
        pred_val = rf.predict([[sup_new, ban_new, dis_new]])[0]
        st.success(f"**Valor Estimado Final por Random Forest: {pred_val:,.2f} €**")
```

Árbol #1 de Random Forest - Muestra Bootstrap [A, B, B, D, E]



Evaluación de Vivienda Nueva (85 m², 2 baños, 2.5 km) -> Cae en Hoja 1 -> Estimación Árbol #1 = 220.000 €

Tarjetas Didácticas

Tarjeta 1

En el anverso pone: "Diagrama de ensamble de árboles de decisión" La respuesta del anverso es: "Random Forest (Bosque Aleatorio)."

¿Podrías explicarme este tema más detalladamente?

El concepto de diagrama de ensamble de árboles de decisión representa la arquitectura central de Random Forest (Bosque Aleatorio). Para comprender plenamente esta tarjeta didáctica, es útil analizar por qué pasamos de un solo árbol a un "ensamble" y cómo funciona este diagrama paso a paso.

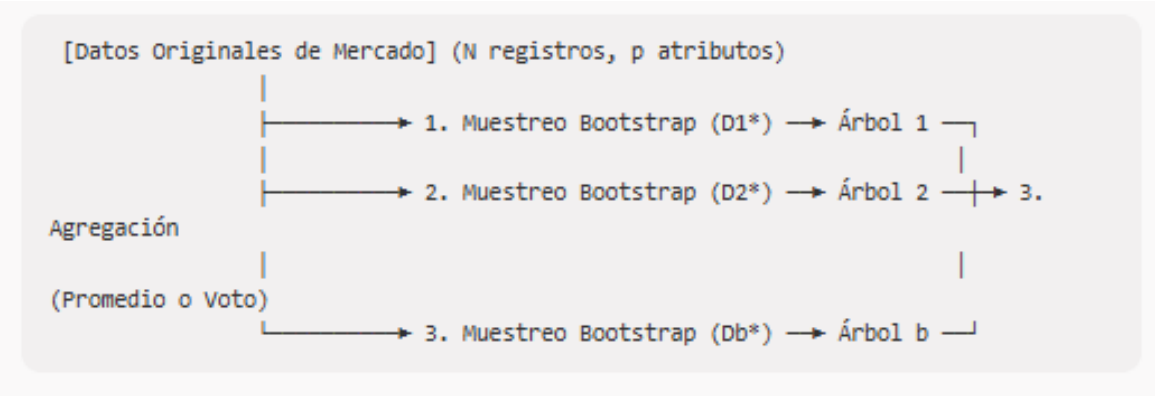
1. ¿Qué es un "Ensamble" en Aprendizaje Automático?

Un árbol de decisión individual (CART) segmenta los datos haciendo preguntas binarias sucesivas (por ejemplo, ¿Superficie > 90 m²? o ¿Tiene ascensor?). Aunque un árbol es fácil de entender, tiene una desventaja severa: es un aprendiz inestable y de alta varianza. Una pequeña variación en los datos de entrada puede cambiar drásticamente toda la estructura del árbol y generar sobreajuste (*overfitting*).

El paradigma de ensamble resuelve este problema aplicando la sabiduría de la multitud: en lugar de confiar la valoración a un único árbol "experto", se construye una asamblea formada por cientos de árboles independientes que votan o promedian sus resultados para tomar una decisión final.

2. Flujo del Diagrama de Ensamble de *Random Forest*

El diagrama de ensamble de *Random Forest* opera mediante tres etapas secuenciales:



Etapa 1: Muestreo Bootstrap (Aleatoriedad en las observaciones)

- A partir del dataset original de N registros, el algoritmo extrae B muestras aleatorias con reemplazamiento (técnica conocida como *Bagging* o *Bootstrap Aggregating*).
- Cada árbol b se entrena con su propia muestra *bootstrap*. Aproximadamente un tercio de los datos quedan fuera de cada muestra (datos *Out-Of-Bag* u OOB), los cuales sirven como conjunto interno de validación insesgado.

Etapa 2: Subespacios Aleatorios (Aleatoriedad en las variables)

- Mientras se construye cada árbol, en cada nodo de división el algoritmo no evalúa todas las variables disponibles. Selecciona al azar únicamente un subconjunto reducido m de atributos (por ejemplo, ($m = \lfloor p/3 \rfloor$en problemas de regresión).
- Esta regla obliga a que cada árbol explore combinaciones diferentes de atributos, rompiendo la correlación entre los árboles del bosque y garantizando diversidad en el ensamble.

Etapa 3: Agregación Predictiva (*Ensemble Output*)

Una vez construidos todos los árboles independientes, el modelo combina sus predicciones según el tipo de problema:

- Regresión (Valuación de Inmuebles / AVM): La estimación final del precio de un inmueble $\hat{Y}$ es el promedio numérico de las salidas de todos los árboles del bosque:

$$\hat{Y} = \frac{1}{B}\sum_{b=1}^{B} T_b\,(x)$$

- Clasificación: La predicción de la categoría se determina por voto de mayoría (*plurality voting*) entre todos los árboles.

3. ¿Por qué el Ensamble es tan potente para la Valuación Inmobiliaria?

- Reducción drástica de la varianza: La Ley Fuerte de los Grandes Números demuestra que al promediar múltiples árboles descorrelacionados, el error del ensamble converge a un límite y evita el sobreajuste al añadir más árboles.
- Capacidad no lineal: Los modelos hedónicos lineales tradicionales (MCO/OLS) asumen relaciones rígidas entre los atributos y el precio, mientras que el ensamble de árboles descubre de forma automática interacciones complejas de mercado (como el efecto combinado del nivel socioeconómico de la zona y la presencia de ascensor).
- Rendimiento empírico: En estudios masivos de valoración inmobiliaria (como el del distrito de *Gangnam*), el ensamble de *Random Forest* redujo el margen medio de error (MAPE) del 19,6 % (obtenido por regresión OLS) a solo un 5.5 %.

Tarjeta 2

En el anverso pone: "¿Cuál es la causa principal de que Random Forest supere significativamente a la regresión lineal en la valuación masiva inmobiliaria?" La respuesta del anverso es: "Su capacidad para explorar estructuras complejas y no lineales sin requerir que el modelador especifique explícitamente la forma funcional de las preferencias del mercado."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica resume uno de los hallazgos conceptuales y empíricos más importantes en la evolución de los Modelos de Valoración Automática (AVM).

Para entender a fondo la respuesta, conviene analizar qué ocurre cuando intentamos valuar un mercado complejo utilizando un modelo estadístico rígido frente a uno flexible impulsado por datos (*data-driven*).

1. El problema de la regresión lineal: La rigidez de la "forma funcional"

Los modelos hedónicos tradicionales basados en Mínimos Cuadrados Ordinarios (MCO / OLS) exigen que el valuador o estadístico especifique con anterioridad una ecuación matemática rígida (por ejemplo, lineal o log-lineal).

Esta especificación previa impone supuestos teóricos muy estrictos sobre el mercado inmobiliario:

- Independencia y separabilidad de atributos: Asume que el impacto de cada característica (superficie, número de baños, ascensor, ubicación) actúa de forma aislada e independiente de las demás.
- Constancia marginal: Asume que el valor que añade un unidad adicional de un atributo (un m² más o un baño más) viene dado por un único coeficiente estático β constante para todo el mercado.

En el mercado real, estos supuestos rara vez se cumplen. Por ejemplo, el impacto monetario de añadir 20 m² adicionales no es constante: depende de si la vivienda es un estudio pequeño o un chalet de lujo, de la antigüedad del edificio y de la zona socioeconómica en la que se ubique. Intentar modelar estas dinámicas con una sola recta o fórmula fija distorsiona la realidad y genera sesgos significativos.

2. La ventaja de *Random Forest*: Construcción *Data-Driven* y estructuras no lineales

Random Forest opera bajo un enfoque completamente no paramétrico:

- Exploración automática sin especificación previa: En lugar de exigir que el valuador defina las ecuaciones, transformaciones polinómicas o términos de interacción de antemano, el algoritmo explora los datos por sí mismo y descubre las relaciones jerárquicas directas e interacciones complejas implícitas en los precios de transacción.
- Efectos contextuales cambiantes: Al estar basado en un ensamble de árboles de decisión que dividen el espacio de datos en regiones específicas, *Random Forest* permite que el efecto marginal de una variable cambie según el contexto. Por ejemplo, la presencia de ascensor puede tener una penalización o premio masivo en edificios antiguos de plantas altas, pero un efecto nulo en edificios modernos de baja altura.

3. Evidencia empírica reportada en las fuentes

La superioridad técnica de esta capacidad no lineal se traduce en mejoras dramáticas de precisión en las pruebas masivas reales presentadas en la literatura:

- Distrito de *Gangnam* (Seúl): La regresión lineal MCO registró un error porcentual absoluto medio (MAPE) de casi el 20%, mientras que *Random Forest* redujo el error al 5,5 %. Además, la probabilidad de predecir el valor exacto dentro de un margen de error menor al 5 % fue del 72 % con *Random Forest*, frente a solo el 17,4 % con el modelo lineal.
- *Ljubljana* (Eslovenia): La regresión lineal solo pudo explicar el 23 % de la variabilidad de los precios ($R^2 = 0,23$), mientras que *Random Forest* alcanzó un $R^2 = 0,57$ con un MAPE del 7,0 % (frente al 17,5 % de OLS), demostrando la naturaleza intrínsecamente no lineal del mercado habitacional urbano.
- Sevilla (España): El modelo de *Random Forest* redujo el error absoluto medio (MAE) en más de 13.000 € por vivienda respecto a MCO, elevando el coeficiente de determinación de 0,788 a 0,870 al capturar de forma más sensible los patrones socioeconómicos y de localización de los barrios.

Tarjeta 3

En el anverso pone: "¿Cuál es el principal supuesto restrictivo del modelo hedónico tradicional basado en OLS?" La respuesta del anverso es: "Asume que las relaciones entre los atributos de la vivienda y su precio son lineales, constantes e independientes (separables)."

¿Podrías explicarme este tema más detalladamente?

El supuesto restrictivo expuesto en esa tarjeta didáctica señala la limitación teórica y matemática fundamental del modelo hedónico convencional estimado por Mínimos Cuadrados Ordinarios (MCO / OLS) en la valuación masiva inmobiliaria.

1. El fundamento del modelo hedónico de OLS

La teoría del precio hedónico (originada por *Lancaster* en 1966 y formalizada por *Rosen* en 1974) establece que la vivienda no es un bien homogéneo, sino un paquete o "cesta" de atributos implícitos (superficie, antigüedad, ubicación, amenidades) que generan utilidad para el comprador.

Bajo la aproximación tradicional de OLS, se asume una función de regresión de la forma:

$$Y = X\beta + \varepsilon$$

Donde la variable dependiente Y (precio o logaritmo del precio) se calcula mediante la combinación lineal de un vector de coeficientes estáticos β multiplicados por las características del inmueble (X) más un término de error (ε).

2. Desglose detallado de los tres supuestos restrictivos

A. Linealidad (Forma funcional fija)

- En qué consiste: Asume que la relación matemática entre el incremento de un atributo y el precio del inmueble es estrictamente directa y proporcional.
- El fallo en el mercado real: La disposición a pagar de los compradores por las características físicas o locacionales no es lineal. Por ejemplo, el impacto monetario de añadir 20 m² a un apartamento pequeño de 50 m² no es el mismo que añadir esos mismos 20 m² a una residencia de 300 m². Del mismo modo, la antigüedad o la distancia al centro de la ciudad presentan rendimientos marginales decrecientes o umbrales no lineales que OLS no logra modelar sin transformaciones *ad hoc*.

B. Constancia (Efecto marginal homogéneo)

- En qué consiste: Asume que el precio implícito asignado a cada atributo mediante el coeficiente β es estático y permanece constante para la totalidad de la muestra analizada.
- El fallo en el mercado real: El valor marginal de una característica varía significativamente según el segmento de mercado, el nivel de ingresos del barrio o la tipología de la propiedad. Una plaza de garaje o un ascensor tienen un valor marginal significativamente distinto en un distrito financiero denso que en una zona residencial periférica de baja densidad. OLS fuerza un único coeficiente promedio para todo el dataset, lo que provoca la subvaloración o sobrevaloración de inmuebles situados en submercados o capas socioeconómicas específicas.

C. Independencia y Separabilidad de Preferencias

- En qué consiste: Asume que la contribución de cada variable al valor total de la vivienda es aditivamente separable e independiente del resto de las características presentes en el inmueble.
- El fallo en el mercado real: Las preferencias del consumidor son intrínsecamente complejas y están entrelazadas mediante interacciones de alto orden. Por ejemplo, el efecto positivo de estar en una planta alta no es independiente de la presencia de ascensor, ni el impacto de la superficie es independiente del nivel socioeconómico de la sección censal. Al no capturar estas interacciones de forma flexible, el modelo lineal incurre en errores de especificación de la forma funcional (*misspecification*).

3. Consecuencias en la precisión y estabilidad del AVM

A. Sensibilidad a la multicolinealidad: En conjuntos de datos urbanos, las variables físicas y espaciales están fuertemente interrelacionadas. OLS sufre de inestabilidad en la estimación de coeficientes cuando existe alta multicolinealidad, inflando la varianza de las estimaciones.

B. Generación frecuente de errores atípicos (*outliers*): Debido a la rigidez geométrica del plano de regresión lineal, OLS tiende a generar predicciones con desviaciones severas (superiores al 50 % del valor real) cuando valúa inmuebles con combinaciones de atributos atípicas.

C. Pérdida de capacidad explicativa: En estudios empíricos donde OLS se enfrenta a entornos urbanos complejos, la variabilidad explicada (R^2) suele caer drásticamente (p. ej., a niveles de 0,23 en *Ljubljana* o a errores porcentuales MAPE del 19,6 % en Gangnam) debido a su incapacidad para adaptarse a la complejidad no lineal del mercado.

4. La solución no paramétrica de *Random Forest*

A diferencia de OLS, *Random Forest* no requiere que el valuador especifique explícitamente la forma funcional de las preferencias del mercado. Al basarse en la partición recursiva de subespacios mediante árboles de decisión, el algoritmo explora de manera impulsada por datos (*data-driven*) la estructura jerárquica de los atributos. Esto le permite capturar de forma nativa los efectos no lineales, las restricciones contextuales y las interacciones cruzadas entre variables sin asumir linealidad, constancia ni separabilidad previa.

Tarjeta 4

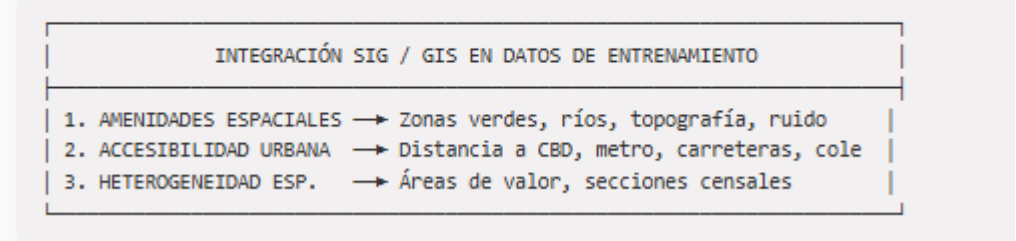
En el anverso pone: "¿Cómo ayuda la integración de Sistemas de Información Geográfica (SIG / GIS) en la valuación masiva inmobiliaria?" La respuesta del anverso es: "Permite calcular e incorporar variables de amenidades espaciales, accesibilidad urbana y heterogeneidad espacial al conjunto de datos de entrenamiento."

¿Podrías explicarme este tema más detalladamente?

La integración de los Sistemas de Información Geográfica (SIG / GIS) con algoritmos de aprendizaje automático como *Random Forest* marca la diferencia entre un Modelo de Valoración Automática (AVM) simplista y un sistema masivo de alta precisión.

En la valoración tradicional, la máxima inmobiliaria de "Ubicación, ubicación, ubicación" solía reducirse a categorías genéricas y estáticas (como el código postal o el distrito administrativo). La tecnología SIG transforma la ubicación en un conjunto denso y continuo de variables geométricas y territoriales.

Desglose de las 3 Dimensiones Clave



1. Cálculo de Amenidades Espaciales y Ambientales

Los SIG permiten cuantificar factores del entorno natural y urbano que afectan positiva o negativamente la calidad de vida y, por ende, el precio del inmueble:

- Entorno natural e hídrico: Cálculo de la distancia euclidiana o de recorrido a parques, bosques, márgenes de ríos o la costa. Por ejemplo, en el estudio de *Ljubljana*, la proximidad al río *Ljubljanica* actúa como una amenidad de valor positivo.
- Topografía y riesgo ambiental: Determinación de la elevación sobre el nivel del mar. En *Ljubljana*, la elevación es un factor crítico para diferenciar viviendas situadas fuera de zonas históricamente inundables.
- Externalidades negativas: Medición de la distancia a fuentes de ruido o contaminación, como pasillos ferroviarios, proximidad al autopistas o al aeropuerto.

2. Medición de la Accesibilidad Urbana

Mediante funciones de proximidad y análisis de redes sobre mallas digitales (por ejemplo, *grids* con resolución de 20 metros en entornos como SAGA GIS o llamadas a MAP APIs):

- Nodos de actividad económica: Distancia al Distrito Central de Negocios (CBD) o a polos de empleo.
- Transporte público y vial: Distancia exacta a estaciones de metro, paradas de autobús urbano/interurbano, accesos a autopistas y carreteras regionales.
- Equipamientos clave: Proximidad a centros educativos/universidades, hospitales, comisarías y centros comerciales.

3. Captura de la Heterogeneidad Espacial y "Áreas de Valor"

El mercado inmobiliario es intrínsecamente heterogéneo; el precio por metro cuadrado varía en el espacio formando micro-mercados o clústeres:

- Agrupación en Áreas de Valor: En estudios sobre Madrid, la creación de la variable "Área de Valor" (agrupando secciones censales vecinas con oferta representativa) resultó ser la variable explicativa más relevante para predecir precios.
- Indicadores socioeconómicos del vecindario: El SIG permite cruzar las coordenadas de la vivienda con bases de datos públicas para atribuir a cada inmueble la renta media disponible de su sección censal, el nivel educativo de la zona o la presión migratoria.
- Fronteras estructurales del mercado: Elementos como vías del tren, ríos o límites catastrales funcionan como barreras naturales que delimitan zonas homogéneas de precio.

¿Por qué SIG y *Random Forest* hacen una alianza perfecta?

Cuando un SIG genera docenas de variables de distancia y ubicación, se produce un problema matemático severo de multicolinealidad (por ejemplo, la distancia al centro suele estar correlacionada

con la distancia a la estación principal o al río).

- La regresión lineal tradicional (OLS) se desestabiliza ante esta multicolinealidad y requiere transformaciones complejas como Análisis de Componentes Principales (PCA).
- *Random Forest*, en cambio, maneja la alta dimensionalidad de forma nativa. Gracias al muestreo aleatorio de variables en cada nodo, es capaz de aislar y evaluar el impacto de cada atributo espacial, capturando relaciones no lineales complejas (como umbrales donde la cercanía al transporte beneficia la valoración hasta cierto límite a partir del cual el ruido empieza a penalizar).

Tarjeta 5

En el anverso pone: "La técnica estadística utilizada en econometría tradicional para reducir la multicolinealidad combinando variables explicativas en factores ortogonales se denomina _____." La respuesta del anverso es: "Análisis de Componentes Principales (PCA)."

¿Podrías explicarme este tema más detalladamente?

El Análisis de Componentes Principales (PCA) es una técnica clásica de reducción de dimensionalidad y álgebra lineal frecuentemente empleada en econometría y modelos hedónicos de regresión para solucionar el problema de la multicolinealidad.

1. El problema de fondo: La multicolinealidad en econometría

En la valuación inmobiliaria tradicional mediante Mínimos Cuadrados Ordinarios (MCO / OLS), las variables explicativas (como la superficie construida, la superficie útil, el número de habitaciones, la distancia al centro o la renta media) suelen presentar una alta correlación entre sí.

Cuando existe multicolinealidad severa (evidenciada por un Factor de Inflación de la Varianza o VIF > 5–10):

- Los errores estándar de los coeficientes estimados por OLS se inflan drásticamente.
- Los parámetros se vuelven altamente inestables y extremadamente sensibles a pequeñas variaciones o ruido en los datos de entrenamiento.
- Resulta muy difícil aislar e interpretar el impacto individual o el "precio implícito" de cada atributo sobre el valor de la vivienda14.

2. ¿Cómo funciona el PCA para resolver la multicolinealidad?

PCA aborda este problema transformando el espacio original de variables correlacionadas en un nuevo conjunto de variables sintéticas llamadas Componentes Principales (PCs):

- Propiedad de Ortogonalidad: La característica matemática fundamental de los Componentes Principales es que son completamente independientes u ortogonales entre sí (su correlación lineal es exactamente cero). Al sustituir las variables originales por estos componentes ortogonales en el modelo de regresión OLS, la multicolinealidad desaparece por completo.

- Ordenación por varianza explicada: El primer componente principal (PC1) captura la máxima varianza posible de los datos originales; el segundo (PC2) captura la mayor parte de la varianza restante ortogonal a PC1, y así sucesivamente.
- Criterio de retención (*Kaiser–Harris*): Para simplificar el modelo econométrico, se suelen conservar solo aquellos componentes principales cuyos valores propios (*eigenvalues*) sean superiores a 1.

3. La principal desventaja de PCA en valuación

Aunque PCA resuelve la inestabilidad matemática de OLS, introduce una severa barrera metodológica: la pérdida de interpretabilidad directa.

En lugar de trabajar con atributos inmobiliarios intuitivos (como *"número de baños"* o *"superficie en* m²), los regresores del modelo OLS pasan a ser combinaciones lineales abstractas. En estudios empíricos de AVM (como el realizado sobre el mercado de *Ljubljana*), los econometristas deben realizar un esfuerzo de interpretación semántica para redefinir los componentes principales agrupados (por ejemplo, interpretando PC1 como *"antigüedad y calidad edilicia"*, PC4 como *"dimensión o tamaño"* o PC7 como *"accesibilidad regional"*).

4. PCA + OLS frente a Random Forest

A diferencia de la econometría lineal tradicional, *Random Forest* no requiere aplicar PCA previo:

1. Manejo nativo de redundancia: Gracias a la selección aleatoria de subespacios de variables (*Random Subspaces*) en cada nodo de cada árbol, *Random Forest* distribuye de forma natural la información redundante a través de múltiples árboles del bosque, haciendo que el ensamble sea intrínsecamente robusto frente a la multicolinealidad.
2. Conservación de las variables originales: Mantiene la nomenclatura e identidad original de cada atributo inmobiliario en el dataset, facilitando la auditoría posterior con herramientas de explicabilidad como SHAP.
3. Captura de no linealidades: En pruebas comparativas empíricas donde se aplicó OLS con componentes principales ortogonales (OLS + PCA) frente a *Random Forest*, el modelo OLS + PCA solo logró explicar el 23 % de la variabilidad del mercado ($R^2 = 0,23$), mientras que *Random Forest* alcanzó un R^2 de 0,57 con errores (MAPE) mucho menores (7 % vs 17 %). Esto demuestra que eliminar la multicolinealidad con PCA no es suficiente si el modelo lineal subyacente no puede capturar las relaciones complejas y no lineales del mercado inmobiliario.

Tarjeta 6

En el anverso pone: "En la evaluación empírica de *Shi* (2017) sobre viviendas de segunda mano, ¿cuál de los modelos evaluados obtuvo el mejor ajuste y cuál el peor?" La respuesta del anverso es: "*Random Forest* obtuvo el mejor ajuste y la Regresión *Lasso* el peor ajuste."

¿Podrías explicarme este tema más detalladamente?

El estudio empírico realizado por *Shi* (2017) analizó el mercado de viviendas de segunda mano en Pekín mediante la comparación de cinco modelos estadísticos y de aprendizaje automático. Los resultados mostraron que *Random Forest* ofreció la mayor precisión de ajuste, mientras que la Regresión *Lasso* obtuvo el rendimiento más deficiente.

1. Por qué *Random Forest* obtuvo el MEJOR ajuste

- Captura de relaciones no lineales e interacciones complejas: El precio de la vivienda de segunda mano depende de la combinación jerárquica e interactiva de sus atributos (por ejemplo, el impacto de la superficie varía según la antigüedad, la planta o la calidad de conservación). *Random Forest* no exige asumir una fórmula matemática previa y aprende estas no linealidades directamente de los datos.
- Doble aleatoriedad (*Bagging* + Subespacios): Al combinar múltiples árboles de decisión entrenados sobre muestras *bootstrap* y evaluar subconjuntos aleatorios de variables en cada nodo, el modelo reduce significativamente la varianza y evita el sobreajuste (*overfitting*).
- Tolerancia al ruido y valores atípicos: Los datos reales de transacciones inmobiliarias suelen contener ruido y heterogeneidad. El ensamble de árboles suaviza las desviaciones extremas.

2. Por qué la Regresión Lasso obtuvo el PEOR ajuste

- Rigidez de la suposición de linealidad: Lasso (*Least Absolute Shrinkage and Selection Operator*) es un modelo lineal. Asume que cada atributo contribuye de forma estrictamente proporcional y constante al precio global, lo que distorsiona la realidad de un mercado inmobiliario heterogéneo.
- Limitación de la regularización L1: Aunque la penalización L1 de *Lasso* ayuda a seleccionar variables ajustando a cero los coeficientes menos relevantes, no otorga la capacidad de modelar curvas, umbrales o interacciones de alto orden si estas no han sido especificadas explícitamente a mano.
- Sensibilidad a distribuciones asimétricas: Las distribuciones de precios residenciales suelen presentar sesgo y variaciones complejas que los planos de regresión lineal no logran adaptar.

Conclusión clave para la Valuación Automática (AVM)

El contraste en el estudio de *Shi* (2017) evidencia que, en la valoración masiva de vivienda usada, la flexibilidad de un algoritmo adaptativo como *Random Forest* supera estructuralmente a los métodos

lineales tradicionales (incluso cuando estos cuentan con mecanismos de selección de variables como *Lasso*).

Tarjeta 7

En el anverso pone: "¿Qué es un AVM en la industria de la tecnología inmobiliaria (*PropTech*)?" La respuesta del anverso es: "Un Modelo de Valuación Automatizada (Automated Valuation Model), software informático que calcula estimaciones de mercado de bienes raíces usando algoritmos analíticos."

¿Podrías explicarme este tema más detalladamente?

Un Modelo de Valuación Automatizada (conocido por sus siglas en inglés AVM, *Automated Valuation Model*) es un sistema informático analítico que calcula estimaciones precisas del valor de mercado de propiedades inmobiliarias en segundos, procesando grandes volúmenes de datos mediante algoritmos matemáticos y de aprendizaje automático (*Machine Learning*).

Dentro de la industria PropTech (la intersección entre la tecnología y el sector inmobiliario), los AVM representan el pilar fundamental para digitalizar, escalar y automatizar procesos que tradicionalmente requerían semanas de trabajo manual.

1. Origen e impulsores clave del AVM

El desarrollo de los AVM ha estado impulsado por dos grandes necesidades operativas y financieras:

- Exigencias regulatorias y bancarias (Acuerdo de Basilea II): Desde las directrices del Comité de Basilea en 2008, las entidades financieras están obligadas a supervisar el valor de las garantías hipotecarias de forma frecuente (como mínimo una vez al año). Realizar tasaciones presenciales continuas sobre millones de hipotecas resulta inviable en tiempo y coste; los AVM surgieron como la solución tecnológica insustituible.
- Tasación masiva fiscal y catastral (CAMA): En el ámbito público, los sistemas CAMA (*Computer Assisted Mass Appraisal*) utilizan AVMs para calcular de forma estandarizada y masiva los valores de suelo e inmuebles con fines de tributación e impuestos.

2. ¿Cómo funciona un AVM internamente?

A diferencia de la tasación tradicional —donde un profesional humano selecciona manualmente de 3 a 5 inmuebles comparables e introduce correcciones subjetivas—, un AVM procesa bases de datos masivas estructuradas en tres grandes bloques de variables:

1. Atributos estructurales del inmueble: Superficie construida, número de habitaciones y baños, estado de conservación, antigüedad, planta y presencia de ascensor, garaje o terraza.
2. Variables locacionales y de accesibilidad (SIG/GIS): Coordenadas geográficas, distancia a transporte público, hospitales, centros educativos, parques o zonas de ocio.

3. Indicadores socioeconómicos del entorno: Renta media del vecindario, sección censal y la delimitación de "Áreas de Valor" (micro-mercados de precios homogéneos).

3. Evolución algorítmica: De la regresión lineal al *Machine Learning*

- Los primeros AVM (Regresión Hedónica OLS): Basados en Mínimos Cuadrados Ordinarios, asumían relaciones lineales y rígidas entre los atributos de la vivienda y su precio. Sin embargo, eran muy vulnerables a errores cuando el mercado presentaba dinámicas complejas o valores atípicos.
- AVMs de Nueva Generación (*Random Forest* y *Boosting*): Algoritmos no paramétricos como *Random Forest* o *Gradient Boosting Machine* (GBM) aprenden interacciones no lineales directamente de las transacciones. Estudios empíricos demuestran que los tasadores humanos o los modelos lineales tradicionales cometen errores relativos promedio del 12 % al 20 %, mientras que un AVM basado en *Random Forest* reduce dicho error (MAPE) a niveles en torno al 5,5 %.

4. AVM Auditable: Transparencia mediante XAI (SHAP)

Uno de los grandes retos de los AVMs avanzados en PropTech era la crítica de actuar como una "caja negra" inaccesible. Hoy en día, esta limitación se supera integrando técnicas de Inteligencia Artificial Explicable (XAI) como SHAP. SHAP descompone la estimación final del AVM en contribuciones monetarias exactas (por ejemplo: +48.000 € por la superficie, +31.000 € por la zona y -17.000 € por la antigüedad), ofreciendo una auditoría transparente y justificada para tasadores, bancos e inversores.

Tarjeta 8

En el anverso pone: "En Estados Unidos, ¿cómo se denominan los sistemas informáticos utilizados por los tasadores fiscales a nivel nacional para la valuación de impuestos inmobiliarios?" La respuesta del anverso es: "CAMA (*Computer Assisted Mass Appraisal*)."

¿Podrías explicarme este tema más detalladamente?

CAMA (acrónimo de *Computer Assisted Mass Appraisal*, o Valuación Masiva Asistida por Computadora) se refiere al conjunto de sistemas informáticos, bases de datos y software especializado utilizado por los tasadores fiscales (assessors) a nivel municipal, condal y estatal en Estados Unidos para calcular el valor imponible (*tax assessment*) de los bienes inmuebles de forma estandarizada y masiva.

1. Origen y Propósito de los Sistemas CAMA

- Equidad y recaudación tributaria: La legislación fiscal exige a las administraciones locales recaudar impuestos sobre la propiedad de manera proporcional y equitativa respecto al valor real de mercado. Realizar inspecciones e informes individuales para millones de propiedades resulta inviable en tiempo y coste.

- Sistematización del valor: Un sistema CAMA automatiza este proceso aplicando modelos matemático-estadísticos sobre bases de datos catastrales masivas, permitiendo estimar el valor de miles de propiedades de forma simultánea.

2. Componentes Fundamentales de un Sistema CAMA

Un entorno CAMA integra tres módulos principales:

1. Base de Datos Catastral y Estructural: Almacena las características físicas detalladas de cada inmueble (superficie del terreno, metros cuadrados construidos, antigüedad, calidad de materiales, número de estancias).
2. Motor de Valoración Automatizada (AVM): Módulo algorítmico que calcula la estimación de valor analizando las transacciones de mercado recientes.
3. Sistemas de Información Geográfica (SIG / GIS): Vinculación cartográfica que incorpora variables de accesibilidad, entorno urbano, servicios y delimitación de secciones catastrales.

3. Evolución Algorítmica en CAMA: De OLS a *Random Forest*

Históricamente, los sistemas CAMA han utilizado modelos hedónicos tradicionales basados en Mínimos Cuadrados Ordinarios (MCO / OLS). Sin embargo, la literatura técnica evidencia la transición hacia algoritmos no paramétricos de aprendizaje automático:

- Limitaciones del enfoque tradicional: La regresión OLS asume relaciones lineales, constantes y separables entre los atributos y el precio, lo que genera distorsiones o errores significativos en mercados heterogéneos.
- Ventaja de Random Forest en CAMA: La incorporación de Random Forest como motor AVM dentro de los sistemas CAMA permite capturar la estructura jerárquica no lineal del mercado y reducir sustancialmente los errores de valoración sin requerir la especificación manual previa de ecuaciones.

4. Marco Regulatorio e Impacto Financiero

El empleo de metodologías de valuación masiva automatizada no solo responde a fines fiscales domésticos, sino que se alinea con estándares internacionales como el Acuerdo de Basilea II, el cual exige a las entidades bancarias y financieras actualizar de manera frecuente el valor de las garantías hipotecarias mediante herramientas estadísticas estables y precisas.

Tarjeta 9

En el anverso pone: "¿Cuál ha sido históricamente el método tradicional utilizado en la valuación masiva de inmuebles?" La respuesta del anverso es: "El modelo de precios hedónicos basado en la regresión lineal por Mínimos Cuadrados Ordinarios (OLS)."

¿Podrías explicarme este tema más detalladamente?

El modelo de precios hedónicos basado en la regresión lineal por Mínimos Cuadrados Ordinarios (MCO

/ OLS) es el marco teórico y cuantitativo que dominó la valuación masiva inmobiliaria y los sistemas catastrales (CAMA) durante la segunda mitad del siglo XX.

1. Origen y Fundamento Teórico

El modelo hedónico se fundamenta en la teoría de la demanda de características de *Kelvin Lancaster* (1966) y en la formalización para mercados diferenciados realizada por *Sherwin Rosen* (1974):

- La vivienda como un "paquete de atributos": La teoría establece que un bien heterogéneo como una vivienda no se valora como una unidad indivisible, sino como una combinación o "cesta" de características individuales3.
- Tres categorías de atributos:
    1. Estructurales: Superficie útil, número de habitaciones, baños, antigüedad, planta y presencia de ascensor.
    2. Locacionales y de accesibilidad: Cercanía al distrito central de negocios (CBD), transporte público, colegios y parques.
    3. Ambientales y socioeconómicos: Renta media del vecindario, niveles de ruido o contaminación y tipo de zona.
- Precios implícitos marginales: La gran ventaja teórica de este modelo es que, al derivar la función de precio con respecto a un atributo específico, se obtiene el precio implícito marginal (la disposición marginal a pagar del comprador por una unidad adicional de dicho atributo).

2. Formulación Matemática y Estimación por OLS

En su especificación convencional, el precio del inmueble (o su transformación logarítmica $\ln(P)$) se modela como una combinación lineal de sus atributos:

$$\ln(P) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

Donde $X_1, X_2, \ldots, X_k$ representan las variables explicativas del inmueble, los coeficientes β son los parámetros a estimar, y ε es el término de error aleatorio [12] [13].

Para encontrar los valores óptimos de β, el método de **Mínimos Cuadrados Ordinarios (OLS)** minimiza la suma de las desviaciones cuadráticas entre los precios reales de transacción y los precios predichos por la ecuación [14]:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

3. Por qué fue el estándar histórico durante décadas

1. Simplicidad e interpretabilidad: Ofrece una interpretación analítica directa. Cada coeficiente β indica con claridad cuánto aumenta o disminuye el valor estimado del inmueble cuando cambia una unidad de la variable X_j.

2. Eficiencia computacional previa al *Big Data*: En una época con capacidad de cómputo limitada, calcular una solución matricial lineal era factible incluso para miles de propiedades.
3. Adopción regulatoria e institucional: Se convirtió en la base de los sistemas CAMA (*Computer Assisted Mass Appraisal*) en Estados Unidos y en el estándar de actualización de garantías hipotecarias bajo marcos como el Acuerdo de Basilea II.

4. Las limitaciones que motivaron el salto hacia *Random Forest*

A pesar de su elegancia teórica, el modelo lineal por OLS presenta deficiencias severas en mercados reales:

- Supuestos de separabilidad y constancia: Asume de forma rígida que el impacto de cada atributo es independiente del resto y constante a lo largo de todo el mercado. En la realidad, el impacto monetario de 20 m² adicionales o de un ascensor varía según la localización, el nivel socioeconómico de la zona y la tipología de la propiedad.
- Inestabilidad por multicolinealidad: Las características inmobiliarias están fuertemente correlacionadas entre sí (p. ej., la superficie, el número de estancias y los baños), lo que infla los errores estándar de los coeficientes de OLS y los vuelve inestables ante pequeños cambios en los datos.
- Mayor frecuencia de errores atípicos (*outliers*): Debido a la rigidez del plano de regresión, OLS tiende a sobrevalorar o infravalorar sistemáticamente en los extremos de la distribución.
- Incapacidad para capturar no linealidades: Pruebas empíricas masivas (como las de *Gangnam* en Seúl o *Ljubljana* en Eslovenia) demostraron que OLS alcanzaba errores porcentuales (MAPE) de hasta el 20 %, mientras que algoritmos adaptativos como *Random Forest* redujeron ese error al 5,5 %.

Tarjeta 10

En el anverso pone: "¿Qué función cumple el 'Ratio de Ventas' (*Sales Ratio* - SR) en la validación de un AVM?"

La respuesta del anverso es: "Evalúa el sesgo de estimación dividiendo el precio predicho por el precio real de venta $SR = \frac{\hat{p}}{p}$; SR >1, indican sobreestimación y SR < 1 subestimación."

¿Podrías explicarme este tema más detalladamente?

El Ratio de Ventas (*Sales Ratio* o *SR*) es el indicador métrico fundamental utilizado en la industria de la tecnología inmobiliaria (PropTech) y la valuación masiva catastral (CAMA) para auditar la precisión y detectar el sesgo de estimación de un Modelo de Valuación Automatizada (AVM).

1. Formulación Matemática y Significado

Para cada inmueble i evaluado, el Ratio de Ventas se define como el cociente entre la estimación calculada por el modelo y el precio real observado en la transacción de mercado:

$$SR_i = \frac{\hat{p}_i}{p_i}$$

Donde:

- $\hat{p}_i$: Es el precio o valor predicho por el AVM para el inmueble.
- p_i: Es el precio real registrado en la compraventa del inmueble en el mercado

2. Interpretación del Sesgo de Estimación

El valor del *SR* permite diagnosticar instantáneamente el comportamiento de la estimación para un inmueble individual o para un segmento del mercado:

- *SR* = 1,0 (Valoración Insesgada / Exacta): La estimación del AVM coincide perfectamente con el valor de transacción del mercado real2.
- *SR* > 1,0 (Sobreestimación o Sobrevaloración): El modelo ha asignado un valor superior al precio que el mercado estuvo dispuesto a pagar ($\hat{p}_i > p_i$). Por ejemplo, un *SR* = 1,15 indica que el AVM sobrevaloró la propiedad en un 15 %.
- *SR* < 1,0 (Subestimación o Subvaloración): El modelo calcula una estimación inferior al precio real de cierre ($\hat{p}_i < p_i$). Por ejemplo, un *SR* = 0,85 indica que el AVM infravaloró la propiedad en un 15 %.

3. Uso del *SR* en la Validación y Estándares Internacionales

En la valuación masiva, el análisis no se limita a inmuebles aislados, sino que evalúa la distribución del *SR* sobre todo el conjunto de prueba mediante los estándares fijados por la IAAO (*International Association of Assessing Officers*).

A. Mediana del Ratio de Ventas (SR_m) — Control del Sesgo Global

La mediana de todos los ratios de ventas (SR_m) del dataset indica si el modelo AVM presenta un sesgo sistémico de sobrevaloración o infravaloración. Los estándares internacionales fijan como aceptable un intervalo de 0,90 a 1,10 (es decir, la mediana de las estimaciones del AVM no debe desviarse más de un 10 % del promedio del mercado).

B. Coeficiente de Dispersión (*COD*) — Control de la Uniformidad

El *SR* es la materia prima para calcular el Coeficiente de Dispersión (*COD*), el cual mide cuán concentrados o dispersos están los ratios de venta de cada inmueble respecto a la mediana global (SR_m):

$$COD = \frac{100}{SR_m}\left(\frac{\sum_{i=1}^{n}|SR_i - SR_m|}{n}\right)$$

Un *COD* bajo (típicamente entre el 5 % y el 15 %) garantiza que el AVM mantiene una alta equidad y consistencia en sus valoraciones a lo largo de todas las tipologías de vivienda.

4. Comportamiento del *SR* en *Random Forest* frente a Regresión Lineal

En la auditoría comparativa de modelos AVM, el análisis del Ratio de Ventas revela patrones críticos de comportamiento:

- Modelos Hedónicos Lineales (OLS): Suelen mostrar un sesgo regresivo progresivo: tienden a sobreestimar los inmuebles de menor valor (*SR* > 1,0) y a subestimar significativamente las viviendas de lujo o situadas en zonas de alta gama (*SR* < 1,0).
- *Random Forest*: Al capturar no linealidades y micro-mercados mediante particiones recursivas, ajusta la distribución del *SR* mucho más cerca de 1,0 en todos los rangos de precio, eliminando los sesgos extremos observados en los modelos lineales tradicionales.

Tarjeta 11

En el anverso pone: "¿Por qué el algoritmo *Random Forest* no requiere un procedimiento externo de validación cruzada para medir su error?" La respuesta del anverso es: "Porque utiliza las muestras *Out-Of-Bag* (*OOB*), que son las observaciones excluidas de cada muestra bootstrap (aproximadamente un tercio del total de datos)."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica hace referencia a una de las propiedades más eficientes y elegantes del algoritmo *Random Forest*: la evaluación interna continua mediante muestras *Out-Of-Bag* (*OOB*).

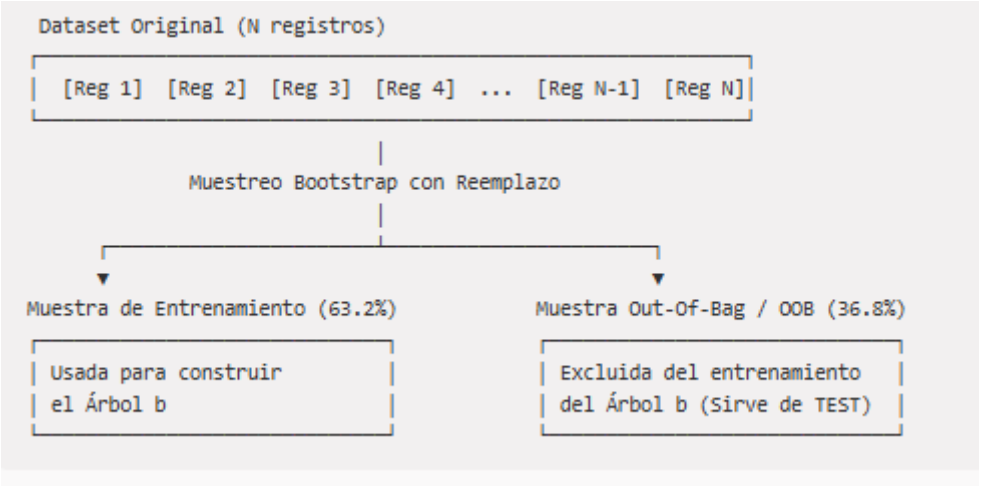
1. El origen matemático de las muestras *OOB*

Random Forest utiliza el método de *Bagging* (*Bootstrap Aggregating*) para construir un bosque de *B* árboles de decisión independientes. Para cada árbol, el algoritmo genera una muestra de entrenamiento (*muestra bootstrap*) seleccionando *N* observaciones al azar con reemplazamiento a partir del dataset original de *N* registros.

Dado que el muestreo se realiza con reemplazo, la probabilidad de que una observación específica no sea seleccionada en una extracción individual es $\left(1 - \frac{1}{N}\right)$. Para una muestra de tamaño *N*:

$$\lim_{N\to\infty}\left(1 - \frac{1}{N}\right)^{N} = \frac{1}{e} \approx 0{,}3679 \approx \mathbf{36,8}\%$$

Esto significa que, en promedio, cada árbol individual se entrena utilizando únicamente el ~63,2 % de los datos. El ~36,8 % restante (aproximadamente un tercio) queda excluido del entrenamiento de ese árbol en particular: a este conjunto excluido se le denomina muestra *Out-Of-Bag* (*OOB*)



2. ¿Cómo se calcula el Error *OOB*?

Para obtener una estimación insesgada del error de generalización de todo el bosque sin utilizar un conjunto de prueba (*test set*) externo ni validación cruzada (*k-fold CV*), el algoritmo sigue este procedimiento:

1. Predicción individual *OOB*: Para cada inmueble o registro *i* del dataset original, se identifican únicamente los árboles del bosque que NO utilizaron ese registro *i* en su entrenamiento.
2. Promediado de estimaciones: Se evalúa la vivienda *i* haciéndola pasar solo por esos árboles *OOB* y se promedian sus salidas (en regresión/AVM) o se toma el voto de mayoría (en clasificación)17.
3. Métrica global de error: Se compara la predicción OOB $\left(\hat{y}_{i,\mathrm{OOB}}\right)$ con el precio real de transacción (y_i) para cada registro de la muestra. La media de estos errores (por ejemplo, el *MSE OOB* o *MAPE OOB*) representa la precisión de generalización del modelo.

3. Ventajas del enfoque *OOB* frente a la Validación Cruzada tradicional

- Ahorro de tiempo de cómputo: La validación cruzada tradicional (p. ej., 10-fold CV) requiere entrenar el modelo completo *k* veces sobre diferentes subconjuntos de datos. En *Random Forest*, el error OOB se calcula de forma simultánea y "gratuita" durante una sola pasada de entrenamiento.

- Estimador insesgado de generalización: *Leo Breiman* demostró teórica y empíricamente que la estimación del error *OOB* es tan precisa como evaluar el modelo sobre un conjunto de prueba independiente asignado externamente.
- Aprovechamiento total de los datos: Permite utilizar el 100 % de los datos disponibles para el entrenamiento del bosque sin necesidad de reservar de forma previa un 20 % o 30 % del dataset únicamente para pruebas.

4. Aplicación adicional: Importancia de Variables por Permutación *OOB*

Las muestras *OOB* se utilizan además para calcular de forma transparente el poder predictivo real de cada característica:

1. Se mide el error *OOB* original sobre los datos retenidos.
2. Se permutan aleatoriamente los valores de una variable x_j (por ejemplo, la superficie) únicamente en los datos *OOB*.
3. Se vuelve a calcular el error *OOB*. Si al alterar esa variable el error aumenta significativamente, se concluye que x_j es una variable altamente determinante para la valoración.

Tarjeta 12

En el anverso pone: "En el estudio de *Ljubljana* (Eslovenia) por *Čeh et al*. (2018), ¿qué reto del mercado inmobiliario tuvo que enfrentar el modelo?" La respuesta del anverso es: "Una caída continua del 28 % en los precios inmobiliarios a lo largo de un período de 6 años (2008–2013) y una compleja forma urbana."

¿Podrías explicarme este tema más detalladamente?

El estudio de *Čeh et al*. (2018) sobre el mercado de apartamentos en *Liubliana* (capital de Eslovenia) es una de las investigaciones empíricas más citadas para demostrar la superioridad de los algoritmos de aprendizaje automático frente a la econometría tradicional en entornos inmobiliarios adversos.

El modelo tuvo que enfrentarse a dos retos entrelazados de gran complejidad: una severa inestabilidad temporal macroeconómica y una geometría urbana altamente heterogénea.

1. El reto macroeconómico: Caída del 28 % en los precios (2008–2013)

- Contexto de recesión profunda: Tras alcanzar su pico histórico de precios en el primer semestre de 2008, el mercado inmobiliario esloveno sufrió el impacto de la crisis financiera global. En los 6 años siguientes analizables por el estudio (2008–2013), los precios de los

apartamentos en *Liubliana* experimentaron una caída acumulada continua del 28 %, representando la contracción más pronunciada de todo el país.

- El fallo de la regresión lineal (OLS): La regresión lineal MCO convencional no logró adaptar de forma flexible esta trayectoria de caída temporal sin ajustes *ad hoc* previos, resultando en un ajuste global muy deficiente (R^2= 0,23) y un error porcentual (MAPE) cercano al 17,5 %.
- La respuesta de *Random Forest*: Al incluir la fecha de transacción (*trans_date*) como variable explícita, *Random Forest* la identificó automáticamente como el tercer factor más determinante del modelo (tras la superficie útil y el año de construcción). El algoritmo capturó de forma no lineal la trayectoria de depreciación (desde promedios de ~3.000 €/m² a comienzos de 2008 hasta ~2.000 €/m² en 2013) sin requerir funciones de ajuste predeterminadas por el valuador.

2. El reto geográfico: Compleja morfología y estructura urbana

- Morfología discontinua: *Liubliana* presenta una estructura urbana irregular caracterizada por "cuñas verdes" (bosques, prados y colinas) que penetran directamente desde la periferia hasta el Distrito Central de Negocios (CBD).
- Barreras y externalidades ambientales:
    - Riesgo de inundación y topografía: La proximidad al río *Ljubljanica* y la elevación topográfica sobre el nivel del mar juegan un papel crítico, otorgando primas de valor a las viviendas situadas por encima de los niveles históricos de inundación.
    - Barreras de infraestructura: Los pasillos ferroviarios conectan el centro con la zona industrial este, generando barreras físicas de mercado y contaminación acústica que penalizan el valor residencial en sus inmediaciones, salvo en áreas específicas de regeneración urbana reciente.
    - Accesibilidad no lineal: La cercanía a vías principales y carreteras regionales presenta efectos umbral; la proximidad beneficia la conectividad, pero, a distancias muy cortas, el ruido y tráfico generan efectos negativos sobre el precio por m².

3. Desempeño comparativo de los modelos

Ante estos dos grandes desafíos, el estudio comparó las predicciones de la Regresión Múltiple por MCO (con reducción de multicolinealidad vía Análisis de Componentes Principales - PCA) y *Random Forest* sobre 7.407 transacciones reales geocodificadas:

Métrica de Validación	Regresión Lineal MCO (+ PCA)	Random Forest (RF)	Criterio / Impacto en la Valuación
Coeficiente R^2	0.23	0.57	RF explica más del doble de la variabilidad del mercado 6 16.
Error Porcentual (MAPE)	17.48%	7.27%	RF reduce el error a menos de la mitad 6 16.
Coeficiente de Dispersión (COD)	17.12%	7.28%	OLS supera el límite máximo aceptable de la IAAO (15%), mientras que RF garantiza alta equidad 6 16.

Tarjeta 13

En el anverso pone: "¿Por qué *Random Forest* gestiona eficazmente las variables cualitativas o categóricas de múltiples niveles sin sufrir sobreajuste?" La respuesta del anverso es: "Porque recodifica las categorías y solo evalúa una fracción aleatoria de ellas en cada nodo, a diferencia de OLS donde crear múltiples variables *dummy* incrementa desmedidamente los parámetros a estimar."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica aborda uno de los grandes problemas prácticos al construir Modelos de Valoración Automatizada (AVM) con datos del mundo real: cómo tratar atributos cualitativos o categóricos que contienen muchas categorías distintas (por ejemplo, el código postal, el distrito/sección censal, la marca de la promotora o el tipo de sistema de calefacción).

1. El problema de la Regresión Lineal (OLS) con variables categóricas multinivel

En la econometría y los modelos hedónicos lineales tradicionales (OLS), una variable categórica con *k* niveles no se puede introducir directamente como un número continuo. Para poder procesarla, el modelador está obligado a aplicar codificación *One-Hot* (o crear variables *dummy*):

- Explosión de parámetros a estimar: Para una variable con *k* categorías (por ejemplo, 50 secciones censales o 30 marcas de constructora), OLS debe crear *k*-1 variables binarias (0 o 1).
- Pérdida de grados de libertad y sobreajuste (*overfitting*): Cada variable *dummy* requiere estimar un nuevo coeficiente β_j global dentro de la matriz de regresión $(X^T X)^{-1} X$. Si el conjunto de datos contiene varias características cualitativas de múltiples niveles, el número total de parámetros a estimar se dispara rápidamente. Esto consume los grados de libertad de la muestra, infla la varianza, genera problemas de multicolinealidad severa y provoca que

el modelo "memorice" el ruido de categorías poco frecuentes.

2. Cómo gestiona Random Forest las variables categóricas sin sobreajustarse

Random Forest supera esta limitación mediante dos mecanismos clave combinados:

A. Recodificación y partición local binaria

A diferencia de OLS —que intenta ajustar un plano global asignando un peso fijo a cada categoría— los árboles de regresión subyacentes en *Random Forest* tratan las categorías mediante preguntas de división local en los nodos.

- Una variable cualitativa de *k* clases se puede recodificar en *k*-1 variables dicotómicas o evaluar agrupaciones de categorías (por ejemplo, *¿La vivienda pertenece al grupo de zonas {A, C, F}?*)25.
- En cada nodo, el algoritmo busca la división que minimice la Suma de Residuos al Cuadrado (RSS) de forma local, sin estimar un coeficiente permanente para todo el mercado.

B. Subespacios aleatorios (*Random Subspaces*)

El factor determinante para evitar el sobreajuste es que, en cada nodo de cada árbol, el algoritmo no evalúa todas las variables o categorías simultáneamente.

- Solo se pone a disposición una pequeña fracción aleatoria *m* de las características (típicamente $m = p/3$ o $m = \sqrt{p}$)
- De este modo, una variable categórica masiva no satura el modelo ni "acapara" la capacidad de aprendizaje. Un árbol individual utilizará solo algunas categorías en ciertos nodos, mientras que otros árboles evaluarán subconjuntos diferentes.
- Al promediar la predicción final de cientos de árboles independientes (vía *Bagging*), las divisiones ruidosas o sobreajustadas en categorías pequeñas se cancelan mutuamente.

3. Ejemplo en Valuación Inmobiliaria (AVM)

Imaginemos un dataset con la variable cualitativa "Barrio / Sección Censal" con 80 categorías diferentes:

Enfoque	Procedimiento	Impacto en el Modelo
Regresión OLS	Genera **79 variables *dummy*** adicionales.	Agrega 79 parámetros β a la ecuación lineal. Riesgo muy alto de sobreajuste y desestabilización por multicolinealidad [1] [...].
Random Forest	Agrupa y evalúa divisiones binarias locales sobre **fracciones aleatorias** de las categorías en distintos nodos [2] [6].	Mantiene la capacidad predictiva, captura diferencias de valor entre zonas de forma no lineal y no sufre de explosión de parámetros ni *overfitting* [1] [2].

Esta capacidad de procesar atributos cualitativos complejos sin perder estabilidad es una de las razones documentadas por las que *Random Forest* logra reducciones drásticas del error porcentual (MAPE) en valoraciones residenciales masivas (pasando del ~20 % en OLS al ~5,5 % en *Random Forest* en estudios como el de *Gangnam*).

Tarjeta 14

En el anverso pone: "¿Qué efecto macroeconómico suele incluirse en modelos de valuación temporal para capturar ciclos del mercado inmobiliario a lo largo de los años?" La respuesta del anverso es: "Variables *dummys* temporales (para OLS) o indicadores como PIB, tasa de crecimiento del PIB, tasa de interés hipotecaria y tasa de variación del precio del suelo (para RF)."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica expone las dos filosofías distintas con las que la econometría tradicional (OLS) y el aprendizaje automático (*Random Forest*) capturan la evolución del mercado inmobiliario a lo largo del tiempo y los ciclos macroeconómicos.

1. El reto de la valuación temporal y los ciclos de mercado

Cuando se trabaja con bases de datos que abarcan varios años (por ejemplo, el estudio de *Gangnam* de 2006 a 2017 o el de *Liubliana* de 2008 a 2013), los precios no solo dependen de las características intrínsecas de la vivienda (superficie, planta, baños) o de la localización. Los precios están fuertemente influenciados por factores macroeconómicos globales como la inflación, las expansiones o contracciones del crédito hipotecario, las tasas de empleo y las recesiones.

2. La aproximación en la Regresión Lineal (OLS): Variables *Dummies* Temporales

En los modelos hedónicos tradicionales estimados por Mínimos Cuadrados Ordinarios (MCO / OLS), la práctica estándar para ajustar los precios a lo largo del tiempo consiste en introducir variables categóricas dicotómicas (*dummies* temporales) para cada año o trimestre.

- Mecanismo: Se crea una variable binaria (0 o 1) para cada periodo. El coeficiente asignado a cada *dummy* absorbe la variación promedio del nivel general de precios de ese periodo específico con respecto al año base.
- Por qué no se suelen incluir variables macroeconómicas individuales en OLS: Si en un modelo OLS con *dummies* temporales se añaden de forma simultánea indicadores como el crecimiento del PIB o los tipos de interés de cada año, se genera una multicolinealidad perfecta o colinealidad exacta. Como el valor del PIB o del tipo de interés es el mismo para todas las viviendas vendidas en un año determinado, su efecto ya queda completamente

absorbido (*embedded*) dentro del coeficiente de la *dummy* temporal de ese año, haciendo redundante la inclusión de variables macro individuales.

3. La aproximación en *Random Forest* (RF): Indicadores Macroeconómicos Continuos

A diferencia de OLS, *Random Forest* no requiere asumir linealidad ni se desestabiliza por la presencia de variables continuas agregadas. Por ello, permite incorporar directamente indicadores macroeconómicos continuos explícitos en el conjunto de entrenamiento:

1. PIB (*Gross Domestic Product*): Representa el tamaño global de la economía.
2. Tasa de crecimiento del PIB real: Captura la fase del ciclo económico (expansión vs. recesión).
3. Tasa de interés hipotecaria: Refleja el coste del endeudamiento y la accesibilidad al crédito para los compradores.
4. Tasa de variación del precio del suelo: Mide la evolución del coste del suelo urbano.
5. Fecha / Periodo de transacción (trans_date): Registra la cronología exacta o el momento del contrato.

¿Por qué esto le da ventaja a *Random Forest*?

- Interacciones contextuales: *Random Forest* puede evaluar cómo afecta un cambio macroeconómico a diferentes tipos de inmuebles mediante divisiones en sus árboles (por ejemplo: "Si la tasa de interés hipotecaria > 5,8 % Y la superficie > 120 m²..."). Esto le permite detectar que un ciclo de tipos de interés altos no afecta por igual a las viviendas de lujo que a las viviendas de gama media o social.
- Captura de tendencias sin necesidad de deflactar previamente: En estudios como el de *Liubliana*, incluir la fecha de transacción (*trans_date*) permitió a *Random Forest* identificarla como la tercera variable más importante del modelo, ajustando de forma no lineal la caída del 28 % en los precios experimentada entre 2008 y 2013 sin necesidad de pre-ajustar los datos manualmente.

Tarjeta 15

En el anverso pone: "¿Cuáles son los dos parámetros teóricos clave de los cuales depende la precisión de un modelo *Random Forest*?" La respuesta del anverso es: "1. La fuerza (fidelidad predictiva) de los árboles individuales. 2. La correlación (dependencia) residual entre los árboles del bosque."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica proviene directamente del trabajo fundacional de *Leo Breiman* (2001), *"Random Forests"*, donde se establece el marco matemático formal que explica por qué este algoritmo de ensamble logra una alta precisión y resistencia al sobreajuste.

Breiman demostró que el error de generalización de un bosque aleatorio (PE^*) no crece al añadir más árboles, sino que converge a un límite estricto que depende de la interacción entre dos propiedades teóricas de los árboles de decisión subyacentes:

1. La fuerza de los árboles individuales (s)

- Definición: Mide la fidelidad o capacidad predictiva individual de cada árbol por separado.
- En clasificación: La fuerza (s) representa el margen promedio ponderado con el que las predicciones del árbol individual aciertan la clase correcta frente a la segunda clase más votada.
- En regresión / valuación de inmuebles: Corresponde al error cuadrático medio individual de los árboles (PE^*) (árbol).
- Impacto: Cuanto más preciso y capaz sea cada árbol por separado (es decir, mayor s o menor (PE^*) (árbol), mayor será la calidad de la base predictiva del ensamble.

2. La correlación entre los árboles ($\bar{\rho}$)

- Definición: Mide el grado de dependencia o similitud estadística entre los errores/residuos de dos árboles distintos del bosque ($T(X, \Theta_i)$ y $T(X, \Theta_j)$)
- El principio del ensamble: Si todos los árboles cometieran los mismos errores en los mismos inmuebles, promediarlos no aportaría ningún beneficio. Para que la sabiduría de la multitud funcione, los árboles deben ser lo más diversos e independientes posible.
- Impacto: Cuanto menor sea la correlación promedio ($\bar{\rho} \to 0$), mayor será la reducción de varianza que se logra al promediar sus predicciones.

3. La Cota Teórica de *Breiman* (Demostración Matemática)

Breiman unificó ambos parámetros en una cota superior matemática para el error de generalización (PE^*) del bosque:

Para Clasificación:

$$PE^* \leq \bar{\rho} \cdot \frac{1 - s^2}{s^2}$$

Donde la razón $\frac{\bar{\rho}}{s^2}$ (c/s² ratio) guía el desempeño del modelo: cuanto menor sea esta razón, menor será el error del bosque.

Para Regresión (Modelos AVM Inmobiliarios):

$$PE^*(\text{bosque}) \leq \bar{\rho} \cdot PE^*(\text{árbol})$$

Esta desigualdad muestra que el error global del bosque es igual al error promedio de un árbol individual multiplicado por el factor de correlación $\bar{\rho}$. Si logramos descorrelacionar los árboles ($\bar{\rho}$ < 1), el error del bosque será siempre una fracción del error de un árbol individual.

4. El dilema de diseño y el papel de la Doble Aleatoriedad

Existe un compromiso práctico (*trade-off*) entre ambos parámetros12:

1. Si intentamos hacer árboles muy fuertes (*s* alto) evaluando todas las variables disponibles en cada división, los árboles resultantes serán muy parecidos entre sí, aumentando la correlación ($\bar{\rho}$).
2. Si inyectamos demasiada aleatoriedad para reducir la correlación ($\bar{\rho} \to 0$), la capacidad individual de cada árbol (*s*) puede caer excesivamente.

Random Forest resuelve este dilema equilibrando la doble aleatoriedad:

- Aleatoriedad en datos (*Bagging*): Entrenar con muestras *bootstrap* reduce la correlación entre muestras de datos.
- Aleatoriedad en variables (*Random Subspaces*): Evaluar solo un subconjunto aleatorio *m* de características en cada nodo (por ejemplo, $m = \lfloor p/3 \rfloor$ rompe la correlación entre árboles manteniendo una fuerza predictiva suficiente en el ensamble.

Tarjeta 16

En el anverso pone: "¿Qué patrón geográfico de error compartido mostraron tanto OLS como *Random Forest* en el mercado de *Ljubljana*?" La respuesta del anverso es: "Ambos tendieron a subestimar las viviendas de precio más alto (SR < 1) y a sobreestimar las propiedades de menor precio (SR > 1), aunque los errores de RF fueron considerablemente menores."

¿Podrías explicarme este tema más detalladamente?

El patrón de error geográfico y por segmento de precio identificado en el estudio de *Liubliana* (Eslovenia) realizado por *Čeh et al*. (2018) revela un fenómeno muy conocido en la econometría y la valuación masiva inmobiliaria: el sesgo de regresión hacia la media.

A continuación, se detalla en qué consiste este patrón, por qué ocurre y en qué se diferenciaron ambos modelos.

1. El marco del indicador: Ratio de Ventas (*SR*)

Para evaluar la precisión del modelo en cada punto del mapa urbano, los autores calcularon el Ratio de Ventas (*Sales Ratio* o *SR*) para cada inmueble:

$$\text{SR} = \frac{\text{Precio Predicho por el Modelo } (\hat{p})}{\text{Precio Real de Venta registrado } (p)}$$

- *SR* < 1,0 (Subestimación): El modelo calcula un valor inferior al precio real de transacción de la vivienda.
- *SR* > 1,0 (Sobreestimación): El modelo calcula un valor superior al precio real pagado en el mercado.

2. El patrón compartido: ¿Qué ocurrió en el mercado de *Liubliana*?

Mediante un Análisis de Puntos Calientes (*Hot Spot Analysis Getis*–Ord G_i^*) cruzado con la distribución espacial de los precios de los 7.407 apartamentos analizados entre 2008 y 2013, los investigadores descubrieron que tanto OLS como *Random Forest* mostraron la misma tendencia de sesgo en los extremos del mercado:

1. Subestimación en las propiedades caras (*SR* < 1.0$):
    - Ubicación: Se concentró en el Distrito Central de Negocios (CBD), en la franja norte de desarrollo económico y en las zonas residenciales contemporáneas de alta gama (condominios con vistas hacia las montañas o el castillo medieval).
    - Comportamiento: En estas zonas de precios elevados (áreas con promedios superiores a los 3.000 €/m²), ambos algoritmos tendieron a predecir precios inferiores a los reales.
2. Sobreestimación en las propiedades baratas ($SR > 1.0$):
    - Ubicación: Ocurrió principalmente en la periferia de la ciudad, en áreas industriales del este o cerca de corredores ferroviarios (con mayor contaminación acústica y menor valor por m²).

- Comportamiento: En estas propiedades de menor valor comercial, los modelos tendieron a asignar precios predichos por encima de los montos reales pactados en la compraventa.

3. ¿Por qué ocurre este fenómeno?

Este patrón se debe al comportamiento de optimización global de los algoritmos de regresión: al intentar minimizar la suma global de errores cuadráticos sobre todo el conjunto de entrenamiento, las funciones de pérdida tienden a empujar las predicciones de los valores extremos (tanto los muy caros como los muy baratos) hacia el centro de la distribución (el precio promedio general del mercado).

4. La diferencia crucial: Magnitud y sensibilidad de *Random Forest*

Aunque ambos modelos compartieron la dirección del sesgo, la magnitud del error de *Random Forest* fue drásticamente menor:

- Regresión Lineal MCO (OLS):
  - Al intentar ajustar un único plano de regresión global sobre todo el mapa urbano, OLS no pudo capturar los picos de valor asociados a amenidades locales específicas (como vistas panorámicas o acabados de lujo).
  - Esto causó una infravaloración severa en los condominios de lujo y un Coeficiente de Dispersión (*COD*) del 17,12 %, superando el límite máximo aceptable de equidad fijado por la IAAO (15 %).
- *Random Forest* (*RF*)*:*
  - Al realizar particiones recursivas locales sobre subespacios de variables (evaluando conjuntamente coordenadas, planta del edificio, año de renovación de instalaciones y proximidad a servicios), *Random Forest* mostró una alta sensibilidad espacial.
  - En las zonas de precios más altos, las predicciones de *Random Forest* se mantuvieron mucho más cercanas a los valores reales que las de OLS ($SR_{RF} > SR_{OLS}$ en condominios clave).
  - Gracias a esta capacidad no lineal, *RF* redujo el *COD* al 7,28 % y el error porcentual medio (MAPE) del 17,48 % (OLS) al 7,27 % (RF).

Resumen para la práctica AVM

El estudio demostró que mientras un modelo lineal aplana el mercado inmobiliario e incurre en sesgos graves en los extremos de precio, *Random Forest* logra acotar significativamente esa distorsión,

permitiendo valoraciones automáticas mucho más equitativas tanto en viviendas de protección/social como en inmuebles residenciales de alta gama.

Tarjeta 17

En el anverso pone: "¿En qué consiste el método SHAP aplicado a modelos de valuación inmobiliaria 'caja negra'?" La respuesta del anverso es: "Calcula los valores Shapley basados en teoría de juegos para atribuir cuantitativamente la contribución (positiva o negativa) de cada atributo al precio predicho de una vivienda."

¿Podrías explicarme este tema más detalladamente?

El método SHAP (*SHapley Additive exPlanations*) se ha convertido en el estándar de Inteligencia Artificial Explicable (XAI) para resolver el problema de la "caja negra" (*black box*) en los Modelos de Valuación Automatizada (AVM) de alta precisión, como *Random Forest* o *Gradient Boosting* (GBM/XGBoost) [*Wang*, 2026].

A continuación, se detalla su origen, fundamento matemático y utilidad práctica en la auditoría de tasaciones inmobiliarias.

1. El dilema de la "Caja Negra" en AVMs

Modelos avanzados como *Random Forest* superan ampliamente a la regresión lineal hedónica tradicional en precisión (por ejemplo, reduciendo el error porcentual medio —MAPE— de casi un 20% a un 5,5 % en estudios masivos como el de *Gangnam* [*Hong et al*., 2020], o logrando coeficientes de determinación R^2 = 0,87 en Sevilla [Gutiérrez et al., 2026]). Sin embargo, estos algoritmos no entregan una fórmula matemática directa ni coeficientes estáticos [Guijarro, 2023; Gutiérrez et al., 2026].

Tradicionalmente, el modelo generaba una estimación puntual (ej. *368.500 €*) sin explicar cómo interactuó cada atributo para llegar a esa cifra final [Guijarro, 2023]. Esta opacidad dificulta la justificación técnica ante sociedades de tasación, auditores bancarios (bajo el marco de Basilea II) o autoridades fiscales en sistemas CAMA [*Hong et al*., 2020; Guijarro, 2023].

2. Fundamento Teórico: De la Teoría de Juegos a la Valuación

SHAP adapta los Valores *Shapley*, creados por el Premio Nobel *Lloyd Shapley* (1953) en el ámbito de la Teoría de Juegos Cooperativos [Gutiérrez et al., 2026]:

- La analogía: En un juego donde varios jugadores colaboran en equipo para obtener una recompensa común, los valores *Shapley* calculan matemáticamente la contribución justa e imparcial de cada jugador.
- Aplicación Inmobiliaria:
  - Los "Jugadores": Son las características del inmueble (superficie en m², número de baños, presencia de ascensor, antigüedad, renta de la zona, distancia al transporte público) [Gutiérrez et al., 2026].
  - La "Recompensa": Es la diferencia entre la estimación calculada para ese inmueble específico y el precio medio esperado de todo el mercado (Valor Base $\mathbb{E} = [f(X)]$) [Wang, 2026].

3. Formulación Matemático-Aditiva de SHAP

SHAP garantiza una propiedad de aditividad local: la predicción final $f(X)$ de una vivienda se descompone exactamente como la suma del valor base promedio del mercado más las contribuciones individuales (positivas o negativas) de cada atributo [Wang, 2026].

$$f(x) = \mathbb{E}[f(X)] + \sum_{j-1}^{p} \phi_j$$

Donde:

- $\mathbb{E}[f(X)]$: Es el valor promedio esperado de todas las viviendas en el dataset de entrenamiento [Wang, 2026].
- ϕ_j: Es el **Valor SHAP** (medido directamente en euros o log-precio) asignado a la característica j [Gutiérrez et al., 2026].

Ejemplo de Auditoría Local para un Inmueble:

```
Valor Medio del Mercado (Base E[f(X)]):  300.000 €
-------------------------------------------------
+ Superficie (110 m²):                  + 48.000 €
+ Renta Media Zona (Nivel Alto):        + 31.000 €
+ Garaje incluido:                      + 14.000 €
+ Conservación Excelente:               + 12.000 €
- Sin Ascensor:                         -  9.500 €
- Antigüedad (45 años):                 - 17.000 €
-------------------------------------------------
= Valor Estimado por Random Forest:     368.500 €
```

4. Ventajas Clave para el Análisis del Mercado Inmobiliario

1. Explicabilidad Doble (Global y Local) [Wang, 2026]:
    - Nivel Local (Tasación Individual): Muestra exactamente qué atributos impulsaron o penalizaron el valor de un inmueble específico, sirviendo como respaldo técnico transparente en informes de tasación [Wang, 2026].
    - Nivel Global (Estructura del Mercado): Mediante gráficos de abejas (*beeswarm plots*), SHAP agrupa todos los inmuebles para mostrar el rango de impacto y la jerarquía de variables a nivel urbano (evidenciando, por ejemplo, en estudios como el de Sevilla o Ames que la superficie y la renta socioeconómica son las variables con mayor peso global) [Gutiérrez et al., 2026; Wang, 2026].
2. Eficiencia con TreeSHAP: Para algoritmos basados en árboles como *Random Forest*, el algoritmo optimizado TreeSHAP permite calcular los valores *Shapley* exactos en tiempo polinómico explorando la estructura de las ramas del bosque [Wang, 2026].
3. Captura de No Linealidades e Interacciones: A diferencia de los coeficientes fijos de la regresión lineal (MCO), SHAP refleja cómo el impacto de una variable cambia según el contexto; por ejemplo, revela si el rendimiento marginal de metros cuadrados adicionales se estabiliza a partir de cierto tamaño o cómo interactúa la superficie con el nivel de ingresos de la zona [Gutiérrez et al., 2026; Wang, 2026].

5. Integración en Investigaciones Recientes

En investigaciones sobre mercados de vivienda en España y Estados Unidos (como los estudios de Sevilla [Gutiérrez et al., 2026] o Ames, Iowa [Wang, 2026]), los valores SHAP se combinan con Gráficos de Dependencia Parcial (PDP), Curvas ICE y herramientas locales como LIME [Gutiérrez et al., 2026; Wang, 2026]. Esta integración permite a los investigadores auditar el modelo ante muestras atípicas y verificar que las estimaciones automáticas cumplen estrictamente con la lógica de mercado y los estándares profesionales de valuación [Gutiérrez et al., 2026; Wang, 2026].

Tarjeta 18

En el anverso pone: "¿Qué ventajas ofrece *Random Forest* respecto al tratamiento de datos faltantes en avalúos inmobiliarios?" La respuesta del anverso es: "Al basarse en particiones de árboles de decisión, permite emitir predicciones utilizando las ramas previamente construidas incluso si faltan ciertos atributos en una propiedad."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica resalta una de las ventajas operativas más importantes de *Random Forest* en la práctica inmobiliaria y en los Modelos de Valoración Automatizada (AVM): su robustez nativa frente a los datos faltantes (*missing data*).

En las bases de datos de mercado (anuncios de portales inmobiliarios, registros catastrales o expedientes de tasación), es habitual que falten datos de ciertos atributos (por ejemplo, el año exacto de la última reforma, la presencia de ascensor o la distancia a equipamientos específicos).

1. El dilema de la regresión lineal tradicional (MCO / OLS)

En la econometría hedónica lineal tradicional, la estimación del precio depende de evaluar una ecuación rígida completa con un coeficiente β para cada atributo.

Si a un inmueble le falta el valor de una sola variable explicativa:

- Eliminación del registro (*Listwise deletion*): El modelo no puede calcular la ecuación y se ve obligado a descartar la propiedad por completo, perdiendo información valiosa de mercado.
- Imputación obligatoria manual: Exige rellenar artificialmente el dato faltante (mediante medias, medianas o modelos secundarios), lo que puede introducir sesgos y distorsionar la distribución real de los precios.

2. Cómo gestiona Random Forest los datos faltantes

Random Forest aborda los datos incompletos mediante mecanismos mecánicos y algorítmicos integrados:

A. Evaluación mediante subespacios de ramas construidas

Al estar compuesto por un ensamble de árboles de regresión, un inmueble recorre el árbol evaluando las condiciones binarias de cada nodo. Si en una propiedad falta determinado atributo, el modelo puede seguir emitiendo la predicción utilizando la porción de las ramas del árbol que ya han sido evaluadas con las variables que sí están disponibles (por ejemplo, superficie, planta y ubicación).

B. La inyección de Subespacios Aleatorios (*Random Subspaces*)

En *Random Forest*, cada árbol y cada nodo individual solo evalúan un subconjunto aleatorio de variables m (típicamente ($m = p/3$)). Esto significa que muchos árboles del bosque no utilizan el atributo faltante en sus divisiones, por lo que calculan el valor del inmueble sin ninguna interferencia ni pérdida de precisión.

C. Imputación mediante matrices de proximidad

Random Forest puede calcular de forma interna una matriz de proximidad basada en la frecuencia

con la que las propiedades terminan en las mismas hojas del bosque. Esto permite imputar valores faltantes de forma adaptativa utilizando los promedios ponderados de las propiedades más parecidas de la muestra de entrenamiento.

D. Ventaja adicional en la explicabilidad con TreeSHAP

Cuando se utilizan métodos de explicabilidad como TreeSHAP para auditar el modelo, si una característica falta en una propiedad, la contribución *Shapley* de dicha variable se puede ajustar directamente a 0 o marginalizar en la estructura del árbol, evitando introducir el sesgo típico de las imputaciones externas.

3. Impacto práctico en el entorno PropTech y AVM

- Retención del 100% de la oferta disponible: Permite aprovechar la totalidad de las ofertas de mercado recopiladas mediante *web scraping* o fuentes catastrales, incluso cuando los anuncios contienen campos incompletos.
- Valoraciones en tiempo real para usuarios: Cuando un cliente o tasador consulta un AVM en un portal inmobiliario y deja campos vacíos (por ejemplo, desconoce el año de instalación del tejado o la tasa del suelo), el modelo genera una estimación robusta fundamentada en el resto de los atributos estructurales y espaciales disponibles.

Tarjeta 19

En el anverso pone: "¿Qué diferencia fundamental existe entre un modelo de regresión lineal y un algoritmo de *Machine Learning* como *Random Forest* respecto a las interacciones entre variables?" La respuesta del anverso es: "El modelo de regresión requiere que el usuario defina explícitamente los términos de interacción, mientras que *Random Forest* los aprende de forma automática durante la división de nodos."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica resume una de las diferencias conceptuales y metodológicas más importantes entre la econometría hedónica tradicional y los algoritmos de aprendizaje automático adaptativos.

Para comprender a fondo la respuesta, conviene analizar qué es una interacción entre variables en el mercado inmobiliario, cómo la gestiona la regresión lineal (MCO / OLS) y de qué manera la descubre *Random Forest* de forma automática a través de la partición recursiva.

1. ¿Qué es una "Interacción entre Variables" en Valuación Inmobiliaria?

Existe una interacción cuando el impacto monetario de un atributo de la vivienda (X_1) sobre su precio

(Y_1) depende directamente del nivel o presencia de otra variable (X_2).

- Ejemplo del Ascensor y la Planta: La presencia de ascensor (X_1) añade un valor marginal muy modesto o casi nulo en una vivienda situada en planta baja (X_2). Sin embargo, en una cuarta o quinta planta de un edificio antiguo (X_2= 5), la presencia de ascensor incrementa significativamente el valor del inmueble.
- Ejemplo de la Superficie y la Renta del Barrio: El valor de añadir 20 m² adicionales (X_1) no es constante; aporta un incremento de precio mucho mayor si la vivienda se ubica en un distrito de renta alta (X_2) que en una zona periférica de ingresos bajos.

2. La Regresión Lineal (OLS): Especificación Manual y Rígida

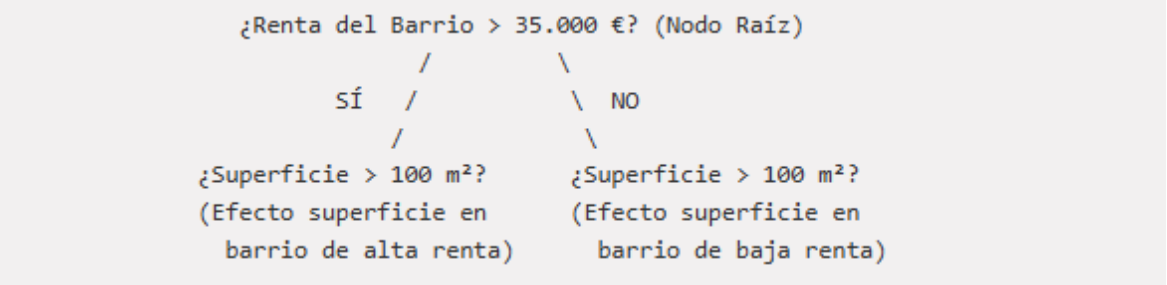
En la regresión hedónica tradicional por Mínimos Cuadrados Ordinarios, la ecuación asume de forma predeterminada que los atributos son independientes y estrictamente aditivos:

$$(Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon)$$

- Obligación de definición explícita: Si el valuador sospecha que dos variables interactúan, debe crear e introducir manualmente un término multiplicativo en la ecuación (por ejemplo, $\beta_3 \cdot (X_1 \cdot X_2))$
- Limitaciones prácticas:
    1. Explosión combinatoria: Si un dataset inmobiliario contiene 25 o 30 atributos (físicos, locacionales y socioeconómicos), existen cientos de posibles interacciones dobles y triples. Probar todas manualmente resulta inviable.
    2. Subjetividad y sesgo de especificación: Obliga al valuador a "adivinar" de antemano qué interacciones existen y asumir su forma funcional matemática.
    3. Multicolinealidad e inestabilidad: Incluir múltiples términos multiplicativos en OLS dispara el Factor de Inflación de la Varianza (VIF), inestabilizando los coeficientes β y degradando la capacidad predictiva.

3. *Random Forest*: Aprendizaje Automático e Implícito mediante Nodos

Random Forest no requiere que el usuario especifique de forma explícita ninguna interacción o forma funcional previa; el algoritmo las descubre de forma *data-driven* durante el entrenamiento.



- Estructura jerárquica de división (CART): Un árbol de regresión divide el espacio de datos mediante preguntas binarias secuenciales en los nodos. Cuando un árbol evalúa la Superficie en un nodo secundario tras haber dividido previamente la muestra por Renta del Barrio en el nodo raíz, está evaluando el impacto de la superficie condicionado al contexto socioeconómico de la zona.
- Naturaleza no paramétrica: La propia ramificación del árbol representa la interacción contextual sin necesidad de multiplicar variables algebraicamente.
- Exploración masiva en el ensamble: Al construir cientos de árboles independientes con subconjuntos aleatorios de variables (*Random Subspaces*), el bosque explora automáticamente interacciones complejas de alto orden entre atributos físicos, espaciales y temporales.

4. Medición de Interacciones Aprendidas (XAI)

Dado que *Random Forest* aprende las interacciones de forma implícita, la literatura reciente sobre valuación inmobiliaria utiliza herramientas de Inteligencia Artificial Explicable para extraerlas y auditarlas:

- Estadístico *H* de *Friedman*: Mide cuantitativamente qué proporción de la varianza del precio se debe a la interacción entre dos variables específicas frente a sus efectos individuales aislados.
- Valores de Interacción SHAP: Descomponen la predicción puntual evaluando cómo la combinación simultánea de dos características altera el valor final estimado en euros respecto al precio medio del mercado.

Tarjeta 20

En el anverso pone: "Para minimizar el error de un *Random Forest*, ¿qué relación matemática se busca entre la correlación (ρ) y la fuerza (s) de los árboles?" La respuesta del anverso es: "Se busca

minimizar el ratio ρ / s², es decir, obtener la menor correlación posible entre árboles manteniendo una alta fuerza predictiva individual."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica proviene directamente del trabajo fundacional de *Leo Breiman* (2001), *"Random Forests"*, donde se demuestra matemáticamente por qué el algoritmo logra una alta precisión y resistencia al sobreajuste.

1. El marco teórico de *Leo Breiman* (2001)

Breiman demostró que a medida que se añaden más árboles al bosque, el error de generalización (PE^*) no crece ni sobreajusta, sino que converge a un límite formal. Dicho límite está acotado superiormente por la relación entre la fuerza de los árboles y su correlación:

$$\mathbf{PE}^* \leq \bar{\rho} \cdot \frac{\mathbf{1} - \mathbf{s}^2}{\mathbf{s}^2}$$

De esta cota matemática surge el indicador $c/s^2 = \bar{\rho}/s^2$, denominado la **razón correlación-fuerza** del bosque aleatorio [3].

2. Desglose de los dos componentes clave

A. La fuerza (*s*) del árbol individual

- Definición: Mide la precisión predictiva individual de cada árbol por separado.
- En el mercado inmobiliario: Representa qué tan certero es un árbol aislado al estimar el precio o la categoría de un inmueble.
- Efecto matemático: Al encontrarse s² en el denominador del ratio ($\bar{\rho}/s^2$), cuanto mayor sea la fuerza de los árboles individuales, menor será la cota de error del ensamble.

3. ¿Por qué se busca minimizar la razón $\bar{\rho}/s^2$?

La fórmula demuestra que el éxito de *Random Forest* no depende únicamente de tener aprendices individuales muy precisos, sino de mantener un equilibrio óptimo entre precisión y diversidad:

- Si enfocamos el modelo solo en aumentar *s* (fuerza): Evaluando todas las variables en cada división, cada árbol elegirá siempre los mismos atributos dominantes (como la superficie y la localización), lo que volverá a los árboles casi idénticos y elevará la correlación ($\bar{\rho} \to 1$), desestabilizando el ensamble.

- Si enfocamos el modelo solo en reducir $\bar{\rho}$ (correlación): Inyectando demasiada aleatoriedad arbitraria, podríamos terminar construyendo árboles basados en atributos poco informativos, lo que destruiría la fuerza predictiva $(s \to 0)$ y dispararía el error global.

Por ello, la guía matemática para diseñar o ajustar un bosque aleatorio consiste en minimizar la división $\bar{\rho}/s^2$: construir árboles lo más descorrelacionados posible sin sacrificar en exceso su capacidad predictiva individual.

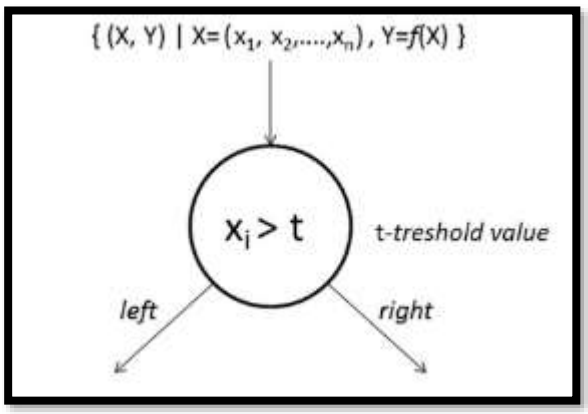
4. ¿Cómo resuelve Random Forest este dilema en la práctica?

El algoritmo alcanza este punto de equilibrio ajustando la doble aleatoriedad:

- Aleatoriedad en observaciones (*Bagging*): Extraer muestras *Bootstrap* independientes para cada árbol altera los datos de entrenamiento observados, reduciendo la correlación de partida.
- Aleatoriedad en atributos (*Random Subspaces*): En cada nodo de división, el algoritmo limita la búsqueda del mejor corte a un subconjunto aleatorio reducido de variables (*m*= max_features, por defecto $\lfloor p/3 \rfloor$ en regresión). Esto evita que una o dos variables dominantes acaparen todas las ramificaciones del bosque, reduciendo drásticamente la correlación ($\bar{\rho}\ \downarrow$) mientras preserva suficiente fuerza predictiva (*s*).

Tarjeta 21

En el anverso pone: "Diagrama de división en un nodo de árbol de regresión"



La respuesta del anverso es: "Se evalúa una prueba binaria ($X_i > t$) seleccionando la variable y el umbral *t* que minimizan la suma de cuadrados de los residuos (RSS) en las ramas resultantes."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica ilustra el mecanismo fundamental de construcción de un árbol de regresión (CART), el cual sirve como el bloque analítico indivisible sobre el que se edifica *Random Forest*.

1. La prueba binaria en el nodo ($X_i > t$)

Cada nodo interno del árbol representa una decisión binaria basada en un atributo específico de la vivienda (X_i) y un valor de umbral numérico (t).

Cuando un conjunto de propiedades llega a un nodo durante la fase de entrenamiento, la regla de decisión las divide en dos subconjuntos o ramas independientes34:

- Rama Izquierda (L): Almacena las observaciones donde el atributo cumple la condición ($X_i > t$).
- Rama Derecha (R): Almacena las observaciones restantes que no la cumplen ($X_i \leq t$).

2. Las predicciones locales en las ramas (Y_{left} y Y_{right})

En los problemas de regresión y valuación inmobiliaria (donde la variable respuesta Y es continua, como el precio del inmueble), la predicción asignada a cada rama corresponde al precio promedio de las viviendas que caen dentro de esa partición específica:

$$Y_{left} = \frac{1}{|L|} \sum_{(X,Y)\in L} Y \quad \text{y} \quad Y_{right} = \frac{1}{|R|} \sum_{(X,Y)\in R} Y$$

Donde $|L|$ y $|R|$ representan la cantidad de observaciones contenidas en la rama izquierda y derecha, respectivamente [4].

3. Criterio de optimización: Minimización del RSS

Para determinar qué atributo X_i evaluar y en qué punto exacto fijar el umbral t, el algoritmo realiza una búsqueda codiciosa (*greedy search*) evaluando la Suma de Cuadrados de los Residuos (RSS) resultante tras la división:

$$RSS = \sum_{(X,Y)\in L} \left(Y - Y_{left}\right)^2 + \sum_{(X,Y)\in R} \left(Y - Y_{right}\right)^2$$

- Medida de homogeneidad/impureza: El *RSS* mide la variabilidad o "desorden" de los precios en las ramas hijas.
- Regla de división: El algoritmo elige la combinación de variable X_i y umbral t que logre la máxima reducción posible del *RSS* (es decir, el mayor decremento de impureza/varianza) en comparación con el *RSS* que tenía el nodo padre antes de dividirse.

4. Ejemplo práctico en Valuación Inmobiliaria (AVM)

Imaginemos un nodo recibiendo una muestra heterogénea de apartamentos con precios que varían desde 100.000 € hasta 500.000 €:

1. El algoritmo prueba múltiples escenarios: *¿Superficie* > 80 m²*?*, *¿Antigüedad* > 15 años}$*?*, *¿Distancia al metro* > 500 m*?*
2. Si la prueba $x_{\text{superficie}} > 85\ \text{m}^2$ separa la muestra de forma que la rama izquierda agrupa casi exclusivamente viviendas de alto valor y la rama derecha agrupa viviendas pequeñas de menor precio, el *RSS* de ambas ramas caerá drásticamente.
3. Al minimizar el *RSS*, el algoritmo garantiza que cada subdivisión del espacio urbano contenga propiedades internamente homogéneas, aislando submercados de forma automática y adaptativa sin imponer ecuaciones lineales rígidas.

Tarjeta 22

En el anverso pone: "¿Qué es la 'relación de densidad construida' (*Building Coverage Ratio* - BCR) en los atributos del vecindario?" La respuesta del anverso es: "Es la proporción o porcentaje resultante de dividir el área de la huella del edificio entre la superficie total del terreno."

¿Podrías explicarme este tema más detalladamente?

La Relación de Densidad Construida (conocida en inglés como Building Coverage Ratio o BCR, y en el urbanismo hispanohablante como Coeficiente de Ocupación del Suelo — COS o Porcentaje de Ocupación) cuantifica la proporción del terreno o parcela que queda físicamente cubierta por la proyección horizontal de la edificación (su "huella" en planta baja).

1. Formulación matemática y significado físico

Su cálculo responde a la siguiente ecuación:

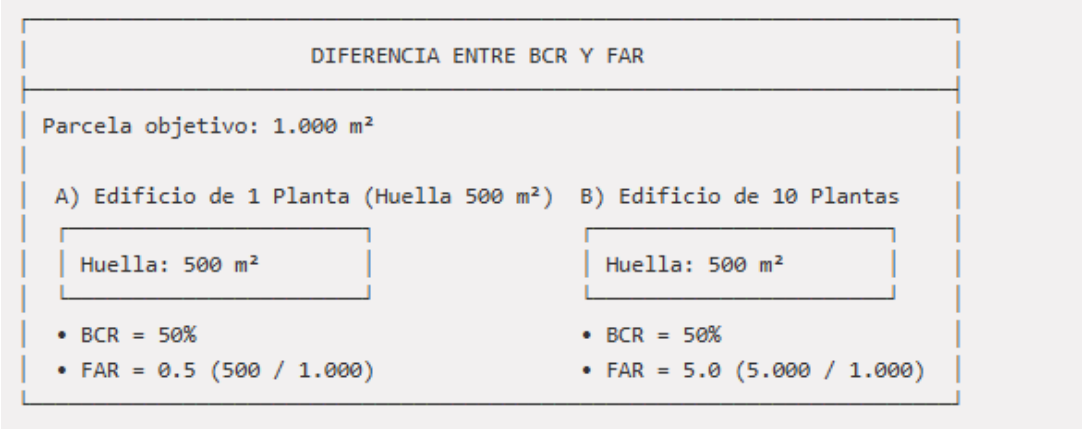
$$\text{BCR} = \left(\frac{\text{Área de la Huella del Edificio (}\textit{Building Area}\text{)}}{\text{Superficie Total del Terreno (}\textit{Land Area}\text{)}} \right) \times 100$$

- Ejemplo práctico: En un terreno de 1.000 m², si la base de la construcción ocupa 250 m², el BCR es del 25 %. El 75 % restante del lote se reserva para espacios libres, patios, jardines, vías de acceso o aparcamientos en superficie.

Diferencia crucial: BCR frente a FAR (*Floor Area Ratio*)

En la ciencia de la valuación inmobiliaria y el análisis catastral, es fundamental diferenciar el BCR del FAR (*Floor Area Ratio* / Coeficiente de Edificabilidad Total):

- BCR (Ocupación en Planta / Densidad Horizontal): Mide únicamente la "pisada" o superficie que el edificio ocupa directamente sobre la parcela en planta baja.
- FAR (Edificabilidad Total / Densidad Vertical): Mide la suma de la superficie construida de todas las plantas dividida por la superficie del terreno.



3. Importancia del BCR en los Modelos de Valoración Automatizada (AVM)

En las bases de datos empleadas para entrenar modelos masivos de valuación (como en el estudio de transacciones de apartamentos en el distrito de *Gangnam,* Seúl), el BCR se registra dentro del grupo de atributos del vecindario y del complejo edilicio (*neighborhood attributes*).

Su utilidad predictiva se fundamenta en varios aspectos:

1. Indicador de calidad residencial y amenidades: Un BCR bajo en complejos residenciales indica que existe mayor proporción de superficie no edificada por metro de parcela, lo que suele asociarse a áreas ajardinadas, mayor distanciamiento entre edificios, ventilación y privacidad (factores que generan primas de valor en el mercado).
2. Evaluación de la saturación del suelo: Un BCR excesivamente alto indica una ocupación intensiva del suelo que puede limitar los espacios comunes o las plazas de aparcamiento en superficie.
3. Procesamiento no lineal en *Random Forest*: A diferencia de los modelos lineales tradicionales que tratan de asignar un precio fijo a cada porcentaje de ocupación, *Random Forest* evalúa el BCR de forma conjunta con el FAR, el número de edificios del complejo y la renta de la zona. Esto le permite capturar de forma no lineal si un determinado porcentaje de ocupación corresponde a una urbanización de lujo con espacios abiertos o a un bloque de

alta densidad urbana.

Tarjeta 23

En el anverso pone: "¿Qué problemas estadísticos suelen erosionar la precisión de los modelos OLS en la estimación de precios de viviendas?" La respuesta del anverso es: "Mala especificación de la forma funcional, multicolinealidad entre variables, presencia de no linealidades y sensibilidad a valores atípicos (outliers)."

¿Podrías explicarme este tema más detalladamente?

Los modelos hedónicos tradicionales basados en Mínimos Cuadrados Ordinarios (MCO / OLS) han sido la piedra angular de la valuación masiva inmobiliaria durante décadas. Sin embargo, en mercados residenciales reales —caracterizados por la heterogeneidad y la complejidad urbana— el rendimiento predictivo de OLS suele verse severamente degradado por cuatro problemas estadísticos fundamentales:

1. Mala especificación de la forma funcional (*Functional Form Misspecification*)

- El problema de fondo: Para aplicar la regresión por Mínimos Cuadrados Ordinarios, el econometrista o valuador debe asumir y fijar de antemano una ecuación matemática rígida (lineal, semilogarítmica o log-log).
- Supuestos irreales: La especificación lineal tradicional presupone la separabilidad y constancia de los efectos de cada atributo sobre el precio de la vivienda. Esto implica asumir implícitamente que la preferencia de los compradores es idéntica en todo el mercado y que cada atributo afecta al precio de forma aislada y constante a través de un único coeficiente (β).
- Efecto en la precisión: En la realidad, el mercado se divide en múltiples submercados (por tipología, tamaño o rango socioeconómico). Un modelo lineal rígido no posee la flexibilidad para adaptarse a estas variaciones de preferencia, provocando un sesgo de especificación que distorsiona las estimaciones.

2. Multicolinealidad entre variables explicativas

- El problema de fondo: En la valuación de inmuebles, las variables explicativas están intrínsecamente correlacionadas entre sí (por ejemplo, la superficie construida se correlaciona con la superficie útil, el número de habitaciones, los baños, las plazas de garaje o el tamaño del terreno).

- Impacto matemático en OLS: Cuando existe una alta multicolinealidad (evidenciada por un Factor de Inflación de la Varianza o VIF > 5–10), la matriz de varianza-covarianza $(X'X)^{-1}$ empleada por OLS para despejar los coeficientes $(\hat{\beta})$ se vuelve matemáticamente inestable.
- Efecto en la precisión:
    - Infla desproporcionadamente los errores estándar de los coeficientes estimados.
    - Vuelve a los parámetros sumamente volátiles y sensibles a pequeñas variaciones en los datos de entrenamiento.
    - Impide aislar o interpretar con precisión el "precio implícito marginal" real de cada atributo individual. *(*Aunque técnicas como el Análisis de Componentes Principales - PCA se usan para mitigar la multicolinealidad antes de OLS, destruyen la interpretabilidad directa de las variables originales*).*

3. Presencia de no linealidades e interacciones complejas

- El problema de fondo: La relación entre las características inmobiliarias y el precio es inherentemente no lineal y está llena de efectos umbral e interacciones contextuales.
    - Rendimientos decrecientes: Un incremento marginal de 20 m² no aporta el mismo valor en un apartamento pequeño que en una propiedad de gran tamaño.
    - Interacciones de atributos: La presencia de ascensor añade un valor modesto en plantas bajas, pero es determinante en plantas elevadas; asimismo, la proximidad a una autopista o estación de metro beneficia la accesibilidad hasta cierto rango, a partir del cual el ruido y las externalidades negativas penalizan el precio.
- Efecto en la precisión: OLS no puede capturar estas interacciones a menos que el valuador las cree e introduzca manualmente una a una (lo cual es inviable cuando existen decenas de atributos). Como resultado, OLS tiende a mostrar un sesgo de regresión hacia la media, sobreestimando de forma sistemática las propiedades más baratas y subestimando las viviendas de lujo o alta gama.

4. Sensibilidad a valores atípicos (*Outliers*)

- El problema de fondo: El algoritmo de OLS calcula la línea o plano de regresión minimizando la Suma de los Residuos al Cuadrado (RSS).
- Efecto en la precisión: Al elevar al cuadrado las desviaciones entre las predicciones y los precios reales, cualquier observación atípica, transacción fuera de mercado o error de

registro ejerce una tracción desproporcionada sobre la pendiente de la regresión. Esto distorsiona las estimaciones de todo el conjunto de datos y genera una frecuencia de errores de predicción graves sustancialmente mayor que la de algoritmos adaptativos (en experimentos comparativos como el de *Gangnam*, la probabilidad de cometer errores extremos superiores al 50 % en la predicción del precio fue casi 8 veces mayor en OLS que en *Random Forest*).

Resumen Comparativo

Problema Estadístico	Comportamiento en OLS / MCO	Solución en Algoritmos Adaptativos (ej. *Random Forest*)
Forma Funcional	Asume linealidad y separabilidad rígida por defecto.	No paramétrico; construye estructuras jerárquicas basadas en datos.
Multicolinealidad	Inestabilidad en coeficientes y elevación del VIF.	Distribuye la información redundante en subespacios aleatorios de variables (*Random Subspaces*).
No Linealidades	Incapaz de detectarlas sin términos especificados a mano.	Las aprende de forma automática mediante la ramificación recursiva de nodos.
Valores Atípicos	Alta sensibilidad debido a la minimización de residuos al cuadrado.	Alta resistencia gracias al promediado de múltiples árboles independientes (*Bagging*).

Tarjeta 24

En el anverso pone: "¿Cuáles son las dos técnicas clave que utiliza Random Forest para garantizar la diversidad entre sus árboles?" La respuesta del anverso es: "1. Muestreo *Bootstrap* con reemplazo (*Bagging*). 2. Selección aleatoria de un subconjunto de variables (predictores) en cada división de nodo."

¿Podrías explicarme este tema más detalladamente?

1. El objetivo de fondo: Reducir la correlación entre árboles

Para comprender por qué se necesitan estas dos técnicas, conviene recordar la teoría matemática de *Random Forest*: El error de generalización de un bosque aleatorio depende de la relación entre dos factores:

1. La fuerza (*s*): La capacidad predictiva e individual de cada árbol por separado3more_horiz.

2. La correlación ($\bar{\rho}$): El grado de similitud entre los errores que cometen los árboles del bosque3more_horiz.

Si todos los árboles se entrenaran exactamente con el mismo conjunto de datos y evaluaran las mismas variables en las mismas posiciones, construir miles de árboles no aportaría ningún beneficio, pues todos cometerían los mismos errores (alta correlación). Para que el promediado del bosque reduzca la varianza global, es imprescindible forzar a los árboles a ser lo más diversos e independientes posible.

Para lograrlo, *Random Forest* aplica una doble capa de aleatoriedad.

2. Primera técnica: Muestreo *Bootstrap* con Reemplazo (*Bagging*)

- ¿En qué consiste?: Acrónimo de *Bootstrap Aggregating* (término introducido por *Breiman* en 1996). En lugar de entrenar todos los árboles con la base de datos original completa, el algoritmo genera para cada árbol una nueva muestra de entrenamiento de tamaño *N* seleccionando registros al azar con reemplazamiento.
- Efecto en los datos: Dado que la selección es con reemplazo, algunas propiedades o transacciones se repetirán en la muestra de entrenamiento de un árbol individual, mientras que aproximadamente un tercio de las observaciones (36,8 %) quedará excluida de ese árbol en particular. Este grupo excluido conforma las muestras *Out-Of-Bag* (OOB).
- Impacto en la diversidad: Al alterar las muestras de entrada de un árbol a otro, ningún árbol observa exactamente la misma combinación de datos. Esto diversifica las particiones iniciales y reduce la varianza de la predicción final al promediar el ensamble.

3. Segunda técnica: Selección Aleatoria de Variables (*Random Subspaces*)

- ¿En qué consiste?: A diferencia de *Bagging* convencional —donde cada árbol evalúa *todas* las variables disponibles en cada nodo—, *Random Forest* restringe intencionadamente el abanico de predictores en cada bifurcación.
- Mecanismo en cada nodo:
    - En cada división de cada árbol, el algoritmo selecciona al azar un subconjunto reducido de variables *m* de un total de *p* características explicativas. En problemas de regresión o valuación inmobiliaria, el estándar por defecto suele ser $m = \lfloor p/3 \rfloor$.
    - La mejor división binaria (la que maximiza la reducción de la impureza o del RSS) se busca únicamente entre ese subconjunto de *m* variables elegidas al azar.

- Por qué es determinante para romper la correlación:
    - En conjuntos de datos inmobiliarios suele haber uno o dos atributos enormemente dominantes (por ejemplo, la superficie construida o la localización). Si se evaluaran todas las variables en cada nodo, prácticamente todos los árboles elegirían la superficie en la raíz y en las primeras divisiones, resultando en una colección de árboles muy parecidos entre sí (alta correlación).
    - Al limitar las variables disponibles a una fracción aleatoria en cada nodo, se obliga a diferentes árboles a explorar y aprender el impacto de variables secundarias o no lineales (como la planta, el año de reforma o la presencia de ascensor).

4. Síntesis: La "Doble Aleatoriedad" en Acción

Dimensión de Aleatoriedad	Técnica Utilizada	Objeto de la Aleatorización	Resultado en el Bosque
En las observaciones	*Bagging* (Bootstrap)	Filas / Muestras de datos	Diversifica los datos observados por cada árbol y genera muestras OOB para validación [2] [15].
En las características	*Random Subspaces*	Columnas / Atributos explicativos	Rompe la dominancia de variables principales y descorrelaciona la estructura de las ramas [8] [9].

Gracias a la sinergia de ambas técnicas, *Random Forest* logra minimizar la correlación ($\bar{\rho}$) manteniendo la fuerza (s) de los árboles individuales, garantizando la convergencia del error y evitando el sobreajuste a medida que se agregan más árboles al modelo.

Tarjeta 25

En el anverso pone: "En la investigación sobre precios de la vivienda en Sevilla (2026), ¿qué combinación metodológica se empleó para interpretar el modelo Random Forest?" La respuesta del anverso es: "Regresión hedónica combinada con *Random Forest* y técnicas XAI como SHAP, Gráficos de Dependencia Parcial (PDP) y Curvas de Expectativa Individual Condicional (ICE)."

La tarjeta didáctica aborda el estudio empírico realizado por Gutiérrez, López del Río y Caridad Ocerín (2026) sobre el mercado residencial de Sevilla (publicado en la Revista INVI), el cual representa uno de los marcos metodológicos más avanzados en la literatura reciente de valuación inmobiliaria.

El objetivo central de la investigación fue resolver el dilema clásico de la valuación con Machine Learning: cómo aprovechar la alta precisión predictiva de *Random Forest* sin perder la interpretabilidad y la transparencia necesarias para la auditoría técnica de los avalúos.

1. La Capa Dual: Estimación Predictiva (MCO + *Random Forest*)

Para evaluar la formación de precios en un dataset de 1.710 apartamentos recolectados en Sevilla, los autores estructuraron un enfoque comparativo en dos niveles:

1. Modelo Econométrico de Referencia (Regresión Hedónica MCO):
    - Sirvió como línea base lineal para estimar los precios implícitos marginales de los atributos estructurales, de localización y socioeconómicos.
    - Presentó limitaciones típicas: problemas de multicolinealidad entre variables de entorno y un ajuste inferior (R^2= 0,788 y un error porcentual absoluto medio MAPE= 27,8 %).

2. Modelo Adaptativo de Ensamble (*Random Forest*):

- Utilizó 500 árboles de decisión en una arquitectura optimizada mediante *grid search* y validación cruzada de 10 pliegues (*10-fold CV*).
- Capturó de forma automática las interacciones y no linealidades del mercado, reduciendo el error promedio a MAPE = 19,6 %, reduciendo el error absoluto medio (MAE) de ~45.153 € a ~32.143 € por vivienda y elevando el ajuste a R^2 = 0,870.

2. La Capa de Explicabilidad (XAI): SHAP + PDP + ICE

Para "abrir la caja negra" de *Random Forest* y comprender cómo el algoritmo construyó sus predicciones, el estudio aplicó un tríptico de Inteligencia Artificial Explicable (*Model-Agnostic* XAI):

```
┌──────────────────────────────────────────────────────────────┐
│              TRÍPTICO DE EXPLICABILIDAD (XAI) EN SEVILLA     │
├──────────────────────────────────────────────────────────────┤
│ 1. SHAP (Valores Shapley)                                    │
│    └─ Mide la magnitud y dirección (+ / -) de cada atributo en euros.
│                                                              │
│ 2. PDP (Partial Dependence Plots)                            │
│    └─ Muestra la tendencia marginal PROMEDIO global de una variable.
│                                                              │
│ 3. ICE (Individual Conditional Expectation)                  │
│    └─ Muestra las curvas INDIVIDUALES de cada vivienda para detectar
│       heterogeneidad no observada o submercados.             │
└──────────────────────────────────────────────────────────────┘
```

A. SHAP (*SHapley Additive exPlanations*)

- Basado en la teoría de juegos cooperativos, descompone la predicción final de cada inmueble en sumas de contribuciones monetarias de sus características.
- Utilidad en Sevilla: Permitió establecer un ranking global de importancia relativa y evaluar el tipo de impacto (positivo o negativo). Reveló que la renta media de la sección censal (renta) y el nivel educativo de la zona (*educ_sup*) ejercen el mayor impacto positivo sobre el valor de la vivienda, superando a varios atributos físicos tradicionales.

B. Gráficos de Dependencia Parcial (PDP - *Partial Dependence Plots*)

- Calculan el efecto promedio marginal que tiene una variable explicativa sobre el precio predicho a lo largo de toda la muestra, manteniendo constantes el resto de las variables.
- Utilidad en Sevilla: Evidenciaron formas funcionales no lineales y efectos umbral. Por ejemplo, en el caso del número de baños (*bano*), el PDP mostró que el mayor incremento de valor ocurre al pasar de 1 a 2 baños, mientras que el salto hacia un tercer baño aporta un rendimiento marginal notablemente inferior.

C. Curvas de Expectativa Individual Condicional (ICE - *Individual Conditional Expectation*)

- Mientras que el PDP dibuja una sola línea con el comportamiento *promedio*, las curvas ICE grafican una línea de respuesta individual para cada vivienda de la muestra.
- Utilidad en Sevilla: Permiten detectar si la relación aprendida por *Random Forest* es uniforme en toda la ciudad o si existen submercados con respuestas divergentes. Si las líneas ICE corren paralelas, la relación es homogénea; si las líneas se cruzan o divergen, señala heterogeneidad espacial o interacciones severas entre atributos.

Adicionalmente, los autores emplearon el Estadístico H de *Friedman* para cuantificar matemáticamente la fuerza de las interacciones no lineales entre pares de variables, destacando la interacción entre la renta de la zona y la superficie.

3. Principales hallazgos revelados por esta combinación

1. Resolución de anomalías de MCO: En la regresión hedónica lineal, la variable número de habitaciones mostraba un coeficiente negativo ambiguo debido a su alta colinealidad con la superficie. La combinación RF + SHAP/PDP/ICE aclaró la verdadera dinámica: el incremento de precio se concentra al pasar de 2 a 3 dormitorios (asociado a demanda familiar), volviéndose nulo o estabilizado en 4 o más estancias para una misma superficie dada.

2. Sensibilidad a la accesibilidad (Metro): MCO asumía una relación lineal uniforme para la distancia a las estaciones de metro. La metodología XAI reveló un patrón no lineal: las viviendas inmediatamente adyacentes a las estaciones sufren pequeñas penalizaciones por ruido/tráfico, situándose la mayor prima de valor en distancias intermedias (~1 km).

Conclusión para la Práctica AVM

La integración de Regresión Hedónica + Random Forest + SHAP + PDP + ICE demuestra que es posible adoptar modelos avanzados de Machine Learning en la valuación masiva sin incurrir en opacidad. Esta metodología entrega la precisión técnica requerida por el mercado financiero y, al mismo tiempo, los gráficos de auditoría transparentes necesarios para validar el avalúo ante reguladores y clientes.

Tarjeta 26

En el anverso pone: "Según el teorema de convergencia de *Breiman* (2001), ¿qué sucede con el error de generalización de un *Random Forest* a medida que aumenta el número de árboles?" La respuesta del anverso es: "El error de generalización converge casi con certeza a un límite fijo, lo que demuestra que *Random Forest* no sufre de sobreajuste (*overfitting*) al agregar más árboles."

¿Podrías explicarme este tema más detalladamente?

El Teorema de Convergencia de *Leo Breiman* (2001) es la demostración matemática formal que explica por qué el algoritmo Random Forest es inmune al sobreajuste (*overfitting*) a medida que se agregan más árboles al ensamble.

1. El enunciado del Teorema y la Ley Fuerte de los Grandes Números

Breiman planteó que cada árbol individual *k* del bosque se construye a partir de un vector aleatorio Θ_k (que gobierna tanto la muestra *bootstrap* como la selección aleatoria de variables en cada nodo). Los vectores $\Theta_1, \Theta_2, \ldots \Theta_k$ son variables aleatorias independientes e idénticamente distribuidas (i.i.d.).

Dado un conjunto de entrenamiento extraído de la distribución de las variables del mercado (*Y*, *X*), el teorema establece que conforme el número de árboles (*K*) tiende a infinito, el error de generalización (PE^*) converge casi con certeza (almost surely) a un límite fijo constante:

- **En Clasificación (Teorema 1.2):**

$$PE^* \xrightarrow[K\to\infty]{\text{a.s.}} P_{X,Y}\left(P_\Theta(h(X,\Theta)=Y) - \max_{j\neq Y} P_\Theta(h(X,\Theta)=j) < 0\right)$$

(El error converge a la probabilidad de que el margen de votos esperado sea negativo) [1] [2].

- **En Regresión / AVM Inmobiliario (Teorema 11.1):**

$$\mathbb{E}_{X,Y}\left(Y - \bar{h}_K(X)\right)^2 \xrightarrow[K\to\infty]{\text{a.s.}} \mathbb{E}_{X,Y}\left(Y - \mathbb{E}_\Theta[h(X,\Theta)]\right)^2$$

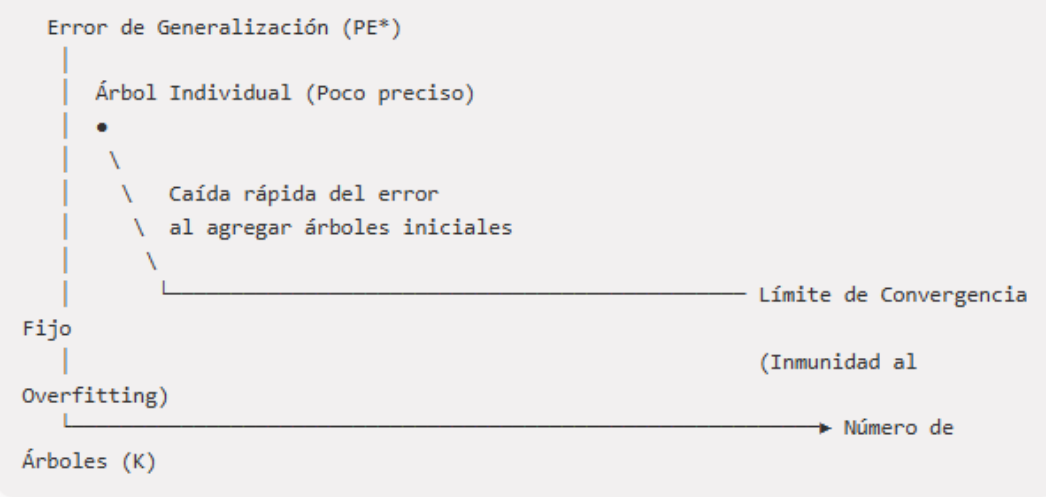
(El error cuadrático medio de la predicción promedio del bosque converge a la esperanza teórica de los árboles individuales) [6].

2. ¿Por qué esto demuestra que Random Forest NO sufre de sobreajuste?

En muchos algoritmos de aprendizaje automático o en árboles de decisión individuales muy profundos, agregar más complejidad o más estimadores secuenciales puede llevar a que el modelo memorice el ruido del dataset de entrenamiento, provocando que el error de prueba (*test error*) vuelva a crecer (curva en forma de "U").

Sin embargo, el Teorema de *Breiman* demuestra que en *Random Forest*:

1. Estabilización de la varianza: Al agregar árboles adicionales, la estimación del bosque no añade varianza arbitraria ni "se aprende los datos de memoria", sino que simplemente aproxima con mayor precisión matemática la integral/esperanza continua de la distribución $\mathbb{E}_\Theta[h(X,\Theta)]$.
2. Existe un techo límite de error: Una vez que el bosque alcanza una cantidad suficiente de árboles (por ejemplo, entre 100 y 500 árboles en la mayoría de las aplicaciones de valuación masiva), el error de generalización se estanca en una asíntota plana y ya no vuelve a subir.



3. ¿De qué depende la calidad del límite al que converge el bosque?

Aunque el teorema garantiza que el error no crecerá, la precisión final alcanzada en ese límite fijo depende de dos parámetros teóricos clave introducidos por *Breiman*:

1. La fuerza promedio de los árboles (*s*): Qué tan precisos son los árboles individuales para estimar el valor del inmueble.
2. La correlación residual entre árboles ($\bar{\rho}$): Qué tan dependientes o similares son los errores cometidos por los distintos árboles del bosque.

Breiman demostró que la cota superior del error de generalización es directamente proporcional a la correlación e inversamente proporcional al cuadrado de la fuerza ($PE^* \leq \bar{\rho} \cdot \frac{1-s^2}{s^2}$) en clasificación, o $PE^* \leq \bar{\rho} \cdot PE^*$(árbol) en regresión).Gracias a la doble aleatoriedad (*Bagging* + selección aleatoria de variables en cada nodo/*Random Subspaces*), *Random Forest* logra mantener la correlación $\bar{\rho}$ muy baja, asegurando que la convergencia ocurra en un nivel de error sustancialmente menor que el de cualquier árbol individual.

4. Implicaciones prácticas en la Valuación Inmobiliaria (AVM)

Para la construcción práctica de Modelos de Valoración Automatizada:

- Sin necesidad de "detención temprana" (*Early Stopping*): A diferencia de algoritmos como *Gradient Boosting* (GBM/XGBoost) o redes neuronales —donde hay que monitorear cuidadosamente la iteración exacta para detener el entrenamiento antes de que sobreajuste—, en *Random Forest* el parámetro *n_estimators* no requiere un ajuste fino obsesivo.
- Criterio de eficiencia: En la práctica, fijar de 100 a 500 árboles suele ser suficiente para alcanzar la convergencia numérica del error sin incurrir en costes de cómputo innecesarios.

Tarjeta 27

En el anverso pone: "¿Qué evalúa el Coeficiente de Dispersión (COD) en el ámbito de la valuación inmobiliaria masiva?" La respuesta del anverso es: "Mide la uniformidad del avalúo evaluando la desviación porcentual promedio de los ratios de venta $(SR_i = \hat{p}_i/p_i)$ con respecto a la mediana del ratio de ventas."

¿Podrías explicarme este tema más detalladamente?

El Coeficiente de Dispersión (COD) es el indicador métrico fundamental exigido por organismos reguladores e instituciones catastrales para auditar la uniformidad y equidad de las valoraciones masivas generadas por un Modelo de Valuación Automatizada (AVM) o un sistema CAMA (*Computer Assisted Mass Appraisal*).

Mientras que métricas como el MAPE o el RMSE miden la magnitud global del error en términos porcentuales o monetarios, el COD evalúa la consistencia distributiva del error entre distintos tipos de inmuebles, verificando que el modelo no favorezca ni penalice injustamente a determinados grupos de propietarios.

1. Formulación Matemática y Significado

El cálculo del COD analiza cómo se distribuyen los Ratios de Ventas $(SR_i = \hat{p}_i/p_i)$ de cada inmueble respecto a la mediana del ratio de ventas de toda la muestra SR_m:

$$COD = \frac{100}{SR_m}\left(\frac{\sum_{i-1}^{n}|SR_i - SR_m|}{n}\right)$$

Donde:

- $SR_i = \frac{\hat{p}_i}{p_i}$: Es el cociente entre el precio predicho por el modelo $(\hat{p}_i)$ y el precio real registrado de la transacción (p_i) [2] [3].
- SR_m: Es la **mediana** de todos los ratios de ventas del conjunto de datos [2] [6].
- n: Es el número total de transacciones analizadas [2] [6].

Matemáticamente, el COD representa la desviación absoluta promedio de los ratios de venta respecto a su mediana, expresada como un porcentaje de dicha mediana.

2. ¿Por qué se utiliza la Mediana y no la Media?

En el análisis catastral y tributario, la distribución de los ratios de venta no suele seguir una curva normal simétrica, sino que presenta sesgos y valores atípicos (*outliers*) debido a transacciones atípicas o errores de registro. El uso de la mediana SR_m en lugar de la media aritmética garantiza que la métrica de equidad sea robusta y no paramétrica, impidiendo que unas pocas ventas distorsionadas alteren la evaluación global del sistema AVM.

3. Umbrales Aceptables y Estándares Internacionales (IAAO)

Según las directrices fijadas en la *Guidance on International Mass Appraisal and Related Tax Policy* de la **IAAO** (*International Association of Assessing Officers*), los valores aceptables del COD para inmuebles residenciales se clasifican en:

Rango de COD (%)	Interpretación Tributaria e Institucional
< 5.0%	**Uniformidad excepcional:** Estimaciones extremadamente consistentes en todo el mercado [8].
5.0% – 15.0%	**Rango Aceptable (Estándar IAAO):** Refleja un nivel adecuado de equidad tributaria y precisión en la valuación masiva [6].
> 15.0%	**Falta de Uniformidad / Inaceptable:** Existe una dispersión excesiva que invalida el modelo para fines de imposición fiscal, generando inequidad y reclamos tributarios [6] [9].

4. Desempeño Comparativo: Random Forest frente a Regresión Lineal (OLS)

En las auditorías empíricas documentadas en las fuentes, la regresión hedónica tradicional por Mínimos Cuadrados Ordinarios (OLS) suele superar el límite del 15 %, mientras que *Random Forest* logra mantenerse ampliamente dentro del rango aceptable:

- **Estudio de Gangnam (Seúl):**
  - OLS: $COD = \mathbf{19.57\%}$ (Excede el límite máximo de uniformidad de la IAAO) [10].
  - **Random Forest:** $COD = \mathbf{5.48\%}$ (Garantiza una valoración altamente uniforme y equitativa) [8] [10].
- **Estudio de Liubliana (Eslovenia):**
  - OLS: $COD = \mathbf{17.12\%}$ (Supera el umbral permitido) [9] [11].
  - **Random Forest:** $COD = \mathbf{7.28\%}$ (Cumple estrictamente los estándares internacionales) [9] [11].

Esta diferencia se debe a que *Random Forest* captura de forma no lineal los micromercados y evita el sesgo de regresión hacia la media, logrando que el ratio de ventas de las viviendas caras y baratas se mantenga estrechamente agrupado alrededor de 1,0.

Tarjeta 28

En el anverso pone: "¿Cuál es la fórmula del Error Porcentual Absoluto Medio (MAPE) para *n* propiedades?" La respuesta del anverso es:

$$\mathrm{MAPE} = \frac{100}{n} \sum_{i=1}^{n} \left| \frac{p_i - \hat{p}_i}{p_i} \right|$$

Donde p_i es el precio real y $\hat{p}_i$ es el precio predicho."

¿Podrías explicarme este tema más detalladamente?

El Error Porcentual Absoluto Medio (conocido por sus siglas en inglés como MAPE — *Mean Absolute Percentage Error*) es una de las métricas estadísticas más utilizadas en la industria inmobiliaria y la ciencia de datos para medir la precisión global de un Modelo de Valuación Automatizada (AVM). Desglose y Explicación Término a Término de la Fórmula

La fórmula matemática para *n* propiedades en el conjunto de validación o prueba es:

$$\text{MAPE} = \frac{100}{n} \sum_{i-1}^{n} \left| \frac{p_i - \hat{p}_i}{p_i} \right|$$

- p_i **(Precio Real / Observado):** Es el precio real de transacción o cierre en el mercado para la vivienda i [3].
- $\hat{p}_i$ **(Precio Predicho):** Es el valor estimado o calculado por el modelo (ya sea Regresión Lineal OLS, Random Forest o Gradient Boosting) para la vivienda i [3].
- $(p_i - \hat{p}_i)$ **(Residuo o Error Monetario):** Es la diferencia directa entre el valor real y la predicción en unidades monetarias (euros, dólares, wones) [3] [4].
- $\frac{p_i - \hat{p}_i}{p_i}$ **(Error Porcentual):** Divide el error monetario entre el precio real de la propiedad para convertir la desviación en una **proporción relativa** a la escala de valor de cada inmueble [3] [4].
- $|\ldots|$ **(Valor Absoluto):** Elimina el signo del error [4]. Esto garantiza que los errores de sobreestimación ($\hat{p}_i > p_i$) y los de subestimación ($\hat{p}_i < p_i$) no se cancelen entre sí al promediar, midiendo únicamente la **magnitud bruta de la desviación** [4].
- $\sum_{i-1}^{n} \ldots$ **(Sumatorio):** Suma los errores porcentuales absolutos de todas las n propiedades evaluadas [3].

- $\frac{100}{n}$ **(Escalamiento a Porcentaje Promedio):** Promedia las desviaciones individuales entre el número total de observaciones n y multiplica por 100 para expresar el resultado final directamente como un **porcentaje (%)** [3] [4].

2. ¿Por qué el MAPE es una de las métricas favoritas en la Valuación Inmobiliaria?

1. Independencia de la Escala y Comparabilidad Directa: A diferencia del RMSE o del MAE (que miden los errores en montos de dinero y dependen de la moneda o del nivel de precios local), el MAPE produce un valor adimensional. Esto permite comparar de forma objetiva el rendimiento de un AVM entrenado en zonas de precios moderados con otro entrenado en distritos de lujo.

2. Interpretación Intuitiva para Reguladores y Tasadores: El MAPE expresa el resultado en un lenguaje directo y comprensible para auditores bancarios y sociedades de tasación. Un MAPE} = 5,5 % significa de manera transparente que, en promedio, las estimaciones del modelo se desvían un 5,5 % del valor real pactado en las compraventas.

3. Evidencia Empírica de las Fuentes: OLS vs. Random Forest

Los estudios empíricos recopilados demuestran cómo la transición desde la regresión lineal hedónica (OLS) hacia *Random Forest* logra reducciones drásticas en el MAPE:

- **Distrito de Gangnam (Seúl, Corea del Sur):**
  - **Regresión Lineal (OLS):** $\mathrm{MAPE} = \mathbf{19.60\%}$ [6].
  - **Random Forest:** $\mathrm{MAPE} = \mathbf{5.48\%}$ (reduciendo el error porcentual a más de la tercera parte) [6].
- **Ciudad de Liubliana (Eslovenia):**
  - **Regresión Lineal (OLS):** $\mathrm{MAPE} = \mathbf{17.48\%}$ [7].
  - **Random Forest:** $\mathrm{MAPE} = \mathbf{7.27\%}$ [7].
- **Ciudad de Sevilla (España):**
  - **Regresión Lineal (MCO):** $\mathrm{MAPE} = \mathbf{27.80\%}$ [8].
  - **Random Forest:** $\mathrm{MAPE} = \mathbf{19.60\%}$ [8].
- **Ames, Iowa (Estados Unidos):**
  - **Random Forest:** $\mathrm{MAPE} = \mathbf{10.43\%}$ [9].
- **Ciudad de Madrid (España):**
  - Los modelos de ensamble avanzados (como Gradient Boosting o Random Forest) alcanzaron MAPEs del **12.17% al 12.70%** [10].

4. Limitación del MAPE

A pesar de su popularidad, el MAPE presenta una debilidad en datos inmobiliarios: sensibilidad ante valores reales p_i extremadamente bajos. Si una base de datos contiene propiedades atípicas de valor muy reducido, la división entre un denominador p_i muy pequeño puede inflar artificialmente el porcentaje de error de ese registro individual. Por esta razón, en la auditoría profesional de modelos AVM, el MAPE siempre se evalúa en conjunto con el *COD* (Coeficiente de Dispersión), el *MAE* (Error Absoluto Medio) y el R^2.

Tarjeta 29

En el anverso pone: "¿Cuál fue el coeficiente de determinación R^2 de *Random Forest* vs OLS en el estudio de departamentos en *Gangnam*?" La respuesta del anverso es: "*Random Forest* alcanzó un R^2 de 0,976 (explicando más del 97% de la varianza), mientras que OLS obtuvo solo 0,726."

¿Podrías explicarme este tema más detalladamente?

El dato expuesto en esta tarjeta didáctica procede del influyente estudio empírico realizado por *Hong, Choi y Kim* (2020) sobre la valuación masiva de apartamentos en el distrito de *Gangnam* (Seúl, Corea del Sur.

A continuación, se detalla el significado de estos valores de R^2 y las razones técnicas por las que *Random Forest* (RF) superó de forma tan contundente a la regresión lineal tradicional por Mínimos Cuadrados Ordinarios (OLS / MCO).

1. Significado del Coeficiente de Determinación (R^2)

El coeficiente (R^2) cuantifica la proporción de la variabilidad o varianza total de los precios reales del mercado que es explicada por el modelo:

- OLS (R^2 = 0,726): El modelo hedónico lineal logró explicar el 72,6 % de la variación de los precios. Esto significa que más del 27 % de la variabilidad del mercado quedó sin explicar, absorbida por el término de error debido a la rigidez del plano de regresión.
- Random Forest (R^2 = 0,976): El algoritmo de aprendizaje automático logró explicar el 97,6 % de la varianza del precio, dejando solo un 2,4 % no explicado. Esto refleja una capacidad casi perfecta para replicar la estructura real de precios de transacción en el conjunto de prueba.

2. Contexto de la Muestra en Gangnam

El estudio analizó un conjunto masivo de 16.601 transacciones reales de compraventa de apartamentos registradas entre 2006 y 2017.

- Densidad geográfica: Todos los datos se concentraron en una superficie urbana altamente densa de 39,55 km² en *Gangnam* (una de las zonas residenciales y comerciales de mayor valor de Corea del Sur).
- Igualdad de condiciones: Ambos modelos (OLS y RF) fueron evaluados utilizando exactamente las mismas 16 variables explicativas (físicas, de la urbanización, locacionales y macroeconómicas). La enorme diferencia en el R^2 no se debió a disponer de más datos,

sino a la forma matemática y algorítmica de procesarlos.

3. ¿Por qué *Random Forest* alcanzó un R^2 tan elevado frente a OLS?

A. Modelización de No Linealidades e Interacciones Complejas

La econometría hedónica OLS asume implícitamente que cada atributo influye en el precio mediante un coeficiente estático β (separabilidad y constancia). En la realidad inmobiliaria, el efecto de un metro cuadrado adicional o de una planta más alta no es constante, sino que depende jerárquicamente del barrio, la marca del edificio o el año de construcción. *Random Forest* explora estas estructuras jerárquicas y relaciones no lineales de forma automática mediante árboles de decisión.

B. Inmunidad a la Multicolinealidad

En el mercado residencial de *Gangnam*, variables como la superficie, el número de edificios del complejo, la tasa de ocupación del suelo (BCR) y el coeficiente de edificabilidad (FAR) presentan una altísima correlación entre sí. En OLS, la multicolinealidad desestabiliza los coeficientes globales y degrada el ajuste. *Random Forest* supera este problema evaluando subespacios aleatorios de variables (*Random Subspaces*) en cada nodo, distribuyendo la información redundante sin perder estabilidad.

C. Captura de Micromercados Homogéneos

Al dividir el espacio de características mediante particiones recursivas binarias, los árboles de *Random Forest* aislaron subgrupos de viviendas altamente homogéneas dentro de *Gangnam*, reduciendo drásticamente la Suma de Cuadrados de los Residuos (RSS) en las hojas finales.

4. Impacto Conjunto en el Resto de Las Métricas de Precisión

El salto en el R^2 del (0,726\) al (0,976) se tradujo directamente en una mejora radical de todas las demás métricas de validación del modelo:

Métrica de Evaluación	Regresión Lineal (OLS)	Random Forest (RF)	Significado e Impacto Práctico
Coeficiente R^2	0.726	0.976	RF explica un 25% más de la varianza del mercado.
Error Porcentual (MAPE)	19.61 %	5,48 %	RF reduce la desviación promedio a menos de la tercera parte.

Métrica de Evaluación	Regresión Lineal (OLS)	Random Forest (RF)	Significado e Impacto Práctico
Uniformidad (COD)	19,57 %	5,48 %	OLS supera el límite de la IAAO (15 %), mientras RF garantiza alta equidad.
Tasa de Acierto (error ≤ 5%)	17,4 %	72,0 %	Con RF, 7 de cada 10 avalúos tienen un error inferior al 5%.
Frecuencia de Errores Graves (>50 %)	3,82 %	0,52 %	RF reduce los valores atípicos extremados a una fracción mínima.

Tarjeta 30

En el anverso pone: "¿Qué variable resultó ser la más determinante para predecir el precio inmobiliario en el modelo *Random Forest* del estudio de *Gangnam*?"

La respuesta del anverso es: "El área (superficie del departamento en m²), seguida por el número de edificios en el complejo residencial."

¿Podrías explicarme este tema más detalladamente?

En el estudio de *Hong, Choi y Kim* (2020) sobre la valuación masiva de apartamentos en el distrito de *Gangnam* (Seúl), se analizaron inicialmente 26 características (estructurales, del complejo residencial, locacionales y macroeconómicas) sobre una muestra de 16.601 transacciones reales.

Para determinar qué variables tenían mayor peso predictivo, el algoritmo *Random Forest* calculó la Reducción Media de Impureza (medida a través del decremento en el Error Cuadrático Medio — MSE) promediada en todos los árboles del bosque.

Los resultados revelaron una jerarquía muy clara sobre los determinantes del valor inmobiliario:

1. El Área (área en m²): El factor dominante del mercado

La superficie útil del departamento se posicionó como el indicador más relevante con gran diferencia sobre todos los demás atributos, aportando más del 55 % a 60 % de la reducción total de la impureza en el modelo.

- Por qué ocurre: En un distrito urbano de extrema densidad y alto valor económico como *Gangnam* (donde el precio medio ronda los 10.000 USD/m²), el tamaño de la vivienda es el principal determinante del precio final de cierre.

- Absorción de información redundante: Los autores descubrieron que variables como el número de plazas de aparcamiento (*parking_lot*), aunque están fuertemente correlacionadas con el precio en análisis individuales, mostraron una baja importancia directa en el árbol. Esto se debe a que la variable área contiene implícitamente esa información: los apartamentos más grandes en *Gangnam* pertenecen casi siempre a unidades con mayores cuotas de estacionamiento asignadas.

2. Número de Edificios en el Complejo (*number of buildings in the complex*): El efecto escala

Sorprendentemente para la econometría lineal tradicional, la segunda variable más determinante fue el número de bloques o edificios que componen la urbanización residencial.

- El fenómeno de los *Macro-Complexes* en Seúl: En el mercado inmobiliario surcoreano, los grandes conjuntos residenciales de alta densidad (*apartment complexes*) ofrecen economías de escala: disponen de mejores zonas verdes, mayor equipamiento comunitario, seguridad privada, administración profesional y mayor liquidez de mercado.
- Diferenciación de valor: Un apartamento de (80 m²) ubicado en un complejo masivo de 30 o 40 edificios alcanza una prima de precio sustancialmente mayor que un apartamento idéntico en superficie situado en un edificio aislado.

3. Factores temporales y el proceso de selección de 16 variables

Siguiendo a las dos variables principales, los siguientes factores con mayor peso predictivo fueron la fecha de transacción (*trans_date*) (para capturar la evolución de los ciclos económicos e inflación entre 2006 y 2017) y la antigüedad de la propiedad (*elapsed_year*).

Por el contrario, las variables de distancia física a equipamientos (como la distancia a estaciones de metro o escuelas) mostraron una importancia directa casi nula dentro de *Random Forest*. Esto se explica porque, al ser *Gangnam* un distrito de tamaño reducido (39,55 km²) con una infraestructura homogénea y altamente conectada, las variaciones de accesibilidad interna no generan grandes diferencias de valor comparadas con la escala del complejo y la superficie.

Para optimizar el modelo y evitar el sobreajuste (*overfitting*), los investigadores eliminaron paulatinamente las variables menos relevantes hasta encontrar el punto que minimizaba el Error Porcentual Absoluto Medio (MAPE), seleccionando un subconjunto óptimo de 16 variables con el que alcanzaron un MAPE récord del 5,48%.

Tarjeta 31

En el anverso pone: "¿Qué es *Random Forest* (Bosque Aleatorio) en el contexto del aprendizaje automático?" La respuesta del anverso es: "Es un algoritmo de ensamble formado por múltiples árboles de decisión independientes cuyas predicciones individuales se promedian (en regresión) para emitir el resultado final."

¿Podrías explicarme este tema más detalladamente?

Random Forest (Bosque Aleatorio) es uno de los algoritmos de aprendizaje automático supervisado más sólidos y utilizados tanto en la ciencia de datos general como en la Valuación Masiva de Inmuebles (AVM). Su concepto central radica en el principio del aprendizaje por ensamble (*ensemble learning*): en lugar de confiar la predicción a un único modelo o árbol de decisión, el algoritmo construye una "multitud" de cientos de árboles de decisión independientes y combina sus resultados para tomar la decisión final.

1. La Filosofía del Ensamble y el Aprendiz Débil

Un árbol de decisión individual es un modelo intuitivo, pero altamente inestable: pequeñas variaciones o ruido en los datos de entrenamiento pueden cambiar drásticamente su estructura y sus predicciones (presenta alta varianza y tendencia al sobreajuste).

Para resolver esta vulnerabilidad, *Leo Breiman* (2001) ideó *Random Forest* combinando la predicción de múltiples árboles individuales (llamados "aprendices débiles"):

- En clasificación: El bosque asigna la categoría final mediante un voto de mayoría.
- En regresión / valuación de inmuebles: El modelo asigna como estimación del precio de una vivienda el promedio aritmético de los precios calculados de forma independiente por cada uno de los *B* árboles del bosque:

$$f_{\mathrm{RF}}(x) = \frac{1}{B}\sum_{b-1}^{B} T_b(x, \Theta_b)$$

Donde T_b representa la predicción del árbol b generado bajo un vector aleatorio de parámetros Θ_b para el inmueble de características x [9] [10].

2. Los Dos Pilares de la "Doble Aleatoriedad"

El verdadero avance de *Random Forest* no es solo construir muchos árboles, sino garantizar que los árboles sean lo más diversos e independientes posible entre sí. Para lograr esta diversidad, el

algoritmo inyecta dos capas independientes de aleatoriedad:

A. Muestreo *Bootstrap* con Reemplazo (*Bagging*)

Desarrollado originalmente por *Breiman* en 1996, el *Bagging* (*Bootstrap Aggregating*) implica que cada árbol del bosque no se entrena con toda la base de datos original, sino con una muestra *Bootstrap* de tamaño *N* extraída al azar con reemplazo.

- Esto causa que aproximadamente un tercio de las propiedades (36,8 %) quede fuera del entrenamiento de cada árbol en particular, formando las muestras *Out-Of-Bag* (OOB) empleadas para validación interna.

B. Selección Aleatoria de Variables (*Random Subspaces*)

Si solo se aplicara *Bagging*, los árboles seguirían siendo muy parecidos porque las variables más dominantes del mercado (como la superficie o la ubicación) serían elegidas siempre en el primer nodo de división de todos los árboles.

- Para romper esa dependencia, *Random Forest* restringe intencionadamente el número de predictores en cada nodo: al evaluar una bifurcación, el algoritmo selecciona al azar únicamente un subconjunto reducido de variables *m* (típicamente $m = p/3$ en regresión) y busca la mejor división únicamente entre ellas.

3. ¿Por qué es Inmune al Sobreajuste (*Overfitting*)?

A diferencia de otros modelos complejos o de redes neuronales —donde agregar más capacidad puede llevar a que el modelo "memorice" el ruido de los datos—, *Breiman* demostró mediante la Ley Fuerte de los Grandes Números que conformes se añaden más árboles al bosque, el error de generalización no crece, sino que converge casi con certeza a un límite fijo constante.

Esta propiedad se debe a que la reducción de varianza lograda al promediar árboles descorrelacionados equilibra la precisión individual de cada árbol (su fuerza *s*) con el grado de independencia entre sus errores (correlación residual $\hat{\rho}$).

4. Ventajas Clave en la Valuación Inmobiliaria (AVM)

1. Captura de no linealidades e interacciones automáticas: El mercado de la vivienda presenta comportamientos jerárquicos y efectos umbral (por ejemplo, el valor de añadir metros cuadrados depende del barrio o del nivel socioeconómico). *Random Forest* aprende estas interacciones de forma adaptativa sin requerir que el valuador especifique términos matemáticos manuales.

2. Robustez ante la multicolinealidad y datos faltantes: Procesa simultáneamente atributos altamente correlacionados entre sí (superficie útil, estancias, número de baños, plazas de garaje) distribuyéndolos en los subespacios aleatorios, e incluso emite predicciones con las ramas disponibles si faltan ciertos datos en una propiedad.
3. Precisión empírica demostrada: En aplicaciones masivas reales (como en el distrito de *Gangnam* en Seúl, o en las ciudades de Sevilla y *Liubliana*), *Random Forest* logra reducir los errores porcentuales promedio (MAPE) de niveles del ~20 % observados en la regresión lineal tradicional (MCO/OLS) a rangos del 5,5 % al 7,2 %, garantizando valoraciones significativamente más precisas y equitativas.

Tarjeta 32

En el anverso pone: "¿Cuál es la principal ventaja de utilizar un modelo híbrido que integra *Random Forest* con *XGBoost* según *Zhao*?" La respuesta del anverso es: "Logra una precisión de predicción de precios inmobiliarios significativamente mayor que la obtenida por cualquiera de los dos modelos de forma individual."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica aborda uno de los desarrollos más avanzados dentro del aprendizaje automático aplicado a la valuación inmobiliaria: el uso de modelos híbridos o ensambles combinados (*stacking* o fusión de modelos).

1. El hallazgo principal de *Zhao*

En las investigaciones sobre predicción del precio de viviendas de segunda mano, *Zhao* (2020) demostró que al integrar *Random Forest* (RF) con *XGBoost* (*Extreme Gradient Boosting*) en un modelo híbrido, la precisión predictiva resultante es significativamente mayor que la obtenida por cualquiera de los dos modelos de forma individual.

2. ¿Por qué funciona tan bien? La complementariedad de *Bagging* y *Boosting*

La razón técnica fundamental detrás de esta mejora radica en que *Random Forest* y *XGBoost* pertenecen a dos familias metodológicas con fortalezas matemáticas opuestas pero altamente complementarias:

Característica	Random Forest (*Bagging + Random Subspaces*)	XGBoost (*Gradient Boosting*)
Arquitectura de construcción	Paralela e independiente: Cada árbol de decisión se entrena de forma aislada a partir de muestras *Bootstrap*.	Secuencial: Cada nuevo árbol se construye específicamente para corregir los errores del árbol anterior.
Objetivo matemático principal	Reducción drástica de la varianza del ensamble.	Reducción drástica del sesgo (*bias*).
Punto fuerte en inmobiliaria	Alta resistencia al sobreajuste (*overfitting*) y excelente manejo de datos atípicos o categóricos.	Alta precisión para capturar relaciones no lineales complejas y efectos umbral muy sutiles.
Riesgo individual	Puede presentar cierta inercia en los extremos del mercado (picos de precios de lujo).	Puede sobreajustarse al ruido o a anomalías locales si no se regulan cuidadosamente los parámetros.

3. La sinergia del modelo híbrido

Al combinar ambos algoritmos (por ejemplo, promediando sus predicciones o utilizando un meta-modelo de regresión mediante *stacking*):

1. Equilibrio Óptimo Sesgo-Varianza: XGBoost aporta la capacidad de "afinar" la estimación capturando matices no lineales del mercado, mientras que *Random Forest* aporta estabilidad y suaviza la predicción global, reduciendo la varianza residual.
2. Mitigación de errores en casos atípicos: Si un algoritmo individual se desvía al evaluar una vivienda con características atípicas (por ejemplo, inmuebles muy caros o pequeños de alta calidad), la estructura del ensamble híbrido amortigua ese sesgo, reduciendo métricas clave de error como el MAPE (Error Porcentual Absoluto Medio) y el RMSE.

4. Relevancia en la Valuación Masiva (AVM)

En el desarrollo de Modelos de Valoración Automatizada, los enfoques híbridos representan el estándar de mayor precisión. Permiten construir sistemas AVM capaces de replicar la compleja

estructura espacial y física de los mercados urbanos, entregando avalúos masivos más consistentes y equitativos para el sector bancario, tributario y de tasaciones profesionales.

Tarjeta 33

En el anverso pone: "En cuanto a la generación de valores atípicos extremados (desviaciones >50%), ¿cómo se comparó Random Forest frente a OLS en Gangnam?" La respuesta del anverso es: "Random Forest generó solo un 0,52 % de predicciones atípicas, mientras que el modelo OLS generó un 3,82 %."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica proviene del estudio de valuación masiva de apartamentos en el distrito de *Gangnam* (Seúl) realizado por *Hong, Choi y Kim* (2020). El análisis de la frecuencia de valores atípicos extremados (outliers) representa uno de los hallazgos más relevantes para la gestión del riesgo financiero y la auditoría de Modelos de Valoración Automatizada (AVM).

1. ¿Cómo se definió un "Error Atípico Extremado"?

En el estudio, los autores definieron cuantitativamente como un error atípico o "catastrófico" a cualquier predicción cuyo error porcentual absoluto superara el 50 % del precio real de transacción registrado en el mercado:

$$\left|\frac{\hat{p}_i - p_i}{p_i}\right| > 0.50$$

2. Comparación cuantitativa directa

Sobre la muestra de prueba (*test set*) del mercado de Gangnam, las tasas de generación de errores extremos mostraron la siguiente distribución:

Criterio de Desviación respecto al Precio Real	Regresión Lineal (OLS)	Random Forest (RF)	Comparativa
Desviación > 50% (Errores Extremos)	3,82 %	0,52 %	OLS generó más de 7 veces más errores graves que RF.
Desviación > 100% (Error del doble o mitad)	0,39 %	0,26 %	RF mantiene menor frecuencia de distorsión severa.
Desviación > 200%	0,18 %	0,19 %	Frecuencia residual casi nula en ambos.

3. ¿Por qué el modelo OLS genera tantos errores graves?

1. Extrapolación y rigidez del plano de regresión: OLS proyecta el precio mediante una única ecuación lineal fija basada en coeficientes globales β. Cuando el modelo evalúa una propiedad con una combinación inusual de atributos (por ejemplo, un departamento extremadamente grande, pero en un edificio muy antiguo o con un sistema de calefacción atípico), la función lineal extrapola sin control, produciendo estimaciones irreales que se alejan drásticamente del valor real.
2. Sensibilidad a la multicolinealidad y apalancamiento: OLS minimiza la suma de residuos al cuadrado. Si ciertas características explicativas están correlacionadas, los coeficientes se desestabilizan y una ligera variación en los atributos de un inmueble atípico dispara la predicción de forma desproporcionada.

4. ¿Por qué Random Forest suprime los errores extremos?

1. Partición jerárquica acotada (*Data-driven*): Un árbol de decisión no extrapola ecuaciones al infinito; divide el espacio de datos en subregiones o "hojas" locales. La predicción asignada a una vivienda es siempre el promedio real de las transacciones históricas contenidas en esa hoja, lo que imposibilita matemáticamente que la estimación "explote" a cifras absurdas.
2. Promediado por Ensamble (*Bagging*): Incluso si un árbol individual realiza una división desafortunada ante un inmueble atípico, el promedio de los 50 o 500 árboles del bosque suaviza el error residual, amortiguando cualquier sesgo puntual.
3. Manejo adaptativo de combinaciones de variables: RF explora las interacciones contextuales sin forzar supuestos de linealidad. Si un atributo tiene un comportamiento distinto en el segmento de lujo que, en el segmento medio, la estructura jerárquica del bosque lo captura sin distorsionar las predicciones del resto del mercado.

5. Importancia práctica en el Marco Bancario y Financiero (Basilea II)

Bajo las normativas bancarias internacionales como Basilea II, las entidades financieras deben monitorear frecuentemente el valor de las garantías hipotecarias mediante métodos estadísticos AVM.

- Que un modelo OLS genere casi un 4 % de avalúos con errores superiores al 50 % implica un riesgo financiero inaceptable: significaría que en 4 de cada 100 créditos hipotecarios la garantía estaría gravemente sobrevalorada o infravalorada.

- Al reducir la tasa de errores extremos a solo 0,52 %, *Random Forest* entrega el margen de seguridad técnica necesario para automatizar la gestión de colaterales y la valuación catastral masiva sin exponer a las instituciones a pérdidas por mala estimación.

Tarjeta 34

En el anverso pone: "Por defecto, para problemas de regresión con *n* variables de entrada, ¿cuántas variables elegibles (*m*) evalúa *Random Forest* en cada nodo según la librería de R?" La respuesta del anverso es: "*m* = *n* / 3(un tercio del total de variables explicativas)."

¿Podrías explicarme este tema más detalladamente?

Esta regla para la selección del hiperparámetro (*m*) (conocido como mtry en la biblioteca *randomforest* de *R*) constituye uno de los pilares prácticos más importantes en la construcción de modelos de regresión con *Random Forest*.

1. La Regla por Defecto: $\lfloor m = n/3 \rfloor$

Cuando se entrena un bosque aleatorio para predecir una variable continua (como el precio de transacción de una vivienda en un modelo de valuación masiva), la librería de R *randomForest* fija por defecto el número de variables candidatas evaluadas en cada nodo como un tercio del total de predictores disponibles ($m = \frac{n}{3}$ *o* $m = \frac{p}{3}$).

- Ejemplo práctico: Si un modelo AVM utiliza 30 variables explicativas (superficie, planta, antigüedad, distancia al metro, renta del barrio, número de baños, etc.), en cada nodo individual de cada árbol el algoritmo evaluará únicamente 10 variables elegidas al azar para buscar el mejor corte binario.

2. ¿Por qué no evaluar todas las variables en cada nodo?

Si en cada bifurcación del árbol se evaluaran las (*n*) variables completas (lo que equivaldría a aplicar simplemente *Bagging* tradicional):

1. Dominancia de atributos principales: En el mercado inmobiliario existen variables enormemente dominantes (como la superficie construida o la localización). Si estuvieran disponibles en todas las divisiones, prácticamente todos los árboles del bosque elegirían la misma variable en el nodo raíz y en las primeras ramas.
2. Alta correlación entre árboles: Esto provocaría que los cientos de árboles generados fueran muy similares entre sí, con errores fuertemente correlacionados, anulando el beneficio de promediar sus estimaciones.

Al restringir la búsqueda a un subespacio aleatorio de (m) variables en cada nodo, se obliga a diferentes árboles a explorar la capacidad predictiva de atributos secundarios e interacciones contextuales no lineales (como el año de reforma de instalaciones o la presencia de ascensor).

3. El Equilibrio Teórico entre Fuerza y Correlación

Según la formulación matemática de *Leo Breiman* (2001), la precisión de un *Random Forest* depende de equilibrar dos factores clave:

- La Fuerza (s): La capacidad de predicción individual de cada árbol por separado.
- La Correlación $\bar{\rho}$: El grado de similitud entre los errores de los árboles del bosque.

El tamaño de (m) gobierna directamente este compromiso (*trade-off*):

- Si (m) es muy pequeño (ej. (m = 1)): Los árboles serán extremadamente diferentes entre sí (baja correlación $\bar{\rho}$ ↓), pero cada árbol individual será relativamente débil (fuerza s ↓).
- Si (m) es muy grande (ej. (m = n)): Cada árbol será más preciso individualmente (fuerza s ↑), pero la correlación entre ellos aumentará ($\bar{\rho}$ ↑)

Las pruebas empíricas de *Breiman* demostraron que fijar $m = \lfloor n/3 \rfloor$ en regresión ofrece un punto dulce (*sweet spot*) idóneo donde se maximiza la descorrelación de los árboles manteniendo una fuerza predictiva suficiente en el ensamble.

4. Regresión vs. Clasificación

Es importante distinguir el valor por defecto según el tipo de problema supervisado:

Tipo de Problema	Valor por defecto habitual de (m) (mtry)	Objetivo
Regresión (ej. Predecir precio del Inmueble)	$m = \lfloor n/3 \rfloor$ (un tercio del total)	Promediar variaciones continuas y suavizar residuos.
Clasificación (ej. Predecir categoría de conservación)	$m = \lfloor \sqrt{n} \rfloor$ (Raíz cuadrada total)	Maximizar el voto por mayoría de clases disyuntivas.

5. Consideración entre Paquetes (R vs. Python)

- En R (*randomForest*): El parámetro se llama mtry y aplica directamente la regla $m = \lfloor n/3 \rfloor$ para regresión de forma nativa.

- En Python (scikit-learn): En la clase RandomForestRegressor, el hiperparámetro equivalente es max_features. Históricamente su valor por defecto era 1.0 (evaluar el 100% de características, es decir ($m = n$), pero se puede configurar explícitamente como max_features=1/3 o max_features='sqrt' para alinearlo con el estándar de R o de ajuste de cuadrícula (*Grid Search*).

Tarjeta 35

En el anverso pone: "¿Cuáles son los dos hiperparámetros principales que necesita configurar un valuador al entrenar un modelo Random Forest?" La respuesta del anverso es: "1. Número de árboles en el bosque (n_estimators). 2. Profundidad máxima de cada árbol (*max_depth*)."

¿Podrías explicarme este tema más detalladamente?

En la práctica de los Modelos de Valoración Automatizada (AVM) y la valuación masiva catastral, una de las mayores ventajas de *Random Forest* es que no requiere especificaciones complejas ni un afinamiento extenuante de parámetros. La literatura especializada destaca que el modelo se define fundamentalmente por dos hiperparámetros principales: el número de árboles y la profundidad de estos.

A continuación, se analiza detalladamente el papel, el impacto y el compromiso (*trade-off*) de cada uno de ellos en la predicción del precio de los inmuebles:

1. Número de Árboles en el Bosque (*n_estimators / ntree*)

- Qué representa: Es la cantidad total de árboles de decisión independientes (*decision trees*) que se van a construir y combinar para integrar el ensamble.
- Mecanismo en Valuación Inmobiliaria: Dado que la estimación del valor de una vivienda en un problema de regresión es el promedio aritmético de las predicciones emitidas por cada árbol individual, n_estimators define el tamaño del comité de evaluación.
- Comportamiento y Convergencia:
    - Según el Teorema de Convergencia de *Breiman* (2001), conforme el número de árboles tiende a infinito, el error de generalización del bosque no sobreajusta (*overfit*), sino que converge casi con certeza a un límite fijo.
    - Un número muy reducido de árboles (ej. < 20) genera estimaciones volátiles debido a la alta varianza intrínseca de los árboles individuales.

  - Al aumentar la cantidad de árboles (por ejemplo, entre 50 y 500 árboles, como los 50 árboles utilizados en el estudio de *Gangnam* o los 500 en Sevilla), el resultado computacional se vuelve altamente estable y consistente.

- Criterio de Ajuste: A diferencia de algoritmos secuenciales (como XGBoost o redes neuronales), en *Random Forest* no existe el riesgo de deteriorar el modelo por agregar "demasiados" árboles. El único límite práctico de incrementar *n_estimators* es el tiempo de cómputo y consumo de memoria.

2. Profundidad Máxima de cada Árbol (*max_depth*)

- Qué representa: Mide el número máximo de niveles de partición binaria ($x_i > t$) permitidos desde el nodo raíz inicial hasta las hojas terminales de cada árbol.
- Mecanismo en Valuación Inmobiliaria: Controla el nivel de subdivisión y granularidad espacial o física con el que el algoritmo segmenta el mercado inmobiliario.
- Impacto en el Modelo:
  - Profundidad reducida (*max_depth* bajo): Da lugar a árboles muy simples ("pocos cortes"). Esto puede provocar subajuste (*underfitting*), haciendo que el modelo sea incapaz de distinguir diferencias sutiles entre tipologías o submercados urbanos.
  - Profundidad elevada (*max_depth* alto): Permite dividir el espacio de atributos en regiones más pequeñas y específicas. Esto ayuda a capturar relaciones no lineales complejas e interacciones contextuales (por ejemplo, cómo el impacto de la planta o el ascensor varía radicalmente según la antigüedad del edificio y la renta de la zona).
- Criterio de Ajuste: Aunque el promediado del bosque amortigua el sobreajuste, limitar max_depth (o fijar los parámetros equivalentes de parada) evita que los árboles individuales memoricen el ruido atípico de transacciones puntuales. En aplicaciones reales de valuación masiva, configuraciones de profundidad intermedia/alta (como *max_depth* = 17 en *Gangnam*) han demostrado alcanzar ajustes óptimos de precisión.

Hiperparámetros Secundarios Complementarios

Aunque *n_estimators* y max_depth dominan la arquitectura del modelo, en librerías como scikit-learn (Python) o randomForest (R) los valuadores suelen ajustar dos hiperparámetros secundarios complementarios:

1. *max_features / mtry*: Cantidad de variables explicativas elegidas al azar para evaluar la mejor división en cada nodo. En regresión inmobiliaria, el estándar por defecto fijado en la literatura es de un tercio del total de predictores ($m = \lfloor n/3 \rfloor$), lo que garantiza descorrelacionar las ramas del bosque.
2. *min_samples_leaf / min_samples_split*: Número mínimo de inmuebles que deben quedar en un nodo o hoja para permitir una nueva ramificación, garantizando que cada valor promedio estimado se apoye en una muestra estadísticamente representativa.

Tarjeta 36

En el anverso pone: "¿Por qué variables como 'distancia a la estación de metro' mostraron baja importancia en *Random Forest* pero alta correlación individual con el precio?" La respuesta del anverso es: "Debido a la presencia de colinealidad con otras variables estructurales principales (como el área y la ubicación geográfica), las cuales absorben la capacidad explicativa en el árbol."

¿Podrías explicarme este tema más detalladamente?

Esta tarjeta didáctica ilustra una de las paradojas más comunes e interesantes al analizar la importancia de variables en modelos de aprendizaje automático basados en árboles, como *Random Forest* [*Hong et al*., 2020; *Breiman*, 2001].

A diferencia de la correlación bivariada (que mide la relación lineal simple e individual entre un predictor y el precio) [*Hong et al*., 2020], la importancia de variables en *Random Forest* mide la contribución marginal o condicional que aporta un atributo para reducir el error de predicción dentro de la estructura multivariante del bosque [Breiman, 2001; Hong et al., 2020].

A continuación, se detalla el mecanismo matemático y práctico que explica por qué ocurre este fenómeno:

1. ¿Cómo calcula *Random Forest* la Importancia de una Variable?

Durante el entrenamiento, *Random Forest* evalúa en cada nodo la reducción de la impureza (medida como la disminución del Error Cuadrático Medio — MSE en problemas de regresión) que produce dividir los datos usando una determinada variable [*Hong et al*., 2020].

- La importancia global de un atributo es el promedio de la reducción de varianza/MSE que logra a lo largo de todos los nodos y árboles donde fue seleccionado para realizar un corte [*Hong et al*., 2020].

- Alternativamente, mediante la permutación de las muestras *Out-Of-Bag* (OOB), el algoritmo mide cuánto aumenta el error del modelo si se "destruye" o altera aleatoriamente la información de esa variable específica [*Breiman*, 2001; *Čeh et al*., 2018].

2. El Mecanismo de Absorción de Varianza por Colinealidad

En el marco teórico fundacional del algoritmo, *Leo Breiman* (2001) explicó formalmente cómo reacciona *Random Forest* ante predictores altamente correlacionados entre sí [*Breiman*, 2001]:

1. Redundancia Informativa: Si dos variables x_1 y x_2 contienen información fuertemente solapada sobre el precio de la vivienda (por ejemplo, la superficie en m² y el número de plazas de aparcamiento, o la ubicación geográfica general y la distancia a un hito urbano), ambas tendrán de forma individual una alta correlación con el valor del inmueble [*Hong et al*., 2020].
2. Prioridad en el Corte: Cuando la variable principal (x_1, como el área o la ubicación) es elegida en los nodos superiores del árbol, realiza la primera partición masiva y absorbe la mayor parte de la reducción del MSE [*Hong et al*., 2020].
3. Pérdida de Ganancia Marginal: Una vez que el árbol ya ha dividido las observaciones basándose en esa variable dominante, introducir la variable secundaria correlacionada (x_2, como la distancia a la estación de metro o las plazas de parking) en nodos subsecuentes ya no genera una reducción adicional significativa en el error residual [*Breiman*, 2001].
4. Resultado en el Indicador: Al no aportar ganancia de información adicional tras haber usado la variable dominante, el valor acumulado de importancia para x_2 cae bruscamente [*Breiman*, 2001; *Hong et al*., 2020].

3. Evidencia Empírica en Investigaciones Reales de AVM

Este comportamiento está ampliamente documentado en los estudios de valuación masiva inmobiliaria incluidos en tus fuentes:

- Estudio del Distrito de *Gangnam* (Seúl):
    - Los autores analizaron la distancia a infraestructuras como estaciones de metro (*distance to subway station*) y el número de plazas de aparcamiento por vivienda (*parking_lot*) [*Hong et al*., 2020].
    - Al evaluar la correlación bivariada directa, *parking_lot* mostraba un coeficiente muy alto con el precio de los departamentos [*Hong et al*., 2020].

- Sin embargo, en el gráfico de importancia del *Random Forest* entrenado, *parking_lot* y la distancia al metro mostraron valores casi nulos o fueron descartados en la selección final de 16 variables [Hong et al., 2020]. La razón analítica fue que la superficie (*area*) y la ubicación geográfica densa de *Gangnam* contenían implícitamente toda la capacidad explicativa del nivel de aparcamiento y de la accesibilidad urbana, dejando a las variables específicas sin ganancia marginal de error [*Hong et al*., 2020].

- Estudio de Sevilla:
  - La correlación lineal tradicional (MCO) mostraba altos Índices de Inflación de la Varianza (VIF) en atributos de accesibilidad y socioeconómicos [*Gutiérrez et al*., 2026].
  - Al aplicar *Random Forest* junto con SHAP, se observó que la renta media del área (renta) y la superficie de la vivienda (superficie) capturan los ejes principales de valor [*Gutiérrez et al*., 2026]. La proximidad a paradas de transporte público o colegios, aunque relevante de forma aislada, pasa a un segundo plano funcional dentro del ensamble debido a la estructura espacial interconectada de la ciudad [*Gutiérrez et al*., 2026].

4. Resumen Comparativo: Correlación vs. Importancia en *Random Forest*

Métrica	Ámbito de Evaluación	Comportamiento ante Colinealidad
Correlación Bivariada (Pearson / Spearman)	Evalúa cada variable por separado respecto al precio (relación 1 a 1) [*Hong et al*., 2020].	No le afecta la redundancia: Si dos variables están correlacionadas con el precio, ambas mostrarán coeficientes altos por igual [Hong et al., 2020].
Importancia en *Random Forest* (Gini / MSE Decrease)	Evalúa la ganancia marginal del predictor dentro de un árbol multivariante e interactivo [*Breiman*, 2001; *Hong et al*., 2020].	Sufre dilución/absorción: La variable dominante "roba" la capacidad explicativa de sus variables colineales, haciendo que estas últimas parezcan irrelevantes [*Breiman*, 2001; *Hong et al*., 2020].

Tarjeta 37

En el anverso pone: "A pesar de la alta precisión de *Random Forest*, ¿cuál es su principal desventaja práctica comparada con un modelo hedónico OLS?" La respuesta del anverso es: "Su menor interpretabilidad directa (modelo tipo 'caja negra'), ya que no genera un coeficiente o valor implícito marginal de precio directo y sencillo para cada atributo."

¿Podrías explicarme este tema más detalladamente?

La desventaja principal de *Random Forest* frente a la regresión lineal hedónica OLS (MCO) radica en el dilema entre precisión predictiva e interpretabilidad directa, conocido como el problema de la "caja negra" (*black box*).

A continuación, se detalla por qué ocurre esta limitación y cómo impacta en la práctica profesional de la valuación inmobiliaria:

1. La Ventaja Interpretativa de OLS: El Coeficiente Marginal Directo

En la econometría hedónica tradicional mediante Mínimos Cuadrados Ordinarios, el modelo formula una relación funcional lineal explícita:

$$p = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

- Interpretación directa y transparente: Cada parámetro estimado $\hat{\beta}_k$representa el precio implícito marginal (o la disposición a pagar marginal del mercado) por una unidad adicional del atributo X_j, manteniendo todo lo demás constante (*ceteris paribus*).
- Ejemplo en euros: Un tasador, auditor o juez puede observar la ecuación de MCO y leer directamente que cada metro cuadrado adicional añade +1.200 €, cada baño adicional aporta $+18.000 € o la presencia de ascensor incrementa el valor en $+25.000 €.

2. Por qué *Random Forest* es una "Caja Negra"

Random Forest no es una ecuación algebraica única, sino un ensamble no paramétrico compuesto por cientos de árboles de decisión independientes que dividen recursivamente el espacio de datos.

1. Inexistencia de un único coeficiente *β*: El modelo no calcula un valor monetario fijo por unidad de atributo. La predicción final para una vivienda es el promedio de los valores asignados en las hojas terminales de los cientos de árboles que componen el bosque.
2. Efectos contextuales y no constantes: En el mercado real, la aportación marginal de un atributo no es constante. El valor de añadir 20 m² o instalar ascensor varía según la antigüedad del edificio, el número de planta y el nivel socioeconómico del barrio. *Random*

Forest capta estas interacciones de forma adaptativa, pero esto significa que no existe una "tasa o tarifa fija" universal para ninguna variable.

3. Imposibilidad de inspección manual: Un ser humano puede leer una ecuación lineal de 10 términos, pero no puede seguir conceptualmente el recorrido simultáneo de una propiedad a través de 500 árboles de decisión profundos con miles de reglas condicionadas.

3. Desafíos Prácticos en el Ámbito Tributario y Financiero

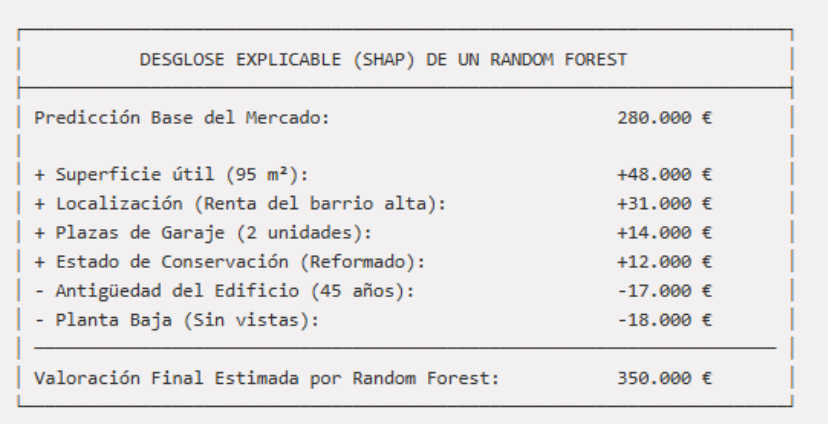
Esta menor interpretabilidad directa plantea retos significativos en el entorno profesional:

- Auditoría y Defensa de Tasaciones: Ante reclamaciones de impuestos catastrales, litigios judiciales o revisiones de garantías hipotecarias bajo el marco de Basilea II, las entidades financieras y administraciones exigen justificar por qué un inmueble ha sido valuado en una cifra específica.
- Aceptación Regulatoria: Entregar únicamente una cifra estimada por un algoritmo complejo ("el modelo predijo 350.000 €") sin un desglose explicativo genera reticencia entre reguladores y sociedades de tasación.

4. La Solución Contemporánea: De la Caja Negra a la Valuación Explicable (XAI)

Para superar esta desventaja sin sacrificar la alta precisión de *Random Forest* (que logra reducir los errores porcentuales del ~20 % en MCO al ~5,5 % en RF), la investigación reciente en AVM integra técnicas de Inteligencia Artificial Explicable (XAI):

- Valores SHAP (TreeSHAP): Descomponen la predicción puntual de un inmueble en sumas de contribuciones monetarias específicas en euros para cada variable, recuperando la capacidad de entregar un informe auditable.
- Gráficos PDP e ICE: Permiten visualizar y demostrar gráficamente cómo responde el precio predicho ante variaciones en la superficie, la planta o la renta de la zona.



DESGLOSE EXPLICABLE (SHAP) DE UN RANDOM FOREST	
Predicción Base del Mercado:	280.000 €
+ Superficie útil (95 m²):	+48.000 €
+ Localización (Renta del barrio alta):	+31.000 €
+ Plazas de Garaje (2 unidades):	+14.000 €
+ Estado de Conservación (Reformado):	+12.000 €
- Antigüedad del Edificio (45 años):	-17.000 €
- Planta Baja (Sin vistas):	-18.000 €
Valoración Final Estimada por Random Forest:	350.000 €

De esta forma, la combinación de *Random Forest + SHAP/PDP/ICE* permite transformar el modelo desde una "caja negra" inescrutable hacia un sistema de valuación masiva de alta precisión, transparente y completamente auditable.

Tarjeta 38

En el anverso pone: "¿Cómo se calcula la importancia de una variable mediante la *técnica Out-Of-Bag* (OOB) en *Random Forest*?" La respuesta del anverso es: "Permutando aleatoriamente los valores de dicha variable en los datos OOB y midiendo el incremento resultante en el error cuadrático medio (MSE) del modelo."

¿Podrías explicarme este tema más detalladamente?

La técnica de importancia por permutación Out-Of-Bag (OOB) —desarrollada originalmente por *Leo Breiman*— es uno de los métodos más sólidos e intuitivos para medir el peso predictivo real de cada característica dentro de un modelo *Random Forest.*

A diferencia de las métricas basadas en la reducción de impureza en los nodos (que se evalúan sobre los datos de entrenamiento), el método OOB evalúa la variable sobre datos no observados por los árboles individuales durante su construcción.

1. El punto de partida: ¿Qué son los datos Out-Of-Bag (OOB)?

Durante el entrenamiento de un *Random Forest*, cada árbol se construye a partir de una muestra de datos extraída mediante muestreo Bootstrap con reemplazo.

Debido a la naturaleza del muestreo con reemplazamiento, aproximadamente un tercio de las observaciones (36,8 %) queda fuera de la muestra de entrenamiento de cada árbol en particular. Estas observaciones no utilizadas constituyen el conjunto *Out-Of-Bag* (OOB) de ese árbol específico y funcionan como un conjunto de validación independiente "gratuito" e insesgado.

2. Algoritmo de cálculo paso a paso

Para medir la importancia de una variable específica X_j (por ejemplo, la superficie en m² o la antigüedad del inmueble), el algoritmo ejecuta los siguientes pasos:

1. Paso 1: Cálculo del Error Base OOB para un árbol determinado del bosque, se evalúan sus predicciones sobre su muestra OOB intacta y se registra el Error Cuadrático Medio de partida MSE.
2. Paso 2: Permutación Aleatoria del Predictor (Ruptura de Información) Se toman únicamente las observaciones OOB de ese árbol y se mezclan o desordenan aleatoriamente

(*shuffling/permutation*) los valores de la variable X_j.

- Propósito: Esta permutación rompe deliberadamente la relación entre la variable X_j y el valor real del inmueble Y (así como sus interacciones con otros atributos), conservando intactas la media y la varianza marginal del atributo.

3. Paso 3: Reevaluación del Error sobre los Datos Permutados Se pasan los datos OOB alterados a través del mismo árbol de decisión y se calcula el nuevo error cuadrático medio con la variable "ruidosa" ($MSE_{permutado}$).
4. Paso 4: Medición del Incremento del Error (ΔMSE) Se resta el error original del error permutado:

$$\Delta \text{MSE}_j = \text{MSE}_{\text{permutado}} - \text{MSE}_{\text{original}}$$

5. Paso 5: Promediado en todo el Bosque Este proceso se repite para cada árbol del bosque y se calcula el promedio del incremento en el MSE correspondiente a la variable X_j a lo largo de todos los estimadores.

3. Lógica e Intuición Estadística del Resultado

El fundamento de este experimento es la paradoja del "ruido inducido":

- Si la variable es DETERMINANTE (alta importancia): Al permutar o destruir su información, el modelo perderá su principal brújula predictiva y cometerá errores graves al estimar los precios de las viviendas OOB. Esto provocará un fuerte incremento en el MSE$(\Delta MSE \gg 0)$ confirmando que el atributo es crítico para la precisión del AVM.
- Si la variable es IRRELEVANTE o RUIDOSA (baja importancia): Como el modelo apenas utilizaba esa variable en las ramificaciones de los árboles, desordenar sus valores no afectará en absoluto la calidad de las predicciones. El MSE apenas cambiará $(\Delta MSE \approx 0)$, o incluso podría mostrar variaciones mínimas atribuibles al azar.

4. Ventajas clave de este enfoque en Valuación Masiva (AVM)

1. Evita el sesgo por sobreajuste (*overfitting*): A diferencia de las métricas tradicionales de ganancia en nodos (*Gini/MSE decrease* en datos de entrenamiento), la permutación OOB mide la pérdida de precisión en datos no vistos durante el entrenamiento, ofreciendo una estimación insesgada de la generalización del modelo.
2. Sin necesidad de reentrenar el modelo: La evaluación se realiza sobre los árboles ya ajustados, lo que optimiza drásticamente el tiempo de cómputo en comparación con la selección de características por eliminación hacia atrás.

3. Captura de interacciones complejas: Al desordenar los valores de X_j, no solo se destruye su efecto principal aislado, sino también todas las interacciones contextuales que dicha variable mantenía con otros atributos del inmueble (como la relación conjunta entre ascensor, planta y antigüedad).

Tarjeta 39

En el anverso pone: "Según el Acuerdo de Basilea II, ¿con qué frecuencia mínima deben las instituciones bancarias monitorear el valor de las colaterales hipotecarias?" La respuesta del anverso es: "Frecuentemente y como mínimo una vez al año."

¿Podrías explicarme este tema más detalladamente?

El Acuerdo de Basilea II (emitido por el Comité de Basilea de Supervisión Bancaria) establece un marco normativo riguroso para la gestión del riesgo de crédito en las entidades financieras, prestando especial atención al seguimiento continuo de las garantías inmobiliarias (*colaterales*) que respaldan los préstamos hipotecarios.

1. El Mandato Regulatorio y sus Excepciones de Frecuencia

- Frecuencia Mínima Anual: El acuerdo exige explícitamente que las instituciones bancarias monitoreen el valor de los bienes inmuebles en garantía de forma frecuente y, como mínimo, una vez al año.
- Entornos de Alta Volatilidad: En mercados inmobiliarios expuestos a fluctuaciones marcadas de precios o cambios significativos en las condiciones macroeconómicas, la normativa recomienda intensificar el seguimiento con una frecuencia aún mayor (por ejemplo, semestral o trimestral).
- Exigencia de Tasación Profesional Individual: Si los indicadores del mercado sugieren que el valor del inmueble ha sufrido un deterioro material relativo o si ocurre un evento de crédito (como el impago o *default* del deudor), se exige que un tasador profesional cualificado realice una revaluación física e individualizada de la propiedad.

2. ¿Por qué exige Basilea II este Monitoreo Continuo?

1. Control del Ratio *Loan-to-Value* (LTV): La relación entre el saldo pendiente del crédito y el valor actualizado de la garantía (LTV) determina el nivel de riesgo de la cartera. Si el mercado sufre una caída de precios y el banco no actualiza el valor del colateral, la entidad estará subestimando el riesgo real de pérdida en caso de ejecución hipotecaria.

2. Cálculo del Capital Regulatorio: Las normativas bancarias exigen que las entidades mantengan reservas de capital proporcionales al riesgo ponderado de sus activos. Disponer de colaterales sobrevalorados distorsiona las provisiones requeridas, comprometiendo la solvencia del sistema financiero.

3. El Desafío Operativo: De las Tasaciones Tradicionales a los Modelos AVM

Realizar inspecciones y tasaciones individuales presenciales para cada hipoteca de forma anual generaría un coste inasumible en tiempo y dinero para el sistema bancario. Para resolver este cuello de botella, el propio Acuerdo de Basilea II autoriza explícitamente el uso de métodos estadísticos de evaluación masiva (tales como índices de precios de vivienda o muestreos automatizados) para actualizar las estimaciones de valor de la cartera global.

En este contexto, los Modelos de Valoración Automatizada (AVM) basados en algoritmos de aprendizaje automático como *Random Forest* se han convertido en la herramienta idónea:

- Eficiencia en Masa: Permiten actualizar el valor de miles de colaterales de forma automatizada, rápida y a una fracción mínima del coste de las tasaciones humanas.
- Precisión y Reducción del Riesgo: Mientras que los índices lineales simples o la regresión hedónica tradicional (OLS) presentan errores del ~20 %, *Random Forest* logra reducir el Error Porcentual Absoluto Medio (MAPE a rangos del 5,5 %), proporcionando la estabilidad técnica necesaria para respaldar las auditorías regulatorias bancarias.

Tarjeta 40

En el anverso pone: "¿Qué métrica mide el porcentaje promedio de desviación entre el precio predicho y el precio de mercado real?" La respuesta del anverso es: "El Error Porcentual Absoluto Medio (MAPE)."

¿Podrías explicarme este tema más detalladamente?

El Error Porcentual Absoluto Medio (conocido globalmente por sus siglas en inglés MAPE — Mean Absolute Percentage Error) es una de las métricas estadísticas más utilizadas y preferidas por las sociedades de tasación y auditores financieros para evaluar la precisión de los Modelos de Valoración Automatizada (AVM)

1. Formulación matemática y concepto

La fórmula del MAPE para una muestra de n propiedades se define formalmente como [3] [4]:

$$\text{MAPE} = \frac{100}{n} \sum_{i-1}^{n} \left| \frac{p_i - \hat{p}_i}{p_i} \right|$$

Donde:

- p_i: Es el precio real observado de la transacción o contrato [3] [4].
- $\hat{p}_i$: Es el precio estimado o predicho por el modelo AVM [3] [4].
- $|p_i - \hat{p}_i|$: Representa el error absoluto en términos monetarios [1].
- $\left|\frac{p_i - \hat{p}_i}{p_i}\right|$: Convierte ese error monetario en una **desviación proporcional relativa** respecto al valor real de la vivienda [1].
- $\frac{100}{n}\sum \ldots$: Promedia todas las desviaciones porcentuales individuales y las multiplica por 100 para expresar el resultado como un porcentaje escalar $(0–100\%)$ [1].

Al tomar el **valor absoluto**, se evita que las sobreestimaciones $(\hat{p}_i > p_i)$ y las subestimaciones $(\hat{p}_i < p_i)$ se cancelen entre sí, midiendo la **magnitud real del margen de error** [1].

2. ¿Por qué es la métrica preferida en el sector inmobiliario?

1. Independencia de la escala: A diferencia del RMSE o del MAE (que miden los errores en unidades monetarias como euros, dólares o wones), el MAPE es adimensional. Esto permite comparar de forma objetiva la precisión de un modelo entrenado en barrios residenciales de valor medio con otro aplicado en zonas de lujo o en diferentes mercados internacionales1.
2. Interpretación intuitiva para clientes y reguladores: Un valor de MAPE = 5,5 % expresa de manera directa que las estimaciones del algoritmo se desvían, en promedio, un 5,5 % respecto al precio final de cierre negociado.
3. Estándar en sociedades de tasación: Es una de las métricas preferidas por la industria de la valoración inmobiliaria profesional para auditar el desempeño de los algoritmos supervisados.

3. Desempeño del MAPE en la literatura (OLS frente a Random Forest)

Los estudios empíricos incluidos en tus fuentes muestran cómo los algoritmos de ensamble como **Random Forest (RF)** reducen sustancialmente el MAPE en comparación con la regresión lineal hedónica tradicional (**OLS / MCO**):

- **Distrito de Gangnam (Seúl):**
  - **OLS:** $\mathrm{MAPE} \approx 19.61\%$ [7] [8].
  - **Random Forest:** $\mathrm{MAPE} \approx 5.48\%$ [8] [9] *(en comparación, se menciona que las tasaciones humanas tradicionales suelen presentar un MAPE de alrededor del* 12%*)* [10] [11].

- **Ciudad de Sevilla:**
  - **MCO:** $\mathrm{MAPE} = 27.8\%$ [12].
  - **Random Forest:** $\mathrm{MAPE} = 19.6\%$ [12].
- **Ciudad de Liubliana:**
  - **OLS:** $\mathrm{MAPE} = 17.48\%$ en datos de prueba [13].
  - **Random Forest:** $\mathrm{MAPE} = 7.27\%$ en datos de prueba [13].
- **Ciudad de Madrid:**
  - Los modelos de ensamble avanzados (como Gradient Boosting o Random Forest) alcanzaron MAPEs comprendidos entre el 12.17% y el 12.70% [14] [15].
- **Ames (Iowa):**
  - **Random Forest:** $\mathrm{MAPE} = 10.43\%$ [16].

4. Limitaciones y métricas complementarias

A pesar de su popularidad, el MAPE presenta la limitación de ser sensible a observaciones con precios reales p_i extremadamente bajos, donde una pequeña variación monetaria puede inflar el porcentaje. Por ello, en una auditoría AVM completa se evalúa junto a:

- COD (Coeficiente de Dispersión): Evalúa la uniformidad y equidad tributaria analizando la dispersión de los ratios de venta respecto a la mediana.
- MAE (Error Absoluto Medio): Mide la magnitud media del error directamente en moneda local (ej. euros o dólares).
- RMSE (Raíz del Error Cuadrático Medio): Penaliza con mayor gravedad las desviaciones o errores atípicos de gran magnitud.
- R^2 (Coeficiente de Determinación): Cuantifica la proporción de la varianza del mercado que logra explicar el modelo.

Tarjeta 41

En el anverso pone: "¿Qué representa la métrica *Hitting Rate* (Tasa de Acierto) en la evaluación de modelos AVM?" La respuesta del anverso es: "La proporción de predicciones cuyo precio estimado cae dentro de un porcentaje de tolerancia predefinido (ej. ≤ 5% o ≤10 %) respecto al precio de venta real."

¿Podrías explicarme este tema más detalladamente?

La Tasa de Acierto (*Hitting Rate*) es una métrica de validación práctica y probabilística fundamental para evaluar Modelos de Valoración Automatizada (AVM) y sistemas de tasación masiva inmobiliaria.

A diferencia de las métricas agregadas globales (como el MAPE o el RMSE) que promedian la magnitud de los errores en toda la muestra, la Tasa de Acierto mide la probabilidad de que una valoración individual caiga dentro de un margen comercial de tolerancia predefinido respecto al precio real de transacción.

1. Definición y formulación matemática

Para una muestra de *n* transacciones evaluadas en el conjunto de prueba, la Tasa de Acierto dentro de un umbral de tolerancia del δ (donde δ suele fijarse en 1 %, 3 %, 5 %, 10 % o 15 %) se calcula como:

$$\text{Hitting Rate}_{\leq \delta} = \frac{\text{Número de propiedades donde } \left|\frac{\hat{p}_i - p_i}{p_i}\right| \leq \frac{\delta}{100}}{n} \times 100$$

Donde:

- p_i: Es el precio de venta real registrado en el mercado [3].
- $\hat{p}_i$: Es la estimación calculada por el modelo AVM [3].
- $\left|\frac{\hat{p}_i - p_i}{p_i}\right|$: Es la desviación porcentual absoluta del avalúo [3].

2. Importancia práctica en el sector financiero y AVM

1. Evaluación de la fiabilidad comercial puntual: En la práctica bancaria, tributaria e hipotecaria, a menudo no basta con saber que un modelo tiene un error medio del 5 % o 10 %; los reguladores y departamentos de riesgo necesitan saber qué porcentaje de los inmuebles se valoran con alta precisión.
2. Complemento transparente del MAPE: El error porcentual medio (MAPE) puede verse sesgado por unos pocos inmuebles con desviaciones extremas. La Tasa de Acierto muestra la distribución acumulada de los aciertos, revelando el grado de sofisticación y consistencia del algoritmo en rangos operativos reales.

3. Evidencia empírica: Regresión Hedónica (OLS) vs. Random Forest (Estudio de *Gangnam*)

El estudio masivo sobre 16.601 transacciones de apartamentos en el distrito de *Gangnam* (Seúl) realizado por *Hong, Choi y Kim* (2020) demostró el salto cualitativo entre la regresión lineal tradicional (OLS) y *Random Forest* (RF) al evaluar las Tasas de Acierto:

Margen de Tolerancia ($\delta\%$)	Regresión Lineal (OLS) [5] [9]	Random Forest (RF) [5] [9]	Interpretación de Mercado [5] [6]
Dentro del 1% ($\leq 1\%$)	3.4%	**21.0%**	RF genera 6 veces más valoraciones virtualmente exactas [5] [9].
Dentro del 3% ($\leq 3\%$)	10.4%	**53.5%**	Más de la mitad de los avalúos de RF tienen un error $\leq 3\%$ [5] [9].
Dentro del 5% ($\leq 5\%$)	17.4%	**72.0%**	**7 de cada 10 inmuebles en RF caen dentro del 5% de error** [1] [...].
Dentro del 10% ($\leq 10\%$)	34.6%	**90.3%**	**9 de cada 10 estimaciones de RF se ajustan a un margen $\leq 10\%$** [5] [9].
Dentro del 15% ($\leq 15\%$)	50.9%	**95.6%**	Prácticamente la totalidad de la muestra alcanza precisión comercial [6] [9].

4. Conclusión

El incremento de la Tasa de Acierto del 17,4 % al 72,0 % (en el rango $\le 5\%$) evidencia que la capacidad de *Random Forest* para capturar estructuras jerárquicas e interacciones no lineales permite ofrecer predicciones notablemente más refinadas y confiables que la regresión hedónica lineal tradicional.

Tarjeta 42

En el anverso pone: "¿Qué beneficio ofrece la densidad geográfica alta de muestras en la precisión de un modelo Random Forest?" La respuesta del anverso es: "Permite capturar con precisión los efectos locacionales micro-urbanos y reduce la variabilidad no observada asociada a la distancia geográfica."

¿Podrías explicarme este tema más detalladamente?

En la valuación masiva inmobiliaria, la ubicación es un componente determinante del precio de una vivienda. Sin embargo, el valor locacional no opera únicamente a gran escala (como el distrito o la ciudad), sino que se manifiesta a nivel micro-urbano (la calle específica, el entorno inmediato de una manzana, la proximidad a una pequeña zona verde o el prestigio puntual de una urbanización).

1. El problema de la baja densidad espacial (Muestras dispersas)

Cuando una base de datos contiene propiedades muy alejadas o dispersas geográficamente sobre un territorio extenso:

- Extrapolación en zonas vacías: El modelo debe deducir el valor de inmuebles situados en áreas donde no existen transacciones cercanas.
- Mayor variabilidad no observada: A mayor distancia física entre las muestras, más difícil resulta medir y aislar los factores locales no registrados en el conjunto de datos (por ejemplo, el nivel de tráfico o ruido de la calle, la calidad del paisajismo inmediato o el estigma/prestigio micro-local).

2. Beneficios de una alta densidad geográfica de muestras

Contar con una elevada concentración de transacciones registradas dentro de una superficie acotada aporta dos ventajas estratégicas:

1. Captura de patrones micro-locacionales: Al haber abundantes datos en un área reducida, las coordenadas geográficas (latitud y longitud) o las agrupaciones micro-territoriales permiten al algoritmo realizar divisiones nodales muy finas, aislando submercados homogéneos a nivel de pocas manzanas o calles.
2. Reducción de la varianza por factores no observados: Dado que las viviendas comparables se encuentran muy próximas físicamente, las condiciones ambientales e infraestructurales no medidas en la base de datos son prácticamente idénticas entre ellas, disminuyendo la variabilidad residual.

3. Evidencia empírica en el estudio de Gangnam (Seúl)

El estudio masivo realizado por *Hong, Choi y Kim* (2020) evidencia el impacto directo de la densidad geográfica:

- Volumen y concentración: Se recopilaron 16.601 transacciones de apartamentos dentro del distrito de *Gangnam*, el cual abarca una extensión urbana de solo 39,55 km² (alcanzando una densidad media de ~420 transacciones por km²).
- Impacto en la precisión: Los autores señalaron que la alta densidad de las muestras fue un factor fundamental para explicar la precisión de *Random Forest*, el cual alcanzó un MAPE del 5,48 % y un (R^2 = 0,976). Al no existir vacíos geográficos significativos, el modelo aprendió con alta sensibilidad la estructura de precios del mercado sin necesidad de extrapolar a ciegas.

4. ¿Cómo aprovecha *Random Forest* esta densidad espacial?

Mientras que la regresión lineal tradicional (MCO / OLS) intenta resumir la ubicación mediante un

parámetro lineal simplificado o coeficientes por distrito, *Random Forest* explora de forma no paramétrica la estructura jerárquica de los datos:

- Con una muestra densa, las particiones binarias recursivas de los árboles de decisión dividen el plano geográfico en "cajones" o regiones locales hiper-específicas, agrupando viviendas con un contexto urbano casi idéntico y aumentando la precisión de la estimación.

Tarjeta 43

En el anverso pone: "¿Qué es la valuación masiva inmobiliaria (*Mass Appraisal*)?" La respuesta del anverso es: "Es el procedimiento estandarizado para valuar un gran número de propiedades de manera simultánea utilizando modelos matemáticos, estadísticas e información geográfica."

¿Podrías explicarme este tema más detalladamente?

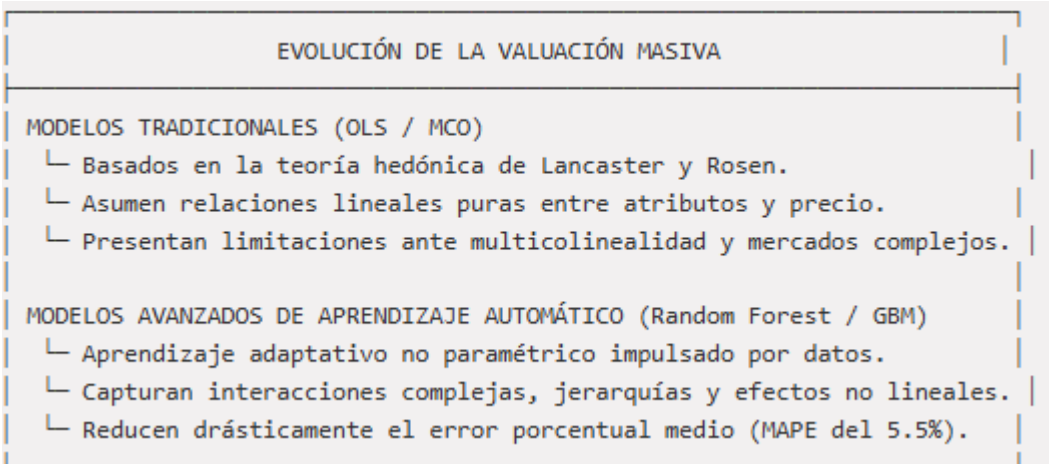
La valuación masiva inmobiliaria (*Mass Appraisal* o *Automated Valuation Model* - AVM) es el procedimiento sistemático y estandarizado para estimar de forma simultánea el valor de mercado de un gran volumen de propiedades a una fecha determinada.

A diferencia de la tasación individual tradicional —que requiere la inspección física y el análisis artesanal de comparables finca por finca—, la valuación masiva integra la estadística matemática, las tecnologías computacionales y los Sistemas de Información Geográfica (SIG) para construir modelos cuantitativos capaces de procesar la dinámica del mercado global.

1. Ámbitos de Aplicación e Importancia Institucional

1. Gestión Catastral y Tributaria (Sistemas CAMA):
    - Constituye la columna vertebral de los sistemas informáticos de valoración masiva (*Computer Assisted Mass Appraisal* - CAMA) utilizados por las administraciones públicas para determinar la base imponible del impuesto predial o de bienes inmuebles de forma equitativa.
2. Supervisión Financiera y Bancaria (Acuerdo de Basilea II):
    - El acuerdo regulatorio internacional de Basilea II exige a las entidades bancarias monitorear con frecuencia (como mínimo una vez al año) el valor de los inmuebles que sirven como garantía o colateral hipotecario. La valuación masiva mediante AVM permite actualizar el riesgo de las carteras hipotecarias masivas de manera ágil y a una fracción del costo de la tasación humana individual.

2. Evolución Metodológica: De la Economía Hedónica al *Machine Learning*



- Modelos Hedónicos Lineales (MCO / OLS):
    - Basados en la teoría de consumo de *Lancaster* y *Rosen*, plantean que el precio de una vivienda es la suma de los valores implícitos marginales de sus componentes físicos y de ubicación.
    - Aunque han sido la herramienta tradicional en AVM, sufren de rigideces al no capturar interacciones no lineales del mercado ni variaciones de peso de un atributo en diferentes submercados.
- Modelos Basados en Aprendizaje Automático (*Random Forest*, *Gradient Boosting*):
    - Representan el paradigma actual de los sistemas AVM. Algoritmos como *Random Forest* exploran la estructura jerárquica de los datos sin imponer supuestos rígidos de linealidad.
    - La evidencia empírica muestra que los modelos avanzados reducen el error porcentual absoluto medio (MAPE) de niveles del 19,.6 % en MCO a un 5,48 % en *Random Forest*, disminuyendo drásticamente los errores graves y mejorando la Tasa de Acierto (*Hitting Rate*).

3. Datos e Indicadores de Calidad en Valuación Masiva

Para que un modelo de valuación masiva sea preciso y auditable, se alimenta de tres grandes categorías de atributos:

1. Atributos Estructurales/Físicos: Superficie útil, número de dormitorios, baños, planta, ascensor o antigüedad.

2. Atributos Espaciales y de Accesibilidad: Coordenadas geográficas (latitud/longitud), cercanía a paradas de transporte, hospitales, colegios o parques.
3. Atributos Socioeconómicos y de Entorno: Renta media por sección censal o área de valor.

Para auditar si el sistema AVM cumple con los estándares internacionales fijados por organizaciones como la IAAO (*International Association of Assessing Officers*), la precisión del modelo se evalúa mediante métricas como el MAPE (magnitud del error relativo), el COD (Coeficiente de Dispersión para medir la uniformidad distributiva) y la Tasa de Acierto.

Tarjeta 44

En el anverso pone: "¿Qué herramienta de explicabilidad local permite explicar la predicción de Random Forest para una vivienda específica mediante un modelo interpretable sustituto?" La respuesta del anverso es: "LIME (*Local Interpretable Model-agnostic Explanations*)."

¿Podrías explicarme este tema más detalladamente?

LIME (*Local Interpretable Model-agnostic Explanations*) es una técnica de Inteligencia Artificial Explicable (XAI) diseñada para descifrar predicciones individuales hechas por modelos complejos de "caja negra", como *Random Forest*.

A diferencia de los métodos de interpretabilidad global (que intentan explicar el comportamiento general de un modelo en todo un mercado), LIME se enfoca en explicar por qué el modelo emitió una predicción específica para un inmueble determinado.

1. El concepto del "Modelo Sustituto Local" (*Surrogate Model*)

Para explicar un modelo complejo sin alterar su arquitectura interna, LIME utiliza una aproximación sustituta local:

1. Inaccesibilidad global, simplicidad local: Un modelo como *Random Forest* puede ser no lineal y sumamente complejo en todo el espacio de datos. Sin embargo, si nos enfocamos únicamente en el entorno o vecindario inmediato de una propiedad específica, la frontera de decisión del modelo se puede aproximar mediante una función lineal simple.
2. Agnóstico al modelo: LIME no necesita acceder a la estructura interna del algoritmo (los nodos o árboles). Funciona evaluando únicamente las pares de entrada (características de la casa) y salida (precio estimado).

2. Algoritmo de funcionamiento de LIME paso a paso

Para explicar la predicción del valor de un departamento específico (por ejemplo, estimarle un valor

de 250.000 €), LIME realiza los siguientes pasos:

```
┌──────────────────────────────────────────────────────────────────┐
│                  MECANISMO DE FUNCIONAMIENTO DE LIME             │
├──────────────────────────────────────────────────────────────────┤
│ 1. Selección del Inmueble Objetivo                               │
│    └─ Se toma la vivienda puntual cuyo avalúo se desea auditar.  │
│                                                                  │
│ 2. Generación de Perturbaciones (Vecindario)                     │
│    └─ Se crean cientos de "viviendas sintéticas" modificando     │
│       ligeramente los atributos (ej. ±5 m², ±1 año de antigüedad).│
│                                                                  │
│ 3. Inferencia en el Random Forest                                │
│    └─ El Random Forest predice el precio para cada muestra sintética.│
│                                                                  │
│ 4. Ponderación por Proximidad                                    │
│    └─ Se asigna más peso a las muestras más parecidas al inmueble real.│
│                                                                  │
│ 5. Ajuste del Modelo Sustituto                                   │
│    └─ Se entrena una Regresión Lineal Dispersa simple sobre esos datos.│
└──────────────────────────────────────────────────────────────────┘
```

El resultado final son los coeficientes de esa regresión lineal local, los cuales reflejan cuánto aporta o resta cada variable en la estimación de esa casa en particular (por ejemplo: Superficie > 90 m²: +35.000 €, Sin ascensor: -12.000 €).

3. LIME en la Valuación Inmobiliaria: Diagnóstico de Casos Atípicos

El uso combinado de LIME con *Random Forest* resulta de gran utilidad para el diagnóstico de errores y la detección de anomalías locales:

- Detección de desviaciones locales: En la investigación sobre precios residenciales con el *dataset Ames* (*Iowa*), *Wang* (2026) utilizó LIME para auditar viviendas atípicas, como casas de área reducida, pero con acabados de muy alta calidad.
- Giro de lógica en submercados: Mientras que la herramienta global SHAP indicaba que el área habitable era siempre el segundo factor más importante de precio en todo el mercado, LIME reveló que en las casas pequeñas de lujo el efecto del área se diluía, siendo reemplazado por el peso de la funcionalidad y la calidad de los materiales. Esto permitió identificar que el *Random Forest* ajustaba su lógica de decisión en rincones específicos de la muestra.

4. Cuadro Comparativo: LIME vs. SHAP vs. PDP/ICE

Herramienta	Enfoque de Interpretación	Metodología Base	Ventaja Principal
LIME	Local (Una vivienda individual).	Entrena un modelo sustituto lineal en el vecindario perturbado de la muestra.	Rápido computacionalmente y entrega explicaciones lineales sencillas para casos individuales.
SHAP	Global y Local.	Basado en la Teoría de Juegos Cooperativos (Valores de *Shapley*).	Teóricamente consistente y exacto, aunque requiere mayor tiempo de cómputo.
PDP / ICE	Global / Curvas de Respuesta.	Promedio marginal (PDP) o líneas individuales (ICE) variando un atributo continuo.	Ideal para identificar formas funcionales, curvas no lineales y efectos umbral.

Tarjeta 45

En el anverso pone: "Según los hallazgos empíricos de Cannon y Cole (2011), ¿cuál es el MAPE promedio de los avalúos inmobiliarios realizados por peritos humanos?" La respuesta del anverso es: "Aproximadamente un 12%."

¿Podrías explicarme este tema más detalladamente?

El hallazgo de *Cannon y Cole* (2011) sobre el Error Porcentual Absoluto Medio (MAPE) del 12% en las tasaciones humanas es uno de los datos de referencia (*benchmarks*) más citados en la literatura académica de economía inmobiliaria y Valuación Masiva (AVM).

1. El Contexto del Estudio de *Cannon y Cole* (2011)

Los investigadores *Sandra E. Cannon* y *Real A. Cole* publicaron el artículo *"How accurate are commercial real estate appraisals? Evidence from 25 years of NCREIF sales data"* en el *Journal of Portfolio Management*.

- Metodología y muestra: Analizaron un registro histórico masivo de 25 años de transacciones inmobiliarias comerciales pertenecientes al *National Council of Real Estate Investment Fiduciaries* (NCREIF) en Estados Unidos.
- El hallazgo clave: Compararon los montos estimados en los informes formales emitidos por peritos y tasadores profesionales humanos contra los precios de cierre reales negociados en el mercado.

- El resultado: El error relativo o desviación porcentual media de las tasaciones humanas se situó en aproximadamente un 12 % respecto al valor final de transacción. Estudios posteriores han confirmado cifras similares en otros mercados internacionales, como Italia (7,7 %) o Japón (13,9 %).

2. ¿Por qué existe este margen de error del 12% en la valuación humana?

A pesar de la experiencia y formación de los peritos tasadores, el proceso de valuación individual presenta limitaciones inherentes:

1. Límites de la percepción y procesamiento multivariante: Un ser humano solo puede considerar e interpretar simultáneamente un número muy reducido de características clave a la vez. En mercados complejos, la interacción conjunta de decenas de factores (físicos, micro-locacionales y macroeconómicos) supera la capacidad de procesamiento intuitivo.
2. Inexactitud de la homogeneización manual: El método comparativo tradicional requiere elegir manualmente un puñado de inmuebles "comparables" y aplicar ajustes o ponderaciones que a menudo contienen componentes de juicio subjetivo.
3. Iliquidez e inercia temporal: El valor de mercado cambia constantemente, pero el tasador suele basarse en ventas pasadas registradas con cierto desfase, lo que introduce inercia frente a aceleraciones o caídas rápidas del mercado.

3. Importancia del dato como *Benchmark* para evaluar los Modelos AVM

En la investigación moderna de valuación masiva, el MAPE del 12 % de la tasación humana sirve como la barra de medir contra la cual se evalúa la efectividad de la inteligencia artificial:

COMPARATIVA DEL ERROR PORCENTUAL MEDIO (MAPE)	
Regresión Lineal Hedónica Tradicional (OLS / MCO)	~ 19.6%
Peritos Tasadores Humanos (Cannon & Cole, 2011)	~ 12.0%
Random Forest (Hong, Choi & Kim, 2020 - Gangnam)	~ 5.5%

- Superación del modelo OLS: Una regresión lineal hedónica tradicional (MCO/OLS) suele cometer un error cercano al 20 % (como el 19,6 % observado en Gangnam o el 27,8 % en Sevilla), siendo sustancialmente menos precisa que un perito humano.
- La ventaja de *Random Forest*: Al integrar aprendizaje automático adaptativo de ensamble, *Random Forest* reduce el MAPE a rangos de solo el 5,5 %.

Este contraste demuestra que un modelo AVM bien entrenado con alta densidad de datos no solo corrige las deficiencias de la regresión lineal, sino que alcanza niveles de precisión y consistencia comercial superiores al promedio de la tasación humana tradicional.

Tarjeta 46

En el anverso pone: "¿Cómo afecta la homogeneidad del tipo de propiedad (ej. solo departamentos residenciales) a la exactitud del avalúo por *Random Forest*?" La respuesta del anverso es: "Mejora significativamente la precisión porque sus características estructurales se representan fácilmente con atributos cuantificables y consolidados."

¿Podrías explicarme este tema más detalladamente?

La homogeneidad del tipo de propiedad (como centrarse exclusivamente en apartamentos residenciales dentro de un mismo entorno urbano) es un factor determinante para maximizar la precisión predictiva de *Random Forest*.

A continuación, se explica en detalle el mecanismo analítico y la evidencia empírica que sustentan esta tarjeta didáctica:

1. La relación entre variables observables y no observadas

Para que un modelo de aprendizaje automático pueda estimar el precio de mercado con baja tasa de error, la base de datos debe contener atributos que capturen las verdaderas fuentes que determinan el valor del inmueble:

- En propiedades homogéneas (Apartamentos residenciales): Los determinantes principales del precio son atributos cuantificables, consolidados y estandarizables (superficie útil en m²), planta o piso, antigüedad del edificio, número de baños/habitaciones, ratio de aparcamiento y tipo de calefacción). Al ser características comunes entre todas las unidades de la muestra, se codifican sin perder información relevante.
- En propiedades heterogéneas (Casas unifamiliares / *Detached Houses*): Existe una alta variabilidad en factores difíciles de cuantificar o estructurar en una tabla de datos, tales como el diseño arquitectónico personalizado, la calidad de acabados interiores específicos, el paisajismo del jardín, las remodelaciones no registradas o la privacidad del lote.

Si una parte significativa de los factores que fijan el precio de una vivienda no está registrada en el conjunto de datos (*unobservable attributes*), la capacidad predictiva del modelo se degrada, no por un fallo del algoritmo, sino por falta de información explicativa de partida.

2. Evidencia Empírica: El Estudio de *Gangnam* (Seúl)

En el estudio masivo de *Hong, Choi y Kim* (2020) sobre 16.601 transacciones de compraventa de apartamentos en el distrito de *Gangnam*, el modelo *Random Forest* alcanzó una precisión récord:

- MAPE de 5,48 % (frente a casi un 20 % de la regresión lineal OLS).
- Coeficiente ($R^2 = 0,976$) (explicando más del 97% de la varianza total del mercado).

Los autores concluyeron explícitamente que este desempeño excepcional no se debió únicamente a las virtudes algorítmicas de *Random Forest*, sino a que el *dataset* abarcaba un único tipo de propiedad altamente homogéneo (apartamentos en un mismo distrito y nivel socioeconómico). Esto permitió que tan solo 16 variables estandarizadas y bien consolidadas bastaran para replicar con alta sensibilidad la estructura real de precios del mercado.

3. ¿Cómo aprovecha *Random Forest* la Homogeneidad?

Random Forest estima el valor dividiendo el espacio de datos en "hojas" terminales a través de cortes binarios:

1. Al trabajar con atributos estandarizados y comunes entre las observaciones, los árboles de decisión forman regiones locales o "cajones" extremadamente puros.
2. Los inmuebles contenidos en cada hoja comparten características estructurales y contextuales casi idénticas, lo que hace que sus precios reales de transacción estén fuertemente agrupados.
3. Al promediar esas hojas terminales en todo el bosque, el margen de error residual oscila en rangos mínimos de variación.

Tarjeta 47

En el anverso pone: "¿Por qué un modelo *Random Forest* supera a la regresión lineal cuando el mercado inmobiliario está segmentado en submercados por nivel de ingresos o tamaño?" La respuesta del anverso es: "Porque la estructura jerárquica de árbol permite adaptar implícitamente la importancia y el efecto de cada atributo según el segmento o submercado específico."

¿Podrías explicarme este tema más detalladamente?

La diferencia fundamental entre la Regresión Lineal Hedónica (OLS / MCO) y *Random Forest* (RF) al evaluar mercados inmobiliarios segmentados radica en cómo manejan la heterogeneidad y las interacciones contextuales entre los atributos.

1. La limitación de OLS: El supuesto de coeficientes globales estáticos

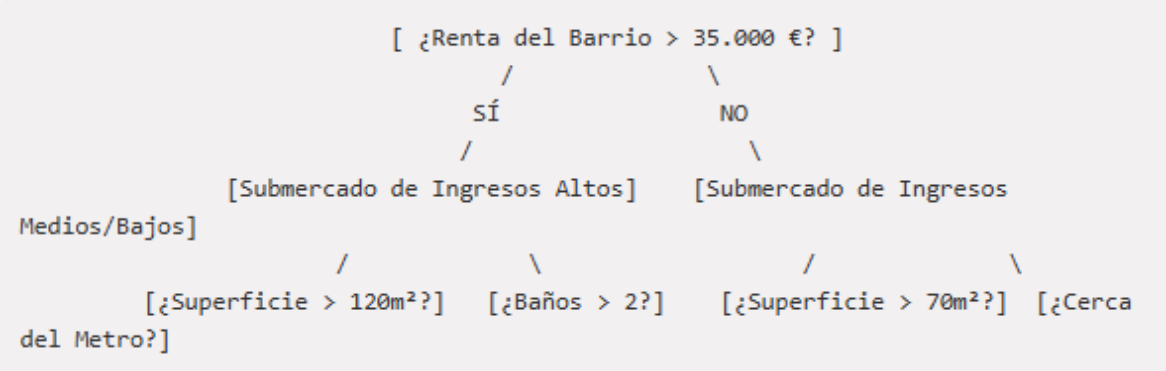
En la econometría hedónica tradicional por Mínimos Cuadrados Ordinarios, el modelo asigna a cada atributo un único coeficiente regresor estático (β_j) para toda la base de datos:

$$\text{Precio} = \beta_0 + \beta_1(\text{Superficie}) + \beta_2(\text{Baños}) + \beta_3(\text{Renta Barrio}) + \cdots + \varepsilon$$

- El problema de la rigidez: OLS asume que el efecto de cada atributo es separable y constante a lo largo de todo el mercado.
- Impacto en mercados segmentados: En la realidad urbana, añadir 20 m² adicionales o un baño extra no incrementa el valor en el mismo monto monetario si se trata de un apartamento pequeño de renta baja que si se trata de un inmueble de lujo en un distrito de ingresos elevados.
- Forzar un plano lineal único para todo el territorio provoca que OLS sobrevalore sistemáticamente las viviendas del segmento medio-bajo e infravalore las del segmento de alto valor, generando altas tasas de error y elevados Índices de Inflación de la Varianza (VIF).

2. El mecanismo de *Random Forest*: Partición jerárquica contextual

A diferencia de OLS, Random Forest no intenta ajustar una única ecuación algebraica global.Al estar compuesto por cientos de árboles de decisión, el algoritmo opera mediante particiones binarias recursivas (*recursive partitioning*):



1. Aislamiento de submercados en los nodos superiores: Las primeras ramificaciones del árbol actúan como "filtros contextuales" que segmentan la muestra según variables clave (como el nivel de renta de la sección censal, la localización o el tamaño del inmueble).
2. Adaptación local de la importancia de los atributos: Una vez que la observación recorre las ramas y llega a un submercado específico, las bifurcaciones subsecuentes evalúan el impacto de las características físicas de forma local y condicionada a ese contexto específico.

3. Captura de la "inestabilidad de la influencia de las variables": Como señalan la literatura teórica de *Breiman* y los estudios de AVM, *Random Forest* capta la variación del peso e impacto que un mismo predictor tiene a través de diferentes segmentos del mercado (*unsteadiness of variable influence across different segments*).

3. Interacciones no lineales aprendidas automáticamente (*Data-driven*)

En la regresión lineal, para capturar que el impacto de la superficie depende del nivel de ingresos, el valuador debería definir explícitamente términos de interacción complejos de forma manual (ej. $\beta \cdot Superficie \cdot Renta$).

Random Forest descubre estas interacciones complejas e interdependencias de forma completamente automática a partir de los datos:

- Evidencia empírica en las fuentes: Herramientas de interpretabilidad como las curvas ICE (*Individual Conditional Expectation)* y los valores SHAP demuestran que la pendiente del precio respecto a la superficie o al número de habitaciones cambia drásticamente según el nivel socioeconómico de la zona. En distritos de altos ingresos, variables como los acabados o el número de baños adquieren pendientes muy pronunciadas, mientras que en sectores de menor renta la superficie total y el acceso al transporte público dominan la formación del precio5more_horiz.

4. Impacto en las métricas de precisión AVM

Esta capacidad para adaptar la lógica de estimación según el submercado explica por qué *Random Forest* supera ampliamente a OLS en todos los estudios empíricos comparativos de la muestra:

- En Gangnam (Seúl), redujo el error relativo promedio (MAPE) del 19,6 % en OLS al 5,5 % en RF.
- En Sevilla (España), disminuyó el MAPE del 27,8 % en OLS al 19,6 % en RF.
- En *Liubliana* (Eslovenia), bajó el MAPE del 17,5 % en OLS al 7,3 % en RF.

En definitiva, la estructura jerárquica de árbol permite que el algoritmo "entienda" que las reglas del mercado cambian según el segmento de la propiedad, logrando valoraciones masivas mucho más precisas, equitativas y ajustadas a la realidad socioeconómica urbana.

Tarjeta 48

En el anverso pone: "En la investigación de *Wang* (2026) sobre la base de datos de viviendas de *Ames*, ¿qué método complementario se utilizó junto con *Random Forest* para la interpretabilidad

global del modelo?" La respuesta del anverso es: "El método SHAP (*SHapley Additive exPlanations*)."

¿Podrías explicarme este tema más detalladamente?

La tarjeta didáctica hace referencia a la investigación de *Ruoxian Wang* (2026) sobre el mercado inmobiliario de *Ames* (*Iowa*, EE. UU.). En este estudio, el autor abordó el dilema fundamental de la Inteligencia Artificial en la valuación de inmuebles: cómo aprovechar la alta precisión predictiva de *Random Forest* sin perder la transparencia del análisis inmobiliario.

Para resolver la naturaleza de "caja negra" del algoritmo, *Wang* construyó un marco analítico integral de dos niveles: SHAP para la interpretabilidad global (macro) y LIME para el diagnóstico de errores locales (micro).

1. El Contexto del Estudio en la Base de Datos de Ames

El conjunto de datos de *Ames* (Iowa) es una de las referencias más utilizadas en la ciencia de datos inmobiliaria por su riqueza informativa (contiene 2.930 registros de transacciones reales y 82 variables explicativas).

Al entrenar el algoritmo de *Random Forest* sobre esta base de datos, el modelo alcanzó un rendimiento excelente:

- Coeficiente de Determinación (R^2): 0,84 (explicando el 84 % de la varianza del mercado).
- Error Porcentual Absoluto Medio (MAPE): 10,43 %.

A pesar de estos excelentes resultados de ajuste, el modelo no genera coeficientes lineales directos por sí solo. Por ello, *Wang* incorporó la metodología SHAP para auditar cómo el bosque aleatorio tomaba sus decisiones a nivel global.

2. ¿Qué es SHAP y por qué se utiliza para la Interpretabilidad Global?

SHAP (*SHapley Additive exPlanations*) es un método de explicabilidad basado en la Teoría de Juegos Cooperativos desarrollada por el Premio Nobel *Lloyd Shapley*.

- Mecanismo matemático: Asigna a cada variable un valor de atribución (Valor *Shapley*) que cuantifica su contribución marginal neta a la predicción final, evaluando todas las combinaciones posibles de características (*coaliciones*).
- Algoritmo *TreeSHAP*: Para modelos basados en árboles como *Random Forest*, se utiliza la variante *TreeSHAP*, que aprovecha la estructura interna de los nodos para calcular estos valores de forma matemáticamente exacta y computacionalmente eficiente.

Hallazgos Globales Clave en *Ames* mediante SHAP:

1. Calidad General de Materiales y Acabados (*OverallQual*): SHAP reveló que la calidad intrínseca del edificio es el predicto global más determinante del valor en *Ames*.
2. Superficie Habitable (*GrLivArea*): Se posicionó como la segunda variable con mayor peso explicativo directo.
3. Efecto de Interacción: El análisis de dispersión SHAP permitió identificar una interacción positiva continua entre ambas variables: la alta calidad del inmueble amplifica de forma no lineal el impacto monetario de cada metro cuadrado adicional de superficie.

3. SHAP frente a la Importancia de Variables Tradicional de *Random Forest*

Antes del desarrollo de SHAP, la importancia de las variables en *Random Forest* se evaluaba mediante la Reducción Media de Impureza (Gini/MSE). Sin embargo, la métrica tradicional presentaba dos limitaciones importantes que SHAP logra resolver:

Criterio	Importancia Tradicional (Impureza/Gini)	Interpretabilidad Global con SHAP
Dirección del Efecto	Muestra solo un valor escalar abstracto; no indica si la variable suma o resta precio.	Muestra la dirección y el signo: distancias en rojo aumentan el precio; en azul lo reducen.
Unidad de Medida	Expresada en puntos de impureza o reducción de varianza residual.	Expresada en la moneda real del mercado (USD) como desviaciones respecto al precio promedio base.
Sesgo por Tipo de Variable	Tiende a sobreestimar variables continuas o con alta cardinalidad.	Distribución imparcial y consistente basada en la contribución neta marginal.

4. La Sinergia del Marco: SHAP (Global) + LIME (Local)

El mayor aporte metodológico de la investigación de *Wang* radica en demostrar que ningún método de interpretabilidad por sí solo es suficiente:

- SHAP (Macro / Global): Establece la jerarquía de reglas y la tendencia general del mercado (ej. a nivel macro, mayor área equivale a mayor precio).

- LIME (Micro / Local): Se aplica sobre muestras o subgrupos específicos para auditar anomalías. En el estudio, LIME reveló que, en inmuebles de superficie reducida, pero de calidad de lujo ("muestras atípicas"), la contribución local del área se reducía drásticamente, siendo sustituida por variables de funcionalidad y acabados locales.

Gracias a la combinación de Random Forest + SHAP, el modelo alcanza una precisión máxima del 10,43 % de MAPE y al mismo tiempo ofrece un informe de valoración transparente, auditable y justificado punto por punto.

Referencias Bibliográficas

- Comité de Supervisión Bancaria de Basilea (BCBS). (2006). *Convergencia internacional de medidas y normas de capital: Marco revisado (Basilea II)*. Banco de Pagos Internacionales (BPI).
- *Breiman, L*. (1996). *Bagging predictors. Machine Learning*, 24(2), 123–140.
- *Breiman, L.* (2001). *Random forests. Machine Learning*, 45(1), 5–32.
- *Breiman*, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth International Group.
- *Cannon, S. E., & Cole, R. A.* (2011). *How accurate are commercial real estate appraisals? Evidence from 25 years of NCREIF sales data*. *The Journal of Portfolio Management*, 37(5), 68–88. https://doi.org/10.3905/jpm.2011.37.5.068
- *Čeh, M., Kilibarda, M., Lisec, A., & Bajat, B.* (2018). Estimating the performance of random forest versus multiple regression for predicting prices of the apartments. *ISPRS International Journal of Geo-Information*, 7(5), 168. https://doi.org/10.3390/ijgi7050168
- *Goldstein, A., Kapelner, A., Bleich, J., & Pitkin, E.* (2015). Peeking inside the black box: Visualizing statistical learning with plots of individual conditional expectation. *Journal of Computational and Graphical Statistics*, 24(1), 44–65.
- Guijarro Martínez, F. (2023). Valoración automática de inmuebles residenciales mediante modelos de Machine Learning. *Revista de Estudios Empresariales. Segunda Época*, (2), 27–40.
- Gutiérrez, E., Caridad López del Río, L., & Caridad Ocerín, J. M. (2026). Determinantes del precio de la vivienda en Sevilla: un enfoque interpretativo con aprendizaje automático. *Revista INVI*, 41(116), 203–243.
- *Hong, J., Choi, H., & Kim, W.* (2020). A house price valuation based on the random forest approach: The mass appraisal of residential property in South Korea. *International Journal of Strategic Property Management*, 24(3), 140–152.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En I. Guyon et al. (Eds.), *Advances in Neural Information Processing Systems 30* (NIPS 2017) (pp. 4765–4774). Curran Associates, Inc.

- *Ribeiro, M. T., Singh, S., & Guestrin, C.* (2016). "*Why should I trust you?": Explaining the predictions of any classifier*. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 1135–1144). ACM.
- *Wang, R.* (2026). Feature attribution and error diagnosis of a Random Forest housing price prediction model integrating SHAP and LIME. En *Proceedings of CONF-MPCS 2026 Symposium: Theoretic Physics and Plasma Physics* (Vol. 2026, Article DL34409).
- *Zhao, C. Y.* (2020). *Research on second hand housing transaction price prediction based on ensemble learning* (Tesis de maestría, Shanxi University).

Clasificación Temática de las Referencias para Estudio

- Fundamentos Matemáticos del Algoritmo: *Breiman (1984, 1996, 2001)*.
- Valuación Masiva y AVM en Inmuebles Residenciales: *Hong et al. (2020)*, *Čeh et al. (2018)*, *Guijarro (2023)*, *Gutiérrez et al. (2026)* y *Zhao (2020)*.
- Interpretabilidad e Inteligencia Artificial Explicable (XAI): *Goldstein et al. (2015)* (ICE), *Lundberg & Lee (2017)* (SHAP), *Ribeiro et al. (2016)* (LIME) y *Wang (2026)* (Ames/SHAP+LIME).
- Precisión de Tasación Humana y Normativa: *Cannon & Cole (2011)* y *Comité de Basilea II*.